

Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский физико-технический институт
(национальный исследовательский университет)»
Физтех-школа прикладной математики и информатики
Кафедра интеллектуальных систем

Дорин Даниил Дмитриевич

**ДЕКОДИРОВАНИЕ ВИЗУАЛЬНОЙ ИНФОРМАЦИИ ИЗ
СИГНАЛОВ МОЗГА НА ОСНОВЕ
ПРОСТРАНСТВЕННО-ВРЕМЕННЫХ
ХАРАКТЕРИСТИК**

09.04.01 — Информатика и вычислительная техника

Выпускная квалификационная работа магистра

Научный руководитель:
Грабовой Андрей Валериевич,
канд. физ.-мат. наук

Москва — 2026

Аннотация

Реконструкция визуальных стимулов по нейронным сигналам представляет собой фундаментальную задачу нейродекодирования, находящуюся на пересечении вычислительной нейронауки и современного машинного обучения. Несмотря на успехи, достигнутые с применением контрастивных представлений и диффузионных генеративных моделей, большинство существующих подходов ограничены использованием одной модальности — либо функциональной магнитно-резонансной томографии (фМРТ) с высоким пространственным разрешением, либо электроэнцефалографии (ЭЭГ) с превосходной временной точностью. Совместное использование этих модальностей остается малоизученным направлением.

Декодирование формализуется в единой постановке и решается в три последовательных этапа, отвечающих возрастающей сложности учитываемой структуры данных: анализ временной динамики сигнала фМРТ, учет его совместной пространственно-временной структуры в условиях ограниченного объема выборки и мультимодальное объединение фМРТ и ЭЭГ. Завершающим этапом служит предлагаемая мультимодальная архитектура, одновременно обрабатывающая сигналы фМРТ и ЭЭГ для реконструкции визуальных стимулов. Для согласования асинхронных и неоднородных записей разработан конвейер предобработки, включающий учет гемодинамической задержки, построение индивидуальных масок мозга испытуемых и восстановление пропущенных ЭЭГ-каналов методом пространственной интерполяции. Эмбединги сигналов мозга контрастивно обучаются для приближения к CLIP-эмбедингам изображений. Предложенная двухстадийная схема генерации включает синтез промежуточного латентного представления через априорную модель, обученную на совместных фМРТ–ЭЭГ эмбедингах, и декодирование этого представления с помощью предобученной диффузионной модели SDXL. Эксперименты на открытом мультимодальном датасете подтверждают эффективность предложенной архитектуры в задаче нейродекодирования. По метрике CLIP-Score мультимодальная модель превосходит одномодальные аналоги, а интеграция диффузионной априорной модели дополнительно повышает семантическую согласованность реконструкций. Через кросс-доменное тестирование проанализированы границы применимости предложенного метода.

Содержание

Обозначения и сокращения	5
Введение	7
1 Анализ предметной области и обзор существующих решений	12
1.1 Визуальные энкодеры для извлечения семантических признаков .	12
1.2 Наборы данных с одновременной регистрацией фМРТ и ЭЭГ . .	12
1.3 Одномодальные методы декодирования визуальной информации .	13
1.4 Генеративные модели для реконструкции изображений	14
1.5 Пространственно-временные характеристики в анализе нейросигналов	14
2 Постановка задачи	16
2.1 Общая постановка мультимодального декодирования	16
2.2 Оценка гемодинамической задержки	16
2.3 Классификация временных рядов фМРТ	17
2.4 Мультимодальное декодирование фМРТ–ЭЭГ	17
3 Методы	18
3.1 Линейная модель для оценки гемодинамической задержки	18
3.2 Пространственно-временная классификация фМРТ	20
3.2.1 Извлечение масок активности мозга	21
3.2.2 Классификация временных рядов	21
3.2.3 Проекция на касательное пространство риманова многообразия	22
3.3 Мультимодальная реконструкция стимулов по сигналам фМРТ–ЭЭГ	23
3.3.1 Контрастивное обучение комбинированных представлений	23
3.3.2 Процесс реконструкции стимулов	30
4 Вычислительный эксперимент	33
4.1 Анализ гемодинамической задержки	33
4.2 Классификация временных рядов фМРТ	35
4.3 Мультимодальное декодирование фМРТ–ЭЭГ	39
4.3.1 Данные	40

4.3.2	Параметры энкодеров	42
4.3.3	Результаты экспериментов	43
4.3.4	Ограничения метода	48
	Заключение	50
	Список литературы	51

Обозначения и сокращения

Сокращения

ИМК	интерфейс мозг–компьютер
фМРТ	функциональная магнитно-резонансная томография
ЭЭГ	электроэнцефалография
BOLD	blood-oxygen-level dependent
CLIP	Contrastive Language–Image Pre-training
SDXL	Stable Diffusion XL
DDPM	Denoising Diffusion Probabilistic Model
IP-Adapter	Image Prompt Adapter
MLP	многослойный перцептрон
ROI	Region of Interest
TSM	Tangent Space Mapping
MSE	среднеквадратичная ошибка восстановления
CLIP-Score	косинусная близость в пространстве CLIP-эмбеддингов

Основные обозначения

$\mathcal{X}_f, \mathcal{X}_e$	пространства данных фМРТ и ЭЭГ
$\mathcal{Y}$	пространство визуальных стимулов
$\mathbf{F}_i, \mathbf{E}_i, \mathbf{I}_i$	фМРТ, ЭЭГ и изображение i -го наблюдения
$\mathbf{S}, \mathcal{T}, L$	временной ряд фМРТ, его длина и число категорий
$\mathfrak{D}$	обучающая выборка
N	объем выборки
$\mathbf{g}$	общее отображение декодирования $\mathcal{X} \rightarrow \mathcal{Y}$
$\mathbf{q}$	прогноз фМРТ-отклика по стимулу $\mathcal{Y} \rightarrow \mathcal{X}_f$
$\mathbf{h}$	классификатор временных рядов $\mathcal{X}_s \rightarrow \{1, \dots, L\}$
$\mathbf{f}$	мультимодальное отображение $\mathcal{X}_f \times \mathcal{X}_e \rightarrow \mathcal{Y}$
$\mathcal{E}_f, \mathcal{E}_e, \mathcal{F}$	энкодеры фМРТ, ЭЭГ и модуль объединения
$\mathbf{Z}_f, \mathbf{Z}_e, \mathbf{Z}_c, \mathbf{Z}_I$	эмбединги фМРТ, ЭЭГ, комбинированный и CLIP
d_f, d_e, d	размерности латентных пространств
Δt	гемодинамическая задержка BOLD-сигнала
$\delta(t)$	приращение фМРТ-скана между соседними кадрами
λ	коэффициент L_2 -регуляризации
$\mathcal{M}, \mathcal{M}^y$	бинарная маска активности: общая и для класса y
$\bar{\mathbf{R}}$	риманово среднее ковариационных матриц
τ	обучаемая температура контрастивной функции потерь
$\mathcal{L}_{\text{contr}}$	контрастивная функция потерь
$\mathcal{L}_{\text{prior}}$	функция потерь априорной диффузионной модели
B	размер батча

Введение

Современные достижения в области анализа нейробиологических данных и нейровизуализации существенно расширили возможности разработки интерфейсов мозг–компьютер (ИМК) [1, 2]. ИМК — это технология прямого взаимодействия нервной системы с внешними устройствами в обход периферических нервно-мышечных путей [3]. Регистрируя и декодируя нейробиологические сигналы — прежде всего электроэнцефалограмму (ЭЭГ), магнитоэнцефалограмму (МЭГ) и функциональную магнитно-резонансную томографию (фМРТ) — такие системы переводят ментальные намерения и когнитивные состояния в управляющие команды для протезов, роботов или компьютерных интерфейсов [4, 5, 6]. Для пациентов с тяжелыми двигательными или коммуникативными нарушениями это открывает возможность вернуть способность к автономному взаимодействию с окружающей средой [7]. Настоящая работа посвящена задаче декодирования и реконструкции визуальных стимулов по одновременным неинвазивным записям мозговой активности — фМРТ и ЭЭГ. Регистрируемые сигналы отражают динамику восприятия визуальных сцен, причем само восприятие зависит не только от свойств внешнего стимула, но и от внутренних когнитивных состояний, эмоциональных реакций и индивидуального опыта наблюдателя.

ЭЭГ и фМРТ — две ключевые нейробиологические модальности, чьи пространственно-временные характеристики разрешения взаимно дополняют друг друга. фМРТ измеряет связанный с нейронной активностью гемодинамический ответ через BOLD-сигнал, который проявляется с задержкой 4–8 секунд [8, 9]; такая задержка отражает инерционность сосудистой системы, медленно реагирующей на возросшую потребность мозга в глюкозе [10, 11]. Сильная сторона фМРТ — высокое пространственное разрешение, тогда как временное жестко ограничено малой частотой сканирования [12]. К этому добавляется чувствительность записи к артефактам от движений головы, пульсации, дыхания и теплового шума сканера [13, 14]. ЭЭГ устроена противоположным образом: она дает высокое временное разрешение и позволяет следить за динамикой нейронных процессов в реальном времени [15], однако ее пространственная локализация ограничена объемной проводимостью тканей головы, а сам сигнал ослаблен низким отношением сигнал/шум [16] и выраженной межиндивидуальной вариабельностью [17, 18]. Совмещение ЭЭГ и фМРТ в одной сессии объединяет достоинства обеих модальностей, но заставляет считаться со специ-

фикой магнитно-резонансной среды: сильное магнитное поле порождает мощные градиентные и кардиобаллистические артефакты [19, 20]. Для их компенсации необходимы магнитно-резонансно совместимые системы записи, точная синхронизация временных меток и специализированные методы постобработки [21].

В связи с развитием контрастивного обучения появилась возможность эффективно сопоставлять данные из разных модальностей. Так, в модели CLIP [22] с помощью контрастивной функции потерь, построенной на косинусном расстоянии, удалось обучить совместное латентное пространство для эмбедингов изображений и текстовых описаний. Аналогичный подход был распространен и на другие пары модальностей — при условии подбора соответствующих энкодеров [23, 24]. В области ИМК это привело к появлению методов реконструкции изображений по нейробиологическим сигналам, в первую очередь по фМРТ или ЭЭГ в отдельности [25, 26]. Основная идея большинства современных моделей заключается в том, чтобы контрастивно приблизить эмбединги мозговой активности к CLIP-эмбедингам изображений. Поскольку CLIP обучался на сопоставлении изображений и текста, его пространство эмбедингов обладает богатой семантической структурой и демонстрирует высокую эффективность в задачах zero-shot (англ. zero-shot, «без примеров»), то есть на новые данные без дополнительного обучения [22]. Это делает CLIP-эмбединги особенно подходящими для обуславливания генеративных моделей, используемых в реконструкции изображений, предъявленных испытуемому во время записи нейросигналов [26]. Однако существующие подходы опираются лишь на одну модальность. В то же время фМРТ и ЭЭГ демонстрируют фундаментально разные, но взаимодополняющие характеристики: первая обеспечивает высокое пространственное разрешение при низком временном, вторая — наоборот [12, 15]. Их комбинация позволяет компенсировать слабые стороны каждой из модальностей и потенциально повысить качество реконструкции.

В данной работе решается задача реконструкции изображений по одновременно зарегистрированным сигналам фМРТ–ЭЭГ, как проиллюстрировано на рис. 1.

До появления недавних мультимодальных наборов данных с визуальными стимулами, таких как [27], обработка ЭЭГ и фМРТ, как правило, проводилась отдельно. Новые датасеты открывают возможность интегрировать оба типа сигналов в единую архитектуру. По аналогии с предшествующими работами, в




Рис. 1: Иллюстрация задачи реконструкции изображений по одновременным сигналам фМРТ-ЭЭГ

настоящей работе используется двухэтапный метод декодирования мозговой активности: 1) контрастивное выравнивание сигналов фМРТ и ЭЭГ с эмбедингами изображений; 2) обуславливание предобученной модели генерации изображений на уточненной априорной моделью эмбединг сигналов мозга. Решение строится в три последовательных этапа, отражающих постепенное усложнение учитываемой структуры сигнала: анализ временной динамики фМРТ, последующий учет его пространственно-временной структуры в условиях ограниченного объема выборки и мультимодальное декодирование по совместным записям фМРТ-ЭЭГ. Основной же вклад настоящей работы заключается в следующем:

- Задача декодирования визуальной информации по сигналам мозга формализована в единой постановке, объединяющей три подзадачи: оценку гемодинамической задержки, классификацию временных рядов фМРТ в условиях ограниченного объема выборки и мультимодальную реконструкцию стимулов по сигналам фМРТ-ЭЭГ.
- Предложена линейная модель прогнозирования фМРТ-отклика по визуальному стимулу, обеспечивающая оценку гемодинамической задержки BOLD-сигнала; полученная оценка согласуется с известным физиологическим диапазоном и используется для временной синхронизации модальностей.
- Разработан метод пространственно-временной классификации временных рядов фМРТ, основанный на масках активности и римановой геометрии ковариационных матриц и сохраняющий устойчивость в условиях ограниченного объема выборки одного испытуемого.

- Вводится мультимодальная модель, использующая одновременно и фМРТ, и ЭЭГ сигналы для реконструкции изображений, просматриваемых пациентом.
- Предлагается архитектура мультимодальной модели, в которой обучаются три модуля: два энкодера, независимо обрабатывающих наблюдаемые сигналы, и модуль объединения, переводящий их в единое комбинированное представление.
- Проводится сравнительный анализ исключением модальностей, демонстрирующий необходимость учета обоих сигналов фМРТ и ЭЭГ совместно.

Публикации и апробация результатов работы. По теме исследования автором подготовлены и представлены следующие работы.

Публикации в научных журналах:

1. **Dorin D.**, Kiselev N. et al. Forecasting fMRI Images From Video Sequences: Linear Model Analysis // Health Information Science and Systems. — 2024. doi: [10.1007/s13755-024-00315-5](https://doi.org/10.1007/s13755-024-00315-5)
2. **Dorin D.**, Grabovoy A., Strijov V. Enhancing fMRI Data Decoding with Spatiotemporal Characteristics in Limited Dataset // Doklady Mathematics. — 2025. doi: [10.1134/S1064562425700383](https://doi.org/10.1134/S1064562425700383)
3. **Dorin D.**, Kiselev N., Grabovoy A. Decoding Visual Information from Neural Signals: Image Reconstruction Based on Joint fMRI and EEG Analysis // Informatika i ee Primeneniya. — 2026.

Доклады на научных конференциях:

1. **Дорин Д. Д.**, Киселев Н. С., Грабовой А. В. Пространственно-временные методы анализа временных рядов // 66-я Всероссийская научная конференция МФТИ — 2024.
2. **Дорин Д. Д.**, Грабовой А. В. Улучшение декодирования фМРТ в условиях ограниченной выборки // 67-я Всероссийская научная конференция МФТИ — 2025.

3. *Дорин Д. Д., Грабовой А. В.* Декодирование визуальной информации из сигналов мозга на основе пространственно-временных характеристик // 68-я Всероссийская научная конференция МФТИ — 2026.
4. *Дорин Д. Д., Киселев Н. С., Грабовой А. В.* Декодирование визуальных стимулов из мультимодальных сигналов мозга // 22-я конференция «Математические методы распознавания образов» (ММРО-2025).
5. *Дорин Д. Д., Грабовой А. В.* Улучшение декодирования данных фМРТ в условиях ограниченного набора данных // AI Journey 2025.

1. Анализ предметной области и обзор существующих решений

В главе рассматриваются ключевые компоненты, на которые опирается декодирование визуальной информации по сигналам мозга: визуальные энкодеры, наборы данных с одновременной регистрацией фМРТ и ЭЭГ, одномодальные методы декодирования, генеративные модели реконструкции, а также методы анализа пространственно-временных характеристик нейросигналов.

1.1. Визуальные энкодеры для извлечения семантических признаков

Визуальный энкодер является одной из ключевых компонент рассматриваемой модели, поскольку от его качества напрямую зависит, насколько полно удастся извлечь семантическую информацию из изображения, включая объекты, их позы и контекст сцены. Для многих задач традиционно используются предобученные с учителем энкодеры, среди которых наиболее распространены сверточные архитектуры VGG-19 [28] и ResNet [29], а также Vision Transformer (ViT) [30]. Такие энкодеры дают устойчивые визуальные эмбединги, и все же, как показывают недавние работы по контрастивному обучению и самообучению, модели вроде CLIP [22] и DINO [31] на базе ViT формируют заметно более выразительные и обобщаемые представления, чем их аналоги, обученные с учителем. Это преимущество устойчиво проявляется в широком круге задач переноса обучения — в том числе при декодировании и реконструкции изображений по нейросигналам. Поэтому в роли визуального энкодера здесь выбран именно CLIP [22]: он эффективен, устойчив к доменным сдвигам и обладает богатой семантической структурой латентного пространства.

1.2. Наборы данных с одновременной регистрацией фМРТ и ЭЭГ

Постановка и решение задачи реконструкции изображений по мозговой активности невозможны без качественных наборов данных, в которых фМРТ и ЭЭГ регистрируются одновременно и под предъявление визуальных стимулов. За последние годы появилось несколько открытых датасетов, включающих совместную регистрацию этих модальностей. Однако большинство доступных наборов либо исключают визуальную стимуляцию, например, регистрируют активность в состоянии покоя или при аудиостимуляции [32, 33], либо содержат разнесенные

во времени сессии фМРТ и ЭЭГ [34], либо ориентированы на верификацию технической совместимости методов регистрации, а не на исследование стимул-зависимой нейродинамики [35]. Из доступных на момент написания работы датасетов лишь два обеспечивают одновременную регистрацию при предъявлении визуальных стимулов: датасет Telesford и др. [27] и датасет Wakeman и др. [36]. Первый содержит записи от 22 участников при просмотре как синтетических стимулов — мерцающего шахматного поля и абстрактных сцен в парадигме Inscapes, — так и натуралистических — коротких видеороликов. Второй включает данные 16 участников при выполнении задачи распознавания статичных изображений лиц. В работе рассматривается датасет [27] в качестве основного, поскольку разнообразие стимулов — от контролируемых синтетических до динамических естественных видео — обеспечивает более широкое покрытие визуальных паттернов и способствует обучению обобщаемых моделей реконструкции. Именно на его основе формируются обучающие тройки (фМРТ, ЭЭГ, изображение).

1.3. Одномодальные методы декодирования визуальной информации

Недавние достижения в декодировании визуальной информации по фМРТ продемонстрировали высокое качество реконструкции за счет интеграции контрастивного обучения и генеративных моделей [25]. Авторы [37] предлагают двухэтапную модель: на первом этапе данные фМРТ кодируются с помощью регрессии, обучаемой индивидуально для каждого участника, после чего реконструируется грубое изображение с помощью VDVAE; на втором — изображение уточняется диффузионной моделью, обусловленной как CLIP-эмбедингами исходного изображения, так и его текстовым описанием, что обеспечивает высокую семантическую согласованность реконструкции. В работе [38] предлагается метод реконструкции видео по временному ряду фМРТ. Используется контрастивное обучение и CLIP-эмбединги, аналогично предыдущему исследованию. Генерация видео осуществляется с помощью модифицированной диффузионной модели с временным вниманием и обуславливанием на эмбединги фМРТ. В работе [39] предлагается диффузионная априорная модель для уточнения фМРТ-эмбедингов в CLIP-пространстве, устраняющая разрыв между модальностями и повышающая качество декодирования. На основе ЭЭГ также до-

стигнуто сопоставимое качество реконструкции. Основная идея многих работ аналогична: двухэтапная реконструкция — сначала контрастивно обучаются эмбединги сигналов ЭЭГ к CLIP-эмбедингам изображений, затем используются предобученная генеративная модель для реконструкции [26, 40, 41]. В качестве кодировщиков применяют различные архитектуры: индивидуальные LSTM для каждого пациента [41], сверточные сети [40], а также гибридные архитектуры, сочетающие свертки с механизмом внимания [26]. Представленные подходы легли в основу проектирования предлагаемого мультимодального энкодера.

1.4. Генеративные модели для реконструкции изображений

Современные генеративные модели изображений сыграли ключевую роль в продвижении задач визуального декодирования. Наиболее успешными оказались латентно-диффузионные архитектуры, которые работают в компактном скрытом пространстве и допускают гибкое обуславливание на внешние эмбединги [42, 43]. Отдельную линию исследований составляют модели, непосредственно обусловленные на CLIP-эмбединги изображений и/или текста, что позволяет использовать общее семантическое пространство для управления генерацией [22, 44]. В таких подходах CLIP-пространство выступает универсальным интерфейсом между модулями, кодирующими различные модальности, и генератором. В настоящей работе следует этой парадигме: для реконструкции изображений используется предобученная латентно-диффузионная модель SDXL (англ. Stable Diffusion XL) [45], обусловленная на CLIP-эмбединги через адаптер IP-Adapter (англ. Image Prompt Adapter) [45, 46], что позволяет напрямую переносить информацию из комбинированных эмбедингов фМРТ–ЭЭГ в пространство генерации.

1.5. Пространственно-временные характеристики в анализе нейросигналов

Точное выделение активных областей мозга, или областей интереса (англ. ROI), составляет ключевой этап декодирования фМРТ: значительная доля вокселей соответствует фону и вносит шум, тогда как за обработку конкретных стимулов отвечают локальные зоны [8, 47]. Наряду с пространственной локализацией важна временная динамика сигнала, и для ее описания хорошо зарекомендовала себя риманова геометрия. Она представляет нейросигнал ко-

вариационными матрицами и работает с ними как с точками на многообразии симметричных положительно определенных матриц, а не как с векторами в евклидовом пространстве [48, 49]. Такой подход успешно применялся к ЭЭГ в задачах классификации моторных образов и распознавания состояний [50, 51, 52], что мотивирует его перенос на данные фМРТ. Классические методы снижения размерности здесь уступают: метод независимых компонент [53] требует множества сигналов, а метод главных компонент [54] игнорирует неевклидову геометрию ковариационных матриц.

Современные архитектуры глубокого обучения, включая рекуррентные нейронные сети, трансформеры и графовые сверточные сети, демонстрируют высокую эффективность при выявлении сложных зависимостей в многомерных временных рядах [55, 56, 57]. Тем не менее, для достижения высокой обобщающей способности этим моделям требуются обширные обучающие выборки. В контексте нейровизуализации объем доступных данных, напротив, существенно ограничен, поскольку запись активности одного испытуемого, как правило, сводится к единственному, протяженному, временному ряду. Данный факт обуславливает необходимость в разработке методов, способных эффективно извлекать пространственно-временные признаки в условиях малого объема выборки.

2. Постановка задачи

Декодирование визуальной информации по сигналам мозга рассматривается в работе как единая задача, к которой осуществляется постепенный переход: сначала анализируется временная динамика сигнала фМРТ, затем к ней добавляется пространственная структура, и наконец выполняется переход к мультимодальности — совместному использованию фМРТ–ЭЭГ. Ниже вводится общий формализм, после чего конкретизируются три отвечающие этим этапам постановки.

2.1. Общая постановка мультимодального декодирования

Пусть $\mathcal{X}_{(m)}$ — пространство наблюдений модальности m , где $m = 1, \dots, M$. Совместное пространство нейробиологических данных определяется как декартово произведение:

$$\mathcal{X} = \mathcal{X}_{(1)} \times \dots \times \mathcal{X}_{(M)}. \quad (1)$$

Визуальный стимул или его характеристика описываются пространством $\mathcal{Y}$. Задача мультимодального декодирования состоит в построении отображения:

$$\mathbf{g} : \mathcal{X} \rightarrow \mathcal{Y}. \quad (2)$$

В рамках общей постановки в работе решаются три задачи: оценка гемодинамической задержки, классификация временных рядов фМРТ и мультимодальное декодирование по одновременным записям фМРТ–ЭЭГ при $M = 2$.

2.2. Оценка гемодинамической задержки

BOLD-сигнал фМРТ возникает с гемодинамической задержкой Δt относительно момента предъявления визуального стимула [9, 11]; ЭЭГ-сигнал, напротив, отражает нейронный отклик практически без задержки. Для анализа задержки рассматривается обратная к декодированию задача: по предъявленному стимулу предсказать вызванный им фМРТ-отклик. Согласно гипотезе о гемодинамической задержке, фМРТ-скан $\mathbf{F}(t) \in \mathcal{X}_f \subseteq \mathbb{R}^{X \times Y \times Z}$ в момент t порождается не текущим, а сдвинутым на Δt в прошлое стимулом $\mathbf{y}(t - \Delta t) \in \mathcal{Y}$.

Формально требуется построить отображение:

$$\mathbf{q} : \mathcal{Y} \rightarrow \mathcal{X}_f, \quad \mathbf{F}(t) \approx \mathbf{q}[\mathbf{y}(t - \Delta t)], \quad (3)$$

сопоставляющее стимулу вызванный им фМРТ-отклик. Искомая задержка — значение гиперпараметра Δt , при котором (3) восстанавливает отклик с наименьшей ошибкой.

2.3. Классификация временных рядов фМРТ

Временной ряд фМРТ — это последовательность из $\mathcal{T}$ сканов:

$$\mathbf{S} = [\mathbf{F}(1), \dots, \mathbf{F}(\mathcal{T})] \in \mathcal{X}_s,$$

где $\mathbf{F}(t) \in \mathcal{X}_f$ — скан в момент t . Задана выборка из N рядов одного испытуемого, каждому из которых сопоставлена метка категории стимула:

$$\mathfrak{D} = \{(\mathbf{S}_i, y_i) \mid i = 1, \dots, N\}, \quad y_i \in \{1, \dots, L\}, \quad (4)$$

где L — число категорий стимулов. Требуется построить отображение:

$$\mathbf{h} : \mathcal{X}_s \rightarrow \{1, \dots, L\}, \quad (5)$$

учитывающее пространственно-временные характеристики ряда.

2.4. Мультимодальное декодирование фМРТ–ЭЭГ

Задан датасет триплетов (фМРТ, ЭЭГ, изображение):

$$\mathfrak{D} = \{(\mathbf{F}_i, \mathbf{E}_i, \mathbf{I}_i) \mid i = 1, \dots, N\}, \quad (\mathbf{F}_i, \mathbf{E}_i) \in \mathcal{X}_f \times \mathcal{X}_e, \quad \mathbf{I}_i \in \mathcal{Y}, \quad (6)$$

где $\mathbf{F}_i \in \mathcal{X}_f$ — фМРТ-скан; $\mathbf{E}_i \in \mathcal{X}_e \subseteq \mathbb{R}^{K \times T}$ — ЭЭГ-запись, где K — число каналов, T — длина временного окна; $\mathbf{I}_i \in \mathcal{Y} \subseteq \mathbb{R}^{H \times W \times C}$ — изображение с высотой H , шириной W и числом каналов C . Требуется построить отображение $\mathbf{f}$ из совместного пространства данных фМРТ–ЭЭГ в пространство изображений:

$$\mathbf{f} : \mathcal{X}_f \times \mathcal{X}_e \rightarrow \mathcal{Y}. \quad (7)$$

3. Методы

Каждой из трех задач, введенных в разделе 2, соответствует свой метод. Сначала описывается линейная модель оценки гемодинамической задержки, затем — пространственно-временная классификация фМРТ в условиях ограниченной выборки, и наконец — мультимодальная реконструкция стимулов по сигналам фМРТ–ЭЭГ.

3.1. Линейная модель для оценки гемодинамической задержки

Отображение $\mathbf{q}$ из (3) реализуется повоксельной линейной регрессией. Рассмотрим запись из $\mathcal{T}$ сканов $\mathbf{F}(1), \dots, \mathbf{F}(\mathcal{T})$; каждому скану $\mathbf{F}(t)$ сопоставлен стимул, предъявленный на Δt раньше; эмбединг которого получен предобученным визуальным энкодером и обозначен $\mathbf{x}(t) \in \mathbb{R}^d$. Схема предложенной модели приведена на рис. 2.




Рис. 2: Схема модели прогнозирования снимков фМРТ по стимулу. На этапе предобработки из видеокadra предобученным энкодером извлекаются признаки, а фМРТ-сканы нормируются. На этапе прогнозирования многомерная линейная модель отображает эмбединг видеокadra в приращение между двумя последовательными сканами

Сжатие фМРТ. Информативная доля вокселей мала, поэтому для ускорения сканы предварительно сжимаются по пространственным измерениям. Сжатие

вдвое задается отображением

$$\chi : \mathbb{R}^{X \times Y \times Z} \rightarrow \mathbb{R}^{X/2 \times Y/2 \times Z/2},$$

а сжатие в 2^k раз — его k -кратным применением. Далее для краткости сохраняются обозначения размерностей $X \times Y \times Z$.

Марковское допущение. Последовательность сканов считается марковской: каждый скан зависит лишь от предыдущего и от текущего стимула. Поэтому модель предсказывает не сам скан, а его приращение

$$\delta(t) = \mathbf{F}(t) - \mathbf{F}(t-1) = [\delta_{xyz}(t)] \in \mathbb{R}^{X \times Y \times Z}, \quad t = 2, \dots, \mathcal{T}, \quad (8)$$

с покомпонентными значениями $\delta_{xyz}(t)$. Полный скан восстанавливается последовательным суммированием приращений.

Повоксельная линейная регрессия. Для каждого вокселя (x, y, z) приращение моделируется линейно по эмбедингу стимула с вектором параметров $\mathbf{w}_{xyz} \in \mathbb{R}^d$:

$$\widehat{\delta}_{xyz}(t) = \langle \mathbf{x}(t), \mathbf{w}_{xyz} \rangle.$$

Параметры находятся минимизацией квадратичной ошибки с L_2 -регуляризацией, коэффициент регуляризации обозначается λ :

$$\mathcal{L}_{xyz}(\mathbf{w}_{xyz}) = \sum_{t=2}^{\mathcal{T}} (\langle \mathbf{x}(t), \mathbf{w}_{xyz} \rangle - \delta_{xyz}(t))^2 + \lambda \|\mathbf{w}_{xyz}\|_2^2. \quad (9)$$

Задача (9) имеет замкнутое решение по методу наименьших квадратов. Введем матрицу объекты–признаки и вектор приращений одного вокселя:

$$\mathbf{X} = [\mathbf{x}(2), \dots, \mathbf{x}(\mathcal{T})]^\top \in \mathbb{R}^{(\mathcal{T}-1) \times d}, \quad \Delta_{xyz} = [\delta_{xyz}(2), \dots, \delta_{xyz}(\mathcal{T})]^\top \in \mathbb{R}^{\mathcal{T}-1}.$$

Тогда

$$\widehat{\mathbf{w}}_{xyz} = (\mathbf{X}^\top \mathbf{X} + \lambda \mathbb{I})^{-1} \mathbf{X}^\top \Delta_{xyz}. \quad (10)$$

Авторегрессионное восстановление. Веса всех вокселей построчно объединяются в матрицу $\widehat{\mathbf{W}} = [\widehat{\mathbf{w}}_1, \dots, \widehat{\mathbf{w}}_{XYZ}]^\top \in \mathbb{R}^{XYZ \times d}$, и прогноз очередного скана

получается авторегрессионно:

$$\text{vec}(\hat{\mathbf{F}}(t)) = \text{vec}(\mathbf{F}(t-1)) + \mathbf{W} \mathbf{x}(t). \quad (11)$$

Последовательное применение (11), начиная с известного первого скана, восстанавливает всю последовательность фМРТ по стимулу и задает отображение $\mathbf{q}$. Задержка Δt входит в модель через сопоставление стимула скану; ее оптимальное значение выбирается по минимуму ошибки восстановления MSE.

3.2. Пространственно-временная классификация фМРТ

На рис. 3 представлена схема модели классификации, реализующей двух-этапный процесс классификации временных рядов фМРТ одного испытуемого по категориям стимулов. На первом этапе происходит *извлечение масок активности мозга для каждой категории стимулов*, что позволяет выделить области, активируемые в ответ на соответствующие стимулы. На втором этапе выполняется *классификация ряда* с использованием извлеченных масок и отображения на касательное пространство риманова многообразия (англ. TSM) [49].




Рис. 3: **Схема модели классификации.** Модель состоит из двух компонентов: слева — извлечение масок активности мозга для каждой категории стимулов, справа — классификация на основе полученных масок и TSM. Модель улавливает пространственно-временные характеристики, отражающие степень соответствия объекта и маски активности конкретного класса, и не зависит от размера выборки, что важно при ограниченной выборке одного испытуемого

3.2.1. Извлечение масок активности мозга

Активные области, или области интереса (англ. ROI), выделяются по корреляции сигнала вокселя со стимулом. Для ускорения каждый скан ряда $\mathbf{S}$ предварительно сжимается 3D average pooling с ядром k_s , после чего сигнал вокселя $F_{xyz}(t)$ и бинарный ряд стимуляции $\mathbf{u} = [u(1), \dots, u(\mathcal{T})]$, $u(t) \in \{0,1\}$, центрируются. Вычисляется их кросс-корреляция при сдвиге, отвечающем гемодинамической задержке Δt :

$$\rho_{xyz} = \frac{1}{\mathcal{T} - 1} \sum_t \dot{u}(t) \dot{F}_{xyz}(t + \Delta t). \quad (12)$$

Бинарная маска активности $\mathcal{M} \in \{0,1\}^{X/k_s \times Y/k_s \times Z/k_s}$ задается единицами в h вокселях с наибольшим значением ρ_{xyz} . Статистическая значимость отбора проверяется критерием ранговой корреляции Кендалла для каждого вокселя с поправкой Холма на множественную проверку, что отсеивает ложные срабатывания.

Маска строится отдельно для каждой категории $y = 1, \dots, L$. Ряды и стимулы объектов класса y объединяются по времени, после чего к ним применяется (12); результат — маска $\mathcal{M}^y \in \{0,1\}^{X/k_s \times Y/k_s \times Z/k_s}$. Усреднение по объектам класса повышает статистическую значимость маски и ее устойчивость к шуму отдельных записей.

3.2.2. Классификация временных рядов

Задан набор данных $\mathfrak{D}$, см. (4), и маски активности $\mathcal{M}^y$, $y = 1, \dots, L$. Искомое отображение $\mathbf{h} : \mathcal{X}_s \rightarrow \{1, \dots, L\}$ представляется суперпозицией

$$\mathbf{h} = \boldsymbol{\eta} \circ \boldsymbol{\psi} \circ \mathcal{A}, \quad (13)$$

где $\mathcal{A}$ — 3D average pooling с ядром k_s , $\boldsymbol{\psi}$ — кодировщик пространственно-временных характеристик, $\boldsymbol{\eta} : \mathbb{R}^d \rightarrow \{1, \dots, L\}$ — классификатор.

Кодировщик является конкатенацией отображений для каждой категории стимула:

$$\boldsymbol{\psi} = \boldsymbol{\psi}_1 \oplus \dots \oplus \boldsymbol{\psi}_L, \quad \boldsymbol{\psi}_y = \boldsymbol{\pi}_y \circ \mathbf{m}_y, \quad d = \sum_{y=1}^L d_y, \quad (14)$$

где $\mathbf{m}_y$ применяет маску $\mathcal{M}^y$ и отбирает h_y активных вокселей, формируя матрицу из $\mathbb{R}^{h_y \times \mathcal{T}}$, а $\boldsymbol{\pi}_y$ проецирует ее на касательное пространство риманова многообразия с последующей векторизацией. Размерность определяется в разделе 3.2.3:

$$d_y = \frac{h_y(h_y + 1)}{2}. \quad (15)$$

Кодировщик $\boldsymbol{\psi}$ переводит ряды в евклидово касательное пространство, извлекая пространственно-временные характеристики, которые отражают степень соответствия объекта и маски конкретного класса. Это упрощает классификацию, поэтому в качестве $\boldsymbol{\eta}$ рассматриваются логистическая регрессия и двухслойный перцептрон.

3.2.3. Проекция на касательное пространство риманова многообразия

Для упрощения изложения индекс класса y опускается. Отображение $\boldsymbol{\pi} : \mathbb{R}^{h \times \mathcal{T}} \rightarrow \mathbb{R}^d$ (TSM) [49] работает с объектами как с точками риманова многообразия ковариационных матриц [48]. Для i -го объекта формируется центрированная матрица активных вокселей $\mathbf{Y}_i \in \mathbb{R}^{h \times \mathcal{T}}$, $i = 1, \dots, N$, и ее ковариационная матрица

$$\mathbf{R}_i = \frac{1}{\mathcal{T} - 1} \mathbf{Y}_i \mathbf{Y}_i^\top \in \mathbb{S}_+^h, \quad (16)$$

где $\mathbb{S}_+^h$ — пространство симметричных положительно определенных матриц размера $h \times h$, образующее риманово многообразие $\mathcal{R}$.

Касательная плоскость для проекции строится в точке риманова геометрического среднего выборки

$$\bar{\mathbf{R}} = \arg \min_{\mathbf{R}} \sum_{i=1}^N \delta_{\mathcal{R}}^2(\mathbf{R}, \mathbf{R}_i), \quad \delta_{\mathcal{R}}(\mathbf{R}_1, \mathbf{R}_2) = \left(\sum_{l=1}^h \log^2 \lambda_l \right)^{1/2},$$

где $\delta_{\mathcal{R}}$ — геодезическое расстояние, а λ_l — собственные значения матрицы $\mathbf{R}_1^{-1} \mathbf{R}_2$. Проекция ковариационной матрицы на касательное пространство задается логарифмическим отображением

$$\mathbf{P}_i = \text{Log}_{\bar{\mathbf{R}}}(\mathbf{R}_i) = \bar{\mathbf{R}}^{1/2} \log(\bar{\mathbf{R}}^{-1/2} \mathbf{R}_i \bar{\mathbf{R}}^{-1/2}) \bar{\mathbf{R}}^{1/2}, \quad \mathbf{P}_i \in \mathbb{R}^{h \times h},$$

а обратное — экспоненциальным $\text{Exp}_{\mathbf{R}}$; матричные функции вычисляются через сингулярное разложение. Касательное пространство евклидово, поэтому верхний треугольник $\mathbf{P}_i$ векторизуется с коэффициентом $\sqrt{2}$ на внедиагональных элементах, что дает эмбединг

$$\mathbf{P}_i^{\text{emb}} \in \mathbb{R}^d, \quad d = \frac{h(h+1)}{2}.$$

Процесс проекции ковариационных матриц на касательное пространство, а затем обратно на многообразие проиллюстрирован на рис. 4.




Рис. 4: **Схема операций римановой геометрии.** Ковариационная матрица $\mathbf{R}_j$ проецируется на касательное пространство $T_{\mathbf{R}}$ в точке $\mathbf{R}$ с использованием логарифмического отображения $\text{Log}_{\mathbf{R}}(\mathbf{R}_j)$. Полученная проекция $\mathbf{P}_j$ затем отображается обратно на риманово многообразие $\mathcal{R}$ с использованием экспоненциального отображения $\text{Exp}_{\mathbf{R}}(\mathbf{P}_j)$. $\delta_{\mathcal{R}}(\mathbf{R}, \mathbf{R}_j)$ — геодезическое расстояние между $\mathbf{R}$ и $\mathbf{R}_j$.

3.3. Мультимодальная реконструкция стимулов по сигналам фМРТ–ЭЭГ

На рис. 5 представлена схема декодирования изображений. Процесс строится из двух основных этапов: контрастивное обучение комбинированных представлений фМРТ–ЭЭГ сигналов и реконструкция стимулов.

3.3.1. Контрастивное обучение комбинированных представлений

Энкодер сигналов фМРТ–ЭЭГ. Архитектура энкодера состоит из трех модулей: энкодера фМРТ, энкодера ЭЭГ и модуля объединения. Для обеспечения персонализированного представления мозговой активности каждый модуль включает индивидуализирующие компоненты, позволяющие явно моделировать




Рис. 5: Схема декодирования изображений на основе сигналов фМРТ–ЭЭГ. Процесс декодирования реализуется в два этапа. На первом этапе проводится контрастное обучение энкодера сигналов фМРТ–ЭЭГ, в ходе которого представления мозговых сигналов выравниваются с замороженными эмбедингами изображений, полученными с помощью модели CLIP. На втором этапе осуществляется двухстадийная генерация реконструкций: сначала обучается диффузионная априорная модель для уточнения эмбедингов сигналов мозга, а затем предобученная диффузионная модель, обусловленная на CLIP-эмбединги, генерирует реконструкции изображений

межсубъектные различия — критически важный аспект при работе с нейросигналами. Архитектуры энкодеров фМРТ и ЭЭГ изображены на рис. 6.

Предобработка ЭЭГ. На этапе предобработки решается задача восстановления пропусков в записях ЭЭГ: сигналы незарегистрированных электродов восстанавливаются методами пространственной интерполяции на основе данных ближайших доступных каналов и известной геометрии расположения датчиков.

Полный набор электродов системы регистрации включает K каналов. Каждому каналу $\{c_k\}_{k=1}^K$ соответствуют фиксированные пространственные координаты $\mathbf{p}_k \in \mathbb{R}^3$ на поверхности скальпа. Множество фактически зарегистрированных каналов в i -й записи обозначим как $\mathcal{C}_i \subseteq \{c_1, \dots, c_K\}$, $i = 1, \dots, N$. От записи к записи набор отсутствующих каналов меняется, поэтому ограничиваться лишь их общим (перекрывающимся) подмножеством нельзя — это привело бы к су-

ущественной потере информации. При этом энкодер ЭЭГ $\mathcal{E}_e$ принимает на вход тензор фиксированной размерности, без чего невозможна обработка обучающей выборки батчами. Отсюда и вытекает необходимость восстановить сигналы недостающих каналов до полного набора.

Для упрощения нотации далее рассматривается единичная запись ЭЭГ $\mathbf{E}$, при этом индекс i объекта выборки опускается. Обозначим через $\mathcal{C} \subset \{c_1, \dots, c_K\}$ — подмножество каналов, для которых доступны временные ряды $\mathbf{e}_k \in \mathbb{R}^T$. Таким образом, наблюдаемая часть записи задается как $\mathbf{E} = \{\mathbf{e}_k\}_{k \in \mathcal{C}}$. Для унификации формата данных каждому отсутствующему каналу $c_k \notin \mathcal{C}$ назначается восстановленный сигнал $\hat{\mathbf{e}}_k \in \mathbb{R}^T$, рассчитываемый как взвешенное среднее значений n пространственно ближайших зарегистрированных электродов:

$$\hat{\mathbf{e}}_k = \sum_{j \in \mathcal{S}_k} w_{kj} \mathbf{e}_j, \quad \sum_{j \in \mathcal{S}_k} w_{kj} = 1, \quad (17)$$

где $\mathbf{e}_j \in \mathbb{R}^T$ — временной ряд канала c_j ; $\mathcal{S}_k$ — множество индексов n ближайших к c_k доступных электродов, определяемое в соответствии с выбранной пространственной метрикой; $w_{kj} \geq 0$ — неотрицательные нормированные веса. В исследовании рассматриваются четыре стратегии определения весов $\{w_{kj}\}$ и формирования множества соседей $\mathcal{S}_k$:

- **Zero** (нулевое заполнение): базовый метод, при котором отсутствующий сигнал заменяется нулевым вектором:

$$\hat{\mathbf{e}}_k = \mathbf{0} \in \mathbb{R}^T.$$

- **NN** (метод одного ближайшего соседа): сигнал отсутствующего канала заменяется сигналом ближайшего зарегистрированного электрода:

$$\hat{\mathbf{e}}_k = \mathbf{e}_{j^*}, \quad j^* = \arg \min_{j: c_j \in \mathcal{C}} \rho_{\text{eucl}}(c_k, c_j), \quad \rho_{\text{eucl}}(c_k, c_j) = \|\mathbf{p}_k - \mathbf{p}_j\|_2.$$

что соответствует $n = 1$ и $w_{kj^*} = 1$ в (17).

- **KNN-Euclidean**: взвешенное усреднение по n ближайшим соседям в евклидовой метрике; веса определяются как величины, обратно пропорци-

ональные расстоянию между электродами:

$$w_{kj} = \frac{1/\rho_{\text{eucl}}(c_k, c_j)}{\sum_{l \in \mathcal{S}_k} 1/\rho_{\text{eucl}}(c_k, c_l)}, \quad \rho_{\text{eucl}}(c_k, c_j) = \|\mathbf{p}_k - \mathbf{p}_j\|_2.$$

- **KNN-Spherical:** то же взвешенное усреднение по n ближайшим соседям, но в сферической метрике — евклидово расстояние здесь заменено геодезическим вдоль поверхности скальпа, которая аппроксимируется сферой радиуса R :

$$\rho_{\text{sph}}(c_k, c_j) = R \cdot \arccos\left(\frac{\langle \mathbf{p}_k, \mathbf{p}_j \rangle}{\|\mathbf{p}_k\|_2 \|\mathbf{p}_j\|_2}\right),$$

веса при этом полагаются $w_{kj} \propto 1/\rho_{\text{sph}}(c_k, c_j)$ и затем нормируются: $\sum_{j \in \mathcal{S}_k} w_{kj} = 1$.

Выполнение процедуры (17) для всех отсутствующих каналов приводит запись ЭЭГ к единому матричному виду $\mathbf{E} \in \mathbb{R}^{K \times T}$ с фиксированным числом каналов K . Тем самым размерность входного тензора согласуется с архитектурой энкодера $\mathcal{E}_e$, что и делает возможной последующую батчевую обработку.

Энкодер ЭЭГ. Энкодер ЭЭГ через конкатенацию объединяет исходные многоканальные данные с индивидуальными обучаемыми эмбедингами пациентов, получая единое векторное представление. Архитектура энкодера включает последовательность трех сверточных слоев: одномерную свертку по временному измерению, одномерную свертку по каналам (пространству) и свертку для сжатия в вектор. Полученный эмбединг пропускается через MLP-голову, формируя итоговое представление. Формально, для батча данных ЭЭГ $\mathbf{E} \in \mathbb{R}^{B \times K \times T}$ энкодер $\mathcal{E}_e$ генерирует эмбединги:

$$\mathbf{Z}_e = \mathcal{E}_e(\mathbf{E}) \in \mathbb{R}^{B \times d_e},$$

где d_e — размерность латентного пространства ЭЭГ.

Предобработка фМРТ. Из всего объема $X \times Y \times Z$ вокселей лишь относительно небольшая часть несет информацию о реакции мозга на визуальный стимул: значительную долю занимают фоновые воксели, значения которых либо

близки к нулю, либо стабильны во времени и не зависят от стимула. Прямая подача всего тензора в обучаемую модель приводит к расточительной параметризации и снижает отношение сигнал/шум. Поэтому на этапе предобработки строится индивидуальная для каждого испытуемого бинарная маска, выделяющая только информативные воксели.

Пусть $F_{xyz}(t)$ — значение вокселя с координатами (x, y, z) в момент t временного ряда фМРТ длиной $\mathcal{T}$. Для каждого вокселя вычисляется суммарная абсолютная разность значений между соседними кадрами:

$$m_{xyz} = \sum_{t=2}^{\mathcal{T}} |F_{xyz}(t) - F_{xyz}(t-1)|.$$

Величина m_{xyz} интерпретируется как накопленная во времени вариация сигнала в данном вокселе: для фоновых вокселей m_{xyz} близка к нулю, для активно реагирующих на стимул — существенно положительна. К одномерному распределению величин $\{m_{xyz}\}$ применяется метод Оцу [58], автоматически подбирающий порог между фоновыми и информативными вокселями. Алгоритм перебирает все допустимые пороги θ , разбивая при каждом из них воксели на два класса — $C_0(\theta) = \{(x, y, z) : m_{xyz} \leq \theta\}$ и $C_1(\theta) = \{(x, y, z) : m_{xyz} > \theta\}$ — с долями $\omega_0(\theta), \omega_1(\theta) = 1 - \omega_0(\theta)$ и средними $\mu_0(\theta), \mu_1(\theta)$. Межклассовая дисперсия имеет вид

$$\sigma^2(\theta) = \omega_0(\theta) \omega_1(\theta) [\mu_0(\theta) - \mu_1(\theta)]^2,$$

оптимальным же считается порог, доставляющий ей максимум:

$$\theta^* = \arg \max_{\theta} \sigma^2(\theta).$$

Найденный порог задает бинарную маску

$$\mathcal{M}_{xyz} = \mathbb{1}\{m_{xyz} > \theta^*\}, \quad \mathcal{M} \in \{0, 1\}^{X \times Y \times Z}, \quad (18)$$

свою для каждого испытуемого; число информативных вокселей $\sum_{xyz} \mathcal{M}_{xyz}$ определяется анатомией и индивидуальной динамикой BOLD-сигнала. После этого для каждого фМРТ-скана $\mathbf{F}$ воксели со значением $\mathcal{M}_{xyz} = 1$ собираются в плотный вектор.

Энкодер фМРТ. Индивидуальные особенности пациентов энкодер фМРТ учитывает с помощью персонализированной линейной проекции. Вектор информативных вокселей, отобранных по бинарной маске $\mathcal{M}$, пропускается через индивидуальный для каждого испытуемого линейный слой, проецирующий признаки в общее латентное пространство размерности 4096. Завершающим этапом является обработка эмбедингов через MLP с остаточными соединениями. Формально, для батча данных фМРТ $\mathbf{F} \in \mathbb{R}^{B \times X \times Y \times Z}$ энкодер $\mathcal{E}_f$ преобразует исходный тензор в латентное представление:

$$\mathbf{Z}_f = \mathcal{E}_f(\mathbf{F}) \in \mathbb{R}^{B \times d_f},$$

где d_f — размерность латентного пространства фМРТ.

Модуль объединения. Полученные эмбединги $\mathbf{Z}_e$ и $\mathbf{Z}_f$ подаются на вход обучаемого модуля объединения $\mathcal{F}$, который интегрирует высокочастотную информацию из ЭЭГ и пространственно детализированные данные фМРТ, формируя совместные эмбединги:

$$\mathbf{Z}_c = \mathcal{F}(\mathbf{Z}_f, \mathbf{Z}_e) \in \mathbb{R}^{B \times d}.$$

В данной работе модуль объединения реализован как конкатенация эмбедингов с последующей обработкой через MLP для извлечения совместных представлений. В качестве альтернативной реализации $\mathcal{F}$ также рассматривалось скользящее усреднение эмбедингов модальностей вида

$$\mathbf{Z}_c = \alpha \mathbf{Z}_f + (1 - \alpha) \mathbf{Z}_e, \quad \alpha \in [0, 1],$$

где α — обучаемый скалярный параметр, балансирующий вклад фМРТ- и ЭЭГ-модальностей. Сравнительный анализ показал, что MLP более эффективно выделяет совместные признаки из пространств фМРТ–ЭЭГ, поэтому именно эта конфигурация принята в качестве основной.

Эмбединги изображений. Для извлечения визуальных эмбедингов используется предобученная модель CLIP ViT-H/14 [22], которая генерирует эмбединги изображений $\mathbf{Z}_I \in \mathbb{R}^{B \times d}$. Данная модель обеспечивает высококачественные, семантически насыщенные и хорошо обобщающиеся эмбединги, а




Рис. 6: Архитектуры кодировщиков фМРТ и ЭЭГ. *Слева:* энкодер ЭЭГ интегрирует индивидуальные обучаемые эмбединги пациентов с исходными многоканальными данными посредством конкатенации, формируя единое векторное представление; далее применяются одномерные свертки по временному и каналному измерениям, а также MLP-голова для генерации итоговых эмбедингов. *Справа:* энкодер фМРТ включает персонализированное маскирование мозга, векторизацию вокселей и проекцию в латентное пространство через индивидуальный линейный слой; завершающая обработка осуществляется с использованием MLP с остаточными соединениями

также совместима с множеством генеративных моделей, предобученных на CLIP-пространстве.

Контрастивное обучение энкодера сигналов мозга. Основной целью контрастивного обучения является сопоставление нейронных представлений фМРТ–ЭЭГ с визуальными эмбедингами, извлеченными с помощью замороженного энкодера CLIP, как показано на рис. 5. Обучение происходит на триплетах (фМРТ, ЭЭГ, изображение) и включает оптимизацию трех ключевых компонентов: энкодера фМРТ $\mathcal{E}_f$, энкодера ЭЭГ $\mathcal{E}_e$ и модуля объединения $\mathcal{F}$. Для вычисления логитов близости используется косинусное расстояние между нормированными эмбедингами:

$$\mathbf{z}_I^n = \frac{\mathbf{z}_I}{\|\mathbf{z}_I\|}, \quad \mathbf{z}_c^n = \frac{\mathbf{z}_c}{\|\mathbf{z}_c\|}, \quad (19)$$

где $\mathbf{z}_I$ — эмбединги изображений, полученные с помощью замороженного CLIP, а $\mathbf{z}_c$ — объединенные эмбединги фМРТ–ЭЭГ. Матрица логитов $\mathbf{L}$ вычисляется

как

$$\mathbf{L} = \mathbf{Z}_I^n (\mathbf{Z}_c^n)^\top \cdot e^\tau, \quad (20)$$

где τ — обучаемый параметр температуры. В процессе контрастивного обучения рассматриваются все возможные пары «объединенный эмбединг мозга — эмбединг изображения» для максимизации эффективности обучения. Критическим аспектом данного подхода является наличие большого числа негативных примеров, что позволяет модели не только корректно сопоставлять положительные пары, но и четко различать негативные. Как показано на рис. 7, при размере батча B формируется матрица логитов размером $B \times B$, где лишь B пар, расположенных на главной диагонали, являются положительными соответствиями.

Функция потерь основывается на симметричной контрастивной оптимизации, аналогичной подходу CLIP [22], и представляет собой усредненную сумму двух кросс-энтропийных потерь:

$$\mathcal{L}_{\text{contr}} = -\frac{1}{2B} \sum_{b=0}^{B-1} \left[\log \left(\frac{\exp(\mathbf{L}_{bb})}{\sum_{j=0}^{B-1} \exp(\mathbf{L}_{bj})} \right) + \log \left(\frac{\exp(\mathbf{L}_{bb})}{\sum_{i=0}^{B-1} \exp(\mathbf{L}_{ib})} \right) \right], \quad (21)$$

где $\mathbf{L}_{ij}$ обозначает элемент матрицы логитов $\mathbf{L}$ на позиции (i, j) .

3.3.2. Процесс реконструкции стимулов

Вводится совместное распределение изображений $\mathbf{x}$ и их скрытых визуальных представлений $\mathbf{z}_I$ при условии комбинированных нейронных эмбедингов $\mathbf{z}_c$:

$$p(\mathbf{x}, \mathbf{z}_I \mid \mathbf{z}_c) \propto p(\mathbf{z}_I \mid \mathbf{z}_c) p(\mathbf{x} \mid \mathbf{z}_I).$$

Здесь $p(\mathbf{z}_I \mid \mathbf{z}_c)$ моделирует согласование комбинированного представления фМРТ–ЭЭГ с высокоуровневым визуальным пространством CLIP (стадия I), а $p(\mathbf{x} \mid \mathbf{z}_I)$ описывает генерацию изображения при условии уточненного визуального эмбединга (стадия II).

Стадия I: диффузионная модель в пространстве CLIP. В пространстве визуальных эмбедингов CLIP обучается легкая диффузионная модель вида

$$\epsilon_{\theta}(\mathbf{z}_I^{(t)}, t, \mathbf{z}_c),$$

Контрастивное предварительное обучение




Рис. 7: Иллюстрация контрастивного обучения и формирования батчей. Отрицательные примеры формируются автоматически. Косинусные расстояния между эмбедами замороженного CLIP и нейронными эмбедами используются в качестве логитов

где $\mathbf{z}_I^{(t)}$ — зашумленная версия истинного эмбеда $\mathbf{z}_I$ на шаге t прямого диффузионного процесса, а $\mathbf{z}_c$ — комбинированный эмбеддинг, полученный модулем слияния. Обучение осуществляется по методу DDPM (англ. Denoising Diffusion Probabilistic Models, вероятностные диффузионные модели расшумления) [59] с функцией потерь

$$\mathcal{L}_{\text{prior}}(\boldsymbol{\theta}) = \mathbb{E}_{\mathbf{z}_I, \mathbf{z}_c, t, \epsilon} \left\| \epsilon - \epsilon_{\boldsymbol{\theta}}(\mathbf{z}_I^{(t)}, t, \mathbf{z}_c) \right\|_2^2. \quad (22)$$

На инференсе априорная диффузионная модель генерирует оценку $\hat{\mathbf{z}}_I \approx \mathbf{z}_I$ итеративной процедурой расшумления, согласующей $\mathbf{z}_c$ с визуальным пространством CLIP. Кодировщики $\mathcal{E}_f$, $\mathcal{E}_e$ и модуль слияния $\mathcal{F}$ остаются замороженными, что упрощает схему и стабилизирует обучение.

Стадия II: генерация изображения при условии $\hat{\mathbf{z}}_I$. Для реконструкции изображения используется предобученная латентно-диффузионная модель

SDXL [45]:

$$\epsilon_{\phi}(\mathbf{x}^{(t)}, t, h(\hat{\mathbf{z}}_I)),$$

где $\mathbf{x}^{(t)}$ — зашумленный латент изображения, а $h(\cdot)$ — проекционный адаптер IP-Adapter [46], переводящий $\hat{\mathbf{z}}_I$ в формат условия, совместимый с SDXL. Модель ϕ не дообучается.

Итоговый процесс реконструкции.

1. Контрастивное обучение выравнивает $\mathbf{z}_c$ с $\mathbf{z}_I$ (см. раздел 3.3.1).
2. Априорная диффузионная модель генерирует согласованное визуальное представление $\hat{\mathbf{z}}_I$ по $\mathbf{z}_c$.
3. Предобученная SDXL, обусловленная через $h(\hat{\mathbf{z}}_I)$, синтезирует изображение $\hat{\mathbf{x}}$.

4. Вычислительный эксперимент

Программная реализация всех вычислительных экспериментов выполнена на фреймворке PyTorch. Исходный код, конфигурации обучения и скрипты для воспроизведения результатов находятся в открытом доступе:

<https://github.com/DorinDaniil/Forecasting-fMRI-Images>.

<https://github.com/DorinDaniil/Spatial-and-Temporal-Characteristics>.

https://github.com/intsystems/CreationOfIntelligentSystems_Simultaneous-fMRI-EEG.

Эксперименты организованы по трем задачам декодирования из раздела 2: сначала оценивается гемодинамическая задержка, затем проверяется пространственно-временная классификация фМРТ в условиях ограниченной выборки, и в завершение оценивается мультимодальная реконструкция стимулов по сигналам фМРТ–ЭЭГ.

4.1. Анализ гемодинамической задержки

Оценка задержки Δt выполнена на наборе данных с одновременной регистрацией видеостимулов и фМРТ [34] с помощью модели $\mathbf{q}$ из раздела 3.1. Набор содержит записи 63 испытуемых, из которых фМРТ-сканы доступны для 30: среди них 16 мужчин и 14 женщин в возрасте от 7 до 47 лет, средний возраст составляет 22 года. Все они просматривали один и тот же короткий аудиовизуальный фильм. Запись длится 390 с; видеокадры предъявляются с частотой 25 Гц, а фМРТ-сканы регистрируются с частотой 1,64 Гц. Размеры составляют $640 \times 480 \times 3$ для видеокадра и $40 \times 64 \times 64$ для фМРТ-скана. Выборка делится на обучающую и тестовую в пропорции 70% к 30%, а значения вокселей нормируются в отрезок $[0, 1]$. В качестве визуального энкодера используется ResNet152 [29] без последнего слоя. Пример данных из выборки приведен на рис. 8.

Качество восстановления оценивается среднеквадратичной ошибкой MSE между истинными сканами тестовой выборки и их восстановлением по формуле (11), усредненной по всем вокселям. По форме эта ошибка совпадает с первым слагаемым функции потерь (9). Модель обучается при различных значениях сдвига, и для каждого из них вычисляется MSE. Если ошибку считать по всему фМРТ-скану, выраженного минимума у зависимости нет, так как области,




Рис. 8: Визуализация данных используемого набора. Для примера выбраны три момента времени. Слева показаны видеокadres, справа — срезы фМРТ-сканов за соответствующий период для трех испытуемых: 7, 13 и 47. Частота видеокadres выше, поэтому каждому фМРТ-скану соответствует несколько кадров

не связанные с обработкой зрительной информации, вносят шум. Чтобы его устранить, ошибка пересчитывается на затылочной доле, которая отвечает за обработку визуальных стимулов [60]. Эта зрительная зона локализуется так: из нижней трети и правых двух третей объема скана отбираются 3% вокселей с наибольшим суммарным абсолютным изменением значений во времени. Выделенные таким образом воксели показаны красным на рис. 9. На этой области зависимость MSE от Δt имеет отчетливый минимум при $\Delta t \approx 5$ с, как показано на рис. 10. Это значение согласуется с известным медицинским диапазоном задержки BOLD-сигнала [9].

Чтобы оценить интерпретируемость вспомогательной модели, рассматривается распределение ее весов. Векторы $\hat{\mathbf{w}}_{xyz}$ усредняются по всем вокселям одного испытуемого, и для полученного вектора строится распределение его компонент. Результат для 4-го испытуемого приведен на рис. 11. Компоненты не сосредоточены вблизи какого-либо одного значения, то есть распределение не вырождено. Это согласуется с тем, что при просмотре видео человек обращает внимание на отдельные части кадра, такие как персонажи или иные значимые детали, поэтому обученная модель опирается на разнообразные признаки стимула.




Рис. 9: Локализация наиболее активной зоны для 47-го испытуемого. Красным выделены 3% наиболее изменчивых во времени вокселей затылочной доли, которая отвечает за обработку визуальной информации, в том числе при просмотре видеоряда. Это подтверждает корректность локализации




Рис. 10: Зависимость MSE от величины гемодинамической задержки Δt . Слева — расчет по всему фМРТ-скану, где выраженный минимум отсутствует из-за шума от областей, не связанных со зрением. Справа — расчет на локализованной затылочной доле, дающий отчетливый минимум при $\Delta t \approx 5$ c

4.2. Классификация временных рядов фМРТ

Вычислительный эксперимент использует данные фМРТ из исследования [61], собранные при изучении представлений лиц и объектов в зрительной коре. Набор данных содержит записи фМРТ от 6 испытуемых. Каждый испытуемый проходил 12 сессий. В каждой сессии испытуемый пассивно просматривал черно-белые изображения восьми категорий, сгруппированные в блоки по 24 секунды, разделенные периодами отдыха. Каждое изображение демонстрировалось в течение 500 мс, после чего следовал интервал между стимулами длительностью 1500 мс. Данные фМРТ мозга записывались с частотой 2.5 c^{-1} . Примеры




Рис. 11: Распределение компонент усредненного по вокселям вектора весов вспомогательной модели для 4-го испытуемого. Веса не концентрируются вокруг одного значения, что указывает на невырожденное распределение и свидетельствует об обученности модели, опирающейся на разнообразные признаки

стимулов приведены на рис. 12.

Кроме того, набор данных содержит временные ряды стимулов и маски активных областей мозга, полученные нейроучеными. Эти области были определены для каждого участника эксперимента индивидуально. В наборе данных Naхby et al. [61] учитывается гемодинамическая задержка в процессе аннотирования, что обеспечивает корректную временную синхронизацию данных. Это позволяет установить гиперпараметр Δt равным 0 в ходе экспериментов.

Из записи каждого испытуемого получено $N = 96$ временных рядов длины $\mathcal{T} = 19$ по $L = 8$ категориям, по 12 объектов на категорию. Выборка разбита на обучающую и тестовую в пропорции 80% к 20%. Качество оценивается метриками Accuracy, Macro F1-score и Micro F1-score. В качестве классификатора η используется логистическая регрессия, число активных вокселей маски $h_y = 10$ для каждой категории.

Анализ исключением компонент. Для оценки вклада каждого компонента в предложенную модель было проведено исследование методом исключения компонент. Рассматривались следующие варианты моделей:

- *Без TSM*: временные ряды преобразуются в вектор после применения масок

Categories of stimuli used in the experiment




Рис. 12: Визуализация стимулов из используемого набора данных. В наборе данных представлено 8 различных типов визуальных стимулов. Для каждого типа выбрано по 4 примера изображений. Стимулы для каждой категории значительно различаются.

каждого класса, конкатенируются и подаются на вход классификатору без использования TSM.

- *Без масок классов*: маска активности рассчитывается как среднее по всем временным рядам, без учета специфичных для классов масок, и TSM применяется для кодирования.
- *Оригинальные маски*: вместо масок, сгенерированных алгоритмом из раздела 3.2.1, используются оригинальные маски, предоставленные нейрочечными, и TSM применяется для кодирования временных рядов.

В Таблице 1 представлены усредненные значения метрик по испытуемым, а также их стандартные отклонения и 95% доверительные интервалы. Статистическая значимость оценивалась с использованием t-тестов для связанных выборок, с результатами, обозначенными звездочками, где $*p\text{-value} < .05$ и $**p\text{-value} < .005$. Это подчеркивает важность каждого компонента относительно полной модели. Была применена поправка Холма для множественного тестирования, чтобы обеспечить достоверность статистических сравнений по трем

метрикам. В качестве классификатора η использовалась логистическая регрессия.

Таблица 1: Анализ методом исключения компонент влияния отдельных компонентов модели на качество классификации. Метрики на тестовых выборках усреднены по испытуемым. Статистическая значимость обозначена звездочками: * p -value < .05, ** p -value < .005, отражающими значимость улучшений относительно полной модели. Доверительные интервалы (англ. CI) представляют диапазон, в котором, вероятно, находятся истинные значения метрик с 95% доверительной вероятностью.

Метод	Accuracy	Macro F1-Score	Micro F1-Score	Accuracy CI	Macro F1 CI	Micro F1 CI
Без TSM	$0.24 \pm 0.11^*$	$0.22 \pm 0.11^*$	$0.24 \pm 0.11^*$	[0.11, 0.37]	[0.09, 0.36]	[0.10, 0.37]
Без масок классов	$0.25 \pm 0.13^*$	$0.23 \pm 0.13^*$	$0.25 \pm 0.13^*$	[0.09, 0.41]	[0.07, 0.39]	[0.09, 0.41]
Оригинальные маски	$0.10 \pm 0.05^{**}$	$0.09 \pm 0.04^{**}$	$0.10 \pm 0.05^{**}$	[0.04, 0.16]	[0.03, 0.14]	[0.04, 0.16]
Предложенная модель	0.61 ± 0.04	0.56 ± 0.03	0.61 ± 0.04	[0.56, 0.66]	[0.52, 0.60]	[0.56, 0.66]

Сравнение с нейросетевыми подходами. Для демонстрации превосходства предложенной модели над подходами на основе нейронных сетей, особенно при работе с ограниченными данными, мы сравниваем ее с двумя альтернативными моделями, использующими различные методы кодирования временных рядов фМРТ:

- *Оригинальные маски и LSTM*: эта модель сначала применяет оригинальные маски, предоставленные нейроучеными, для выбора активных областей мозга. Затем временные ряды из этих областей кодируются с использованием сети долгой краткосрочной памяти (англ. LSTM), которая улавливает временные зависимости. Извлеченные признаки передаются через линейный слой с активацией softmax для классификации.
- *Оригинальные маски и Attention*: эта модель сначала применяет оригинальные маски, предоставленные нейроучеными, для выбора активных областей мозга. Затем временные ряды из этих областей кодируются с использованием слоя внимания для кодирования временных рядов. Механизм внимания взвешивает временные признаки, фокусируясь на наиболее релевантных временных точках, и результирующий контекстный вектор передается через линейный слой с активацией softmax для классификации.

В Таблице 2 представлены средние значения метрик по испытуемым на тестовой выборке для каждой модели в сравнении с предложенной моделью,

использующей логистическую регрессию в качестве классификатора η . Таблица включает статистическую значимость, оцененную с использованием t-тестов для связанных выборок, обозначенную звездочками, где $**p\text{-value} < .005$, рассчитанную для проверки гипотезы об том, что улучшения метрик для полной модели статистически значимы. Применяется поправка Холма для множественного тестирования, чтобы обеспечить достоверность статистических сравнений по трем метрикам. Кроме того, представлены 95% доверительные интервалы (англ. CI), чтобы указать диапазон, в котором, вероятно, находятся истинные значения метрик.

Таблица 2: Сравнение модели с подходами на основе нейронных сетей. Метрики усреднены по испытуемым для тестовой выборки, с указанием статистической значимости и доверительных интервалов. Статистическая значимость обозначена звездочками: $**p\text{-value} < .005$.

Модель	Accuracy	Macro F1-Score	Micro F1-Score	Accuracy CI	Macro F1 CI	Micro F1 CI
Оригинальные маски и LSTM	0.12 $\pm$ 0.02**	0.03 $\pm$ 0.01**	0.12 $\pm$ 0.02**	[0.09, 0.14]	[0.02, 0.04]	[0.09, 0.14]
Оригинальные маски и Attention	0.14 $\pm$ 0.04**	0.04 $\pm$ 0.03**	0.14 $\pm$ 0.04**	[0.11, 0.18]	[0.02, 0.07]	[0.11, 0.18]
Предложенная модель	0.61 $\pm$ 0.04	0.56 $\pm$ 0.03	0.61 $\pm$ 0.04	[0.56, 0.66]	[0.52, 0.60]	[0.56, 0.66]

Экспериментальные результаты, представленные в Таблице 2, подчеркивают превосходство предложенной модели по сравнению с подходами на основе нейронных сетей, особенно в сценариях с ограниченной выборкой. Использование специфичных для классов масок из раздела 3.2.1, и TSM для кодирования позволяет модели эффективно улавливать как пространственные, так и временные характеристики данных фМРТ. Статистическая значимость, обозначенная $p\text{-value} < .005$, подтверждает гипотезу о том, что наблюдаемые улучшения метрик статистически значимы и маловероятно произошли случайно. Доверительные интервалы дополнительно обеспечивают меру надежности этих оценок, укрепляя обоснованность улучшений производительности модели.

4.3. Мультимодальное декодирование фМРТ–ЭЭГ

В данном разделе проводится эмпирическая оценка метода, предложенного в разделе 3.3. Раздел 4.3.1 описывает характеристики используемого датасета, параметры регистрации сигналов и процедуры предобработки, включая восстановление отсутствующих каналов ЭЭГ и построение индивидуальных масок мозга для фМРТ. В разделе 4.3.2 приведены архитектурные детали и гиперпараметры энкодеров для каждой модальности, а также модуля объединения

эмбедингов. Раздел 4.3.3 содержит результаты вычислительных экспериментов: качественный анализ реконструкций и количественную оценку через метрику CLIP-Score. Ограничения предложенного метода обсуждаются в разделе 4.3.4.

4.3.1. Данные

В работе используется открытый датасет с одновременной регистрацией фМРТ и ЭЭГ при предъявлении визуальных стимулов [27]. Данные собраны у 22 здоровых участников в возрасте 23–51 года в ходе двух сканирований. Эксперимент включает записи в состоянии покоя, при просмотре мерцающего шахматного поля, абстрактной анимации **Inscapes** — компьютерно сгенерированной последовательности трехмерных фигур с плавными переходами — а также коротких видеороликов, представляющих натуралистические стимулы: фрагменты мультфильмов **The Present** и **Despicable Me**, а также фрагменты фильмов с обезьянами. Все визуальные стимулы демонстрируются в естественном, натуралистическом формате, что способствует высокой межсубъектной корреляции и устойчивости нейронных откликов. Синхронизация ЭЭГ и фМРТ достигается через запись триггеров сканера в ЭЭГ-поток. Предобработка ЭЭГ включает удаление градиентных и кардиобаллистических артефактов, полосовую фильтрацию и усредненное реферирование. Для фМРТ применяется стандартная коррекция движения, сглаживание и нормализация. Параметры регистрации сведены в табл. 3.

Исходно данные поступают в виде трех асинхронных потоков: временные ряды фМРТ, временные ряды ЭЭГ и видеозапись стимулов. Регистрация ведется синхронно, однако частоты дискретизации у модальностей различны: фМРТ обновляется с частотой 0,476 Гц, ЭЭГ записывается с частотой 5000 Гц, а видеостимул образует непрерывный поток кадров. У каждого сигнала есть и собственные артефакты (для ЭЭГ — градиентные и кардиобаллистические, для фМРТ — двигательные), а набор доступных электродов у разных участников неодинаков; в совокупности это исключает прямую подачу сырых записей на батчевое обучение нейросетевой модели. Поэтому первый шаг предобработки — разбиение записей на согласованные триплеты (**F**, **E**, **I**). С учетом гемодинамической задержки $\Delta t = 5$ с каждому фМРТ-тензору в момент времени t ставятся в соответствие окно ЭЭГ и кадр видеостимула, отвечающие моменту $t - \Delta t$. Видеопоток предварительно разбивается на кадры с частотой 3 FPS, а

ЭЭГ-сигнал сегментируется на матрицы размера (K, T) , где K — число каналов, а T — длина временного окна.

Параллельно с временной синхронизацией проводится пространственная предобработка, важная для снижения размерности и стандартизации входных тензоров. Чтобы снизить размерность фМРТ и убрать фоновые воксели, для каждого участника строится индивидуальная маска мозга (18): вычисляется суммарное абсолютное изменение сигнала во времени по каждому вокселю, и к полученному тензору применяется метод Оцу [58] для автоматического выбора порога. Результат — бинарная маска мозга, отделяющая воксели мозга от фона. Пример применения маски мозга на срезы снимка фМРТ показан на рис. 13. Важный этап подготовки данных — приведение записей ЭЭГ к фиксированному набору каналов. Монтаж набора данных [27] включает $K = 61$ кортикальный электрод. Расположение электродов на скальпе согласно системе 10–20 показано на рис. 14. Однако в ряде записей часть каналов отсутствует, в результате чего количество доступных каналов $|\mathcal{C}_i| \geq 50$ варьируется. Пересечение множеств доступных каналов для всей выборки оказывается пустым ($\bigcap_i \mathcal{C}_i = \emptyset$), поскольку не существует канала, присутствующего без исключений во всех элементах выборки. Следовательно, использование общего для всех записей подмножества каналов невозможно, что обуславливает необходимость восстановления отсутствующих сигналов до полного набора из $K = 61$ канала согласно методу, описанному в разделе 3.3.1, см. (17). Для выбора оптимальной стратегии восстановления проведено сравнение четырех методов: нулевого заполнения, интерполяции по ближайшему соседу и двух вариантов метода k -ближайших соседей с евклидовой и сферической метриками. Качество интерполяции оценивалось по среднеквадратичной ошибке (MSE) восстановления сигнала, рассчитанной независимо для каждого канала. Результаты представлены на рис. 15, где по оси абсцисс отложен индекс канала, а по оси ординат — значение ошибки.

Таблица 3: Описание оборудования и основные параметры нейросигналов

Модальность	Оборудование	Частота дискретизации	Каналы
ЭЭГ	Brain Products BrainCap MR	5000 Гц	61 кортикальный электрод
фМРТ	Siemens 3.0 T TIM Trio	0,476 Гц	12-канальная головная катушка




Рис. 13: Для снижения размерности данных фМРТ применяются маски головного мозга, исключаяющие фоновые воксели, не несущие информации о визуальном стимуле. Маски формируются на основе анализа наиболее изменчивых вокселей в ответ на стимуляцию. Воксели, включенные в маску, выделены красным цветом

4.3.2. Параметры энкодеров

В экспериментах использовались две специализированные архитектуры, адаптированные под особенности каждой модальности. Энкодер фМРТ начинается с персонализированной линейной проекции: для каждого участника воксели, отобранные с помощью индивидуальной бинарной маски, проецируются в пространство размерности 4096 обучаемым линейным слоем. За этим следует остаточный многослойный перцептрон, состоящий из трех полносвязных преобразований: первый расширяет представление до 2048, второй сохраняет эту размерность, а третий сжимает до 1024. Между слоями применяются нелинейность GELU и нормализация по слою; к выходу каждого блока добавляется остаточное соединение от входа. Dropout во всех слоях установлен в 0,1.

Для обработки ЭЭГ-сигналов применялся компактный энкодер. Входные данные имеют размер 61×525 , где 60 каналов соответствуют кортикальным электродам, а один дополнительный канал — обучаемому эмбедингу участника. Архитектура включает три последовательные свертки: временная свертка с ядром (1, 32) и 256 фильтрами, пространственная свертка с ядром (61, 1) и 512 фильтрами, а также глобальная свертка с ядром (1, 525) и 1024 фильтрами. После сверток следует MLP-проектор, реализующий преобразование $1024 \rightarrow 2048 \rightarrow 1024$ с нелинейностью GELU и LayerNorm. Dropout во всех сверточных и проекционных слоях равен 0,1. Выходной эмбединг имеет размерность 1024,




Рис. 14: Конфигурация монтажа из $K = 61$ кортикального электрода, используемая в датасете [27]. Датчики расположены согласно системе 10–20. Данная схема используется для восстановления отсутствующих каналов методом k -ближайших соседей, описанным в разделе 3.3.1.

что обеспечивает совместимость с модулем слияния и CLIP-пространством.

Модуль объединения эмбедингов фМРТ и ЭЭГ реализован как двух-слойный MLP: первый слой расширяет конкатенированное представление (размерность 2048) до 4096, второй сжимает его обратно до целевой размерности 1024. Активация — GELU, dropout — 0,1. Выходной эмбединг лежит в CLIP-пространстве и подается как условие при генерации изображений.

4.3.3. Результаты экспериментов

Для вычислительных экспериментов из всего набора стимулов датасета [27] было отобрано подмножество видеозаписей, разумно сочетающее объем данных с семантическим разнообразием визуальных стимулов. Всего датасет содержит




Рис. 15: Сравнение стратегий восстановления отсутствующих каналов ЭЭГ. По оси абсцисс отложен индекс канала, по оси ординат — среднеквадратичная ошибка (MSE). Метод нулевого заполнения характеризуется максимальной ошибкой, тогда как алгоритмы на основе k -ближайших соседей обеспечивают минимальные значения MSE для большинства каналов.

пять типов видеостимулов: абстрактную анимацию **Inscapes**, мультфильмы **The Present** и **Despicable Me**, а также натуралистические видеоролики с обезьянами — **monkey1**, **monkey2**, **monkey5**. Два из них — **Inscapes** и **Despicable Me** — заметно сдвинуты по домену относительно реалистичных сцен. **Inscapes** — это компьютерно сгенерированная последовательность абстрактных трехмерных фигур, лишенных семантически интерпретируемых объектов, а **The Present** и **Despicable Me** принадлежат к жанру анимации с сильно стилизованной визуальной подачей. Обучение на гетерогенной смеси столь различных доменов без явной доменной адаптации приводит к конфликту градиентных сигналов и ухудшению обобщающей способности модели. В связи с этим для основного эксперимента были выбраны три видеостимула из категории **monkey**, которые обеспечивают достаточное разнообразие сцен: различные ракурсы, освещение, действия персонажей, при сохранении единого визуального домена — натуралистической видеосъемки. Объемы данных по каждому датасету приведены в табл. 4.

Для верификации эффективности предложенного подхода проведены два эксперимента: визуальный анализ изображений-реконструкций и количественная оценка через CLIP-Score.

В первом эксперименте выполнено сравнение реконструкций, полученных

Таблица 4: Объемы данных по видеостимулам датасета **monkey***, использованным в основном эксперименте. Данные разделены в пропорции 80% к 20% для обучения и тестирования соответственно, с равномерным распределением записей испытуемых между выборками

Видеостимул	Общий объем	Обучающая выборка	Тестовая выборка
monkey1	5 941	4 753	1 188
monkey2	4 477	3 582	895
monkey5	4 579	3 664	915

с диффузионной априорной моделью и без нее на тестовых объектах из датасета **monkey***. Примеры приведены на рис. 16. Для проверки гипотезы о чувствительности модели к распределению визуальных стимулов был проведен дополнительный эксперимент по кросс-доменной реконструкции. Модель, обученная исключительно на датасете **monkey***, применялась для декодирования сигналов фМРТ–ЭЭГ, зарегистрированных при просмотре абстрактной анимации **Inscapes**. Поскольку визуальные характеристики стимулов **Inscapes** принципиально отличаются от реалистичных сцен, на которых проводилось обучение, энкодер фМРТ–ЭЭГ не получает на вход паттерны нейронной активности, соответствующие выученному распределению. В результате комбинированный эмбединг $\mathbf{z}_c$ формируется в области латентного пространства, удаленной от кластеров, ассоциированных с обучающими стимулами, что приводит к генерации семантически несогласованных изображений, см. рис. 17. Без явной доменной адаптации или аугментации тренировочных данных обобщение на распределения с сильным визуальным сдвигом не гарантируется. Для оценки устойчивости моделей необходим датасет с выраженной доменной разнородностью, однако, как показано в разделе 1.2, открытые мультимодальные наборы данных, обладающие подобным разнообразием визуальных стимулов, на текущий момент отсутствуют.

Во втором эксперименте проводится количественная оценка с использованием метрики CLIP-Score — косинусной близости между CLIP-эмбедингом реконструированного изображения $\mathbf{z}_I$ и комбинированным представлением мозговой активности $\mathbf{z}_c$:

$$\text{CLIP-Score}(\mathbf{z}_c, \mathbf{z}_I) = \frac{\langle \mathbf{z}_c, \mathbf{z}_I \rangle}{\|\mathbf{z}_c\| \cdot \|\mathbf{z}_I\|}. \quad (23)$$



Рис. 16: Примеры реконструкции изображений по сигналам фМРТ–ЭЭГ. Строки соответствуют различным режимам: (1) оригинальное изображение; (2) реконструкция из CLIP-эмбединга оригинального изображения с помощью предобученной SDXL (предельное качество реконструкции); (3) реконструкция предложенным методом без диффузионной априорной модели; (4) реконструкция предложенным методом с диффузионной априорной моделью. Применение априорной модели повышает семантическую согласованность реконструированных изображений с исходными стимулами

Метрики вычислялись на тестовой выборке датасета [27], использовались данные из видеостимулов *monkey1*, *monkey2*, *monkey5*. Усреднение проводилось по участникам и объектам. Для получения результатов в табл. 5 были использованы следующие конфигурации моделей:

1. **ЭЭГ**: используется только энкодер ЭЭГ $\mathcal{E}_e$, модуль объединения отключен, эмбединг $\mathbf{Z}_e$ напрямую используется для реконструкции без априорной модели.
2. **фМРТ**: используется только энкодер фМРТ $\mathcal{E}_f$, модуль объединения отключен, эмбединг $\mathbf{Z}_f$ напрямую используется для реконструкции без априорной модели.
3. **фМРТ–ЭЭГ**: используются оба энкодера $\mathcal{E}_e$ и $\mathcal{E}_f$ с модулем объединения $\mathcal{F}$, формирующим комбинированный эмбединг $\mathbf{Z}_c$ без априорной модели.
4. **ЭЭГ & Diffusion Prior**: используется энкодер ЭЭГ с последующей априорной диффузионной моделью для уточнения эмбединга перед генерацией.

1. Оригинальное
изображение

2. Оригинальная
реконструкция

3. Предлагаемым
методом

4. Предлагаемым
методом с
Diffusion Prior




Рис. 17: Пример реконструкции стимула из домена **Inscapes** моделью, обученной на датасете **monkey***. Строки соответствуют различным режимам: (1) оригинальное изображение; (2) реконструкция из CLIP-эмбединга оригинального изображения с помощью предобученной SDXL (предельное качество реконструкции); (3) реконструкция предложенным методом без диффузионной априорной модели; (4) реконструкция предложенным методом с диффузионной априорной моделью. Отсутствие семантической согласованности обусловлено доменным сдвигом между обучающими и тестируемыми стимулами

5. **фMPT & Diffusion Prior**: используется энкодер фMPT с последующей априорной диффузионной моделью для уточнения эмбединга перед генерацией.
6. **фMPT–ЭЭГ & Diffusion Prior**: используется полная архитектура с обоими энкодерами, модулем объединения и априорной диффузионной моделью.

Полученные результаты демонстрируют, что использование одной модальности дает худшие показатели по сравнению с комбинированной моделью на основе фMPT и ЭЭГ. Более того, интеграция диффузионной априорной модели существенно повышает CLIP-Score для всех конфигураций, а наилучшее качество достигается при совместном использовании фMPT, ЭЭГ и диффузионной априорной модели. Это подтверждает, что мультимодальность компенсирует фундаментальные ограничения отдельных методов регистрации, а двухстадийная генерация критически важна для семантической точности реконструкции.

Таблица 5: Сравнение CLIP-Score для различных конфигураций модели на трех видеостимулах из набора данных. Произведено усреднение по всем 22 испытуемым, нижним регистром указаны среднеквадратичные отклонения. Наилучшие результаты выделены жирным шрифтом

Модель	Название видеостимула		
	monkey1	monkey2	monkey5
ЭЭГ	0,231 $\pm$ 0,004	0,262 $\pm$ 0,004	0,224 $\pm$ 0,005
фМРТ	0,254 $\pm$ 0,004	0,270 $\pm$ 0,003	0,242 $\pm$ 0,003
фМРТ–ЭЭГ	0,310 $\pm$ 0,003	0,312 $\pm$ 0,004	0,284 $\pm$ 0,003
ЭЭГ & Diffusion Prior	0,542 $\pm$ 0,005	0,557 $\pm$ 0,003	0,538 $\pm$ 0,003
фМРТ & Diffusion Prior	0,564 $\pm$ 0,005	0,571 $\pm$ 0,004	0,551 $\pm$ 0,005
фМРТ–ЭЭГ & Diffusion Prior	0,668 $\pm$ 0,003	0,647 $\pm$ 0,005	0,644 $\pm$ 0,003

4.3.4. Ограничения метода

Отдельно стоит оговорить ограничения, которые накладывает использование CLIP-пространства как промежуточного представления. CLIP обучался сопоставлять изображения с текстовыми описаниями, поэтому его эмбединги несут преимущественно семантику высокого уровня — объекты, их взаимосвязи, общий контекст сцены — но почти не удерживают низкоуровневые визуальные характеристики: точные текстуры, локальные паттерны, пиксельные детали. Как следствие, предложенный метод реконструкции нацелен на семантическую согласованность полученных изображений с исходными стимулами, а не на точное пиксельное воспроизведение низкоуровневых деталей. Это ограничение неизбежно вытекает из самого выбора CLIP в качестве промежуточного представления и присуще всем подходам на основе CLIP-эмбедингов [25, 26, 39].

Метод проверялся на одном публичном датасете [27], а качество реконструкции оценивалось преимущественно метрикой CLIP-Score. Кросс-доменные эксперименты подтвердили, что обобщающая способность модели не безгранична: на стимулах из домена, которого не было в обучающей выборке — например, на абстрактной анимации **Inscapes** — качество реконструкции заметно снижается. Причина в том, что энкодеры подстраивают свои представления под конкретное распределение визуальных признаков тренировочного домена и не обладают встроенной инвариантностью к резким семантическим сдвигам. Поэтому перенос метода на другие типы стимулов — статичные изображения, абстрактные паттерны, текстовые сцены — либо на иные условия регистрации потребует

дополнительной валидации и, вероятно, явной доменной адаптации. Сказывается и индивидуальная вариабельность нейронной активности участников: от нее эффективность метода тоже может зависеть. Привлечение гетерогенных датасетов или альтернативных метрик усилило бы выводы, хотя и имеющихся результатов достаточно для подтверждения работоспособности подхода в рамках заявленного домена.

Заключение

Декодирование визуальной информации по сигналам мозга решено в три последовательных этапа, отвечающих возрастающей сложности учитываемой структуры данных: анализ временной динамики фМРТ, учет ее пространственно-временной структуры в условиях ограниченного объема выборки и мультимодальное объединение фМРТ и ЭЭГ. Завершающим этапом является предложенная мультимодальная архитектура, восстанавливающая визуальные стимулы по одновременным сигналам фМРТ–ЭЭГ: комбинированные эмбединги мозговой активности контрастивно выравниваются с CLIP-пространством, после чего генерация выполняется в две стадии — через априорную диффузионную модель и предобученную SDXL. Существенный методологический вклад — конвейер предобработки записей, который согласует модальности во времени, снижает размерность фМРТ и приводит ЭЭГ-сигналы к унифицированному набору каналов. Эксперименты подтверждают, что совместное использование модальностей превосходит одномодальные аналоги, а пространственно-временные характеристики данных фМРТ–ЭЭГ дополняют друг друга. Подключение диффузионной априорной модели дополнительно повышает семантическую согласованность реконструкций.

Кросс-доменный эксперимент дает ожидаемую картину: на стимулах, не представленных в обучающей выборке, качество падает — сказываются настройка энкодеров под конкретное распределение признаков и отсутствие встроенной доменной инвариантности. Этот результат очерчивает границы применимости метода и обозначает доменную адаптацию как направление дальнейшей работы. В целом предложенный подход закладывает прочную методологическую основу для последующих исследований в области мультимодального нейродекодирования и потенциально применим в задачах интерфейсов мозг–компьютер.

Список литературы

1. Brain-computer interface technology: a review of the first international meeting / Jonathan R Wolpaw, Niels Birbaumer, William J Heetderks et al. // *IEEE transactions on rehabilitation engineering*. — 2000. — Vol. 8, no. 2. — Pp. 164–173. — URL: <https://doi.org/10.1109/TRE.2000.847807>.
2. Mining event-related brain dynamics / Scott Makeig, Stefan Debener, Julie Onton, Arnaud Delorme // *Trends in cognitive sciences*. — 2004. — Vol. 8, no. 5. — Pp. 204–210. — URL: <https://doi.org/10.1016/j.tics.2004.03.008>.
3. McFarland Dennis J. Brain-computer interfaces for communication and control // *Clin. Neurophysiol.* — 2002. — Vol. 113. — Pp. 767–791. — URL: [https://doi.org/10.1016/S1388-2457\(02\)00057-3](https://doi.org/10.1016/S1388-2457(02)00057-3).
4. Assistive Mobile Robot with Shared Control of Brain-Machine Interface and Computer Vision / Yonghao Song, Weifeng Wu, Chengqi Lin et al. // 2020 IEEE 4th Information Technology, Networking, Electronic and Automation Control Conference (ITNEC) / IEEE. — Vol. 1. — 2020. — Pp. 405–409. — URL: <https://doi.org/10.1109/ITNEC48623.2020.9085096>.
5. A self-paced BCI with a collaborative controller for highly reliable wheelchair driving: Experimental tests with physically disabled individuals / Aniana Cruz, Gabriel Pires, Ana Lopes et al. // *IEEE Transactions on Human-Machine Systems*. — 2021. — Vol. 51, no. 2. — Pp. 109–119. — URL: <https://doi.org/10.1109/THMS.2020.3047597>.
6. Dorin Daniil Dmitrievich, Grabovoy Andrey Valerievich, Strijov Vadim. Enhancing fMRI data decoding with spatiotemporal characteristics in limited dataset // *Doklady Rossijskoj Akademii Nauk. Matematika, Informatika, Processy Upravleniya*. — 2025. — Vol. 527. — Pp. 11–30.
7. Decoding hand movements from human EEG to control a robotic arm in a simulation environment / Andreas Schwarz, Maria Katharina Höller, Joana Pereira et al. // *Journal of neural engineering*. — 2020. — Vol. 17, no. 3. — P. 036010. — URL: <https://doi.org/10.1088/1741-2552/ab882e>.

8. Forecasting fMRI images from video sequences: linear model analysis / Daniil Dorin, Nikita Kiselev, Andrey Grabovoy, Vadim Strijov // *Health Information Science and Systems*. — 2024. — Vol. 12, no. 1. — P. 55. — URL: <https://doi.org/10.1007/s13755-024-00315-5>.
9. Time course EPI of human brain function during task activation / Peter A. Bandettini, Eric C. Wong, R. Scott Hinks et al. // *Magnetic Resonance in Medicine*. — 1992. — июнь. — Vol. 25, no. 2. — Pp. 390–397. — URL: <http://dx.doi.org/10.1002/mrm.1910250220>.
10. Brain magnetic resonance imaging with contrast dependent on blood oxygenation. / S Ogawa, T M Lee, A R Kay, D W Tank // *Proceedings of the National Academy of Sciences*. — 1990. — декабрь. — Vol. 87, no. 24. — Pp. 9868–9872. — URL: <http://dx.doi.org/10.1073/pnas.87.24.9868>.
11. Logothetis Nikos K. The Underpinnings of the BOLD Functional Magnetic Resonance Imaging Signal // *The Journal of Neuroscience*. — 2003. — май. — Vol. 23, no. 10. — Pp. 3963–3971. — URL: <https://doi.org/10.1523/jneurosci.23-10-03963.2003>.
12. Glover Gary H. Overview of Functional Magnetic Resonance Imaging // *Neurosurgery Clinics of North America*. — 2011. — апрель. — Vol. 22, no. 2. — Pp. 133–139. — URL: <https://doi.org/10.1016/j.nec.2010.11.001>.
13. Menon Ravi S, Kim Seong-Gi. Spatial and temporal limits in cognitive neuroimaging with fMRI // *Trends in cognitive sciences*. — 1999. — Vol. 3, no. 6. — Pp. 207–216. — URL: [https://doi.org/10.1016/s1364-6613\(99\)01329-7](https://doi.org/10.1016/s1364-6613(99)01329-7).
14. Logothetis Nikos K. What we can do and what we cannot do with fMRI // *Nature*. — 2008. — Vol. 453, no. 7197. — Pp. 869–878. — URL: <https://doi.org/10.1038/nature06976>.
15. Srinivasan Ramesh. Methods to improve the spatial resolution of EEG.
16. Schlögl Alois, Slater Mel, Pfurtscheller Gert. Presence research and EEG. — 2002. — 01.

17. Learning a common dictionary for subject-transfer decoding with resting calibration / Hiroshi Morioka, Atsunori Kanemura, Jun-ichiro Hirayama et al. // *NeuroImage*. — 2015. — Vol. 111. — Pp. 167–178.
18. Transfer learning in brain-computer interfaces / Vinay Jayaram, Morteza Alamgir, Yasemin Altun et al. // *IEEE Computational Intelligence Magazine*. — 2016. — Vol. 11, no. 1. — Pp. 20–31.
19. Ritter Petra, Villringer Arno. simultaneous EEG–fMRI // *Neuroscience & Biobehavioral Reviews*. — 2006. — Vol. 30, no. 6. — Pp. 823–838.
20. Removal of fMRI environment artifacts from EEG data using optimal basis sets / Rami K Niazy, Christian F Beckmann, Gian Domenico Iannetti et al. // *Neuroimage*. — 2005. — Vol. 28, no. 3. — Pp. 720–737.
21. Methods for simultaneous EEG–fMRI: an introductory review / René J Huster, Stefan Debener, Tom Eichele, Christoph S Herrmann // *Journal of Neuroscience*. — 2012. — Vol. 32, no. 18. — Pp. 6053–6060.
22. Learning transferable visual models from natural language supervision / Alec Radford, Jong Wook Kim, Chris Hallacy et al. // International conference on machine learning / PMLR. — 2021. — Pp. 8748–8763.
23. Audio–text retrieval based on contrastive learning and collaborative attention mechanism / Tao Hu, Xuyu Xiang, Jiaohua Qin, Yun Tan // *Multimedia Systems*. — 2023. — Vol. 29, no. 6. — Pp. 3625–3638.
24. Connecting multi-modal contrastive representations / Zehan Wang, Yang Zhao, Haifeng Huang et al. // *Advances in Neural Information Processing Systems*. — 2023. — Vol. 36. — Pp. 22099–22114.
25. fmri-based decoding of visual information from human brain activity: A brief review / Shuo Huang, Wei Shao, Mei-Ling Wang, Dao-Qiang Zhang // *International Journal of Automation and Computing*. — 2021. — Vol. 18, no. 2. — Pp. 170–184.
26. Visual Decoding and Reconstruction via EEG Embeddings with Guided Diffusion / Dongyang Li, Chen Wei, Shiyong Li et al. // *Advances in Neural*

- Information Processing Systems / Ed. by A. Globerson, L. Mackey, D. Belgrave et al. — Vol. 37. — Curran Associates, Inc., 2024. — Pp. 102822–102864. — URL: https://proceedings.neurips.cc/paper_files/paper/2024/file/ba5f1233efa77787ff9ec015877dbd1f-Paper-Conference.pdf.
27. An open-access dataset of naturalistic viewing using simultaneous EEG-fMRI / Qawi K. Telesford, Eduardo Gonzalez-Moreira, Ting Xu et al. // *Scientific Data*. — 2023. — август. — Vol. 10, no. 1. — URL: <http://dx.doi.org/10.1038/s41597-023-02458-8>.
 28. *Simonyan Karen, Zisserman Andrew*. Very Deep Convolutional Networks for Large-Scale Image Recognition. — 2015. — URL: <https://arxiv.org/abs/1409.1556>.
 29. *He Kaiming, Zhang Xiangyu, Ren Shaoqing, Sun Jian*. Deep Residual Learning for Image Recognition. — 2015. — URL: <https://arxiv.org/abs/1512.03385>.
 30. *Dosovitskiy Alexey, Beyer Lucas, Kolesnikov Alexander et al.* An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. — 2021. — URL: <https://arxiv.org/abs/2010.11929>.
 31. *Caron Mathilde, Touvron Hugo, Misra Ishan et al.* Emerging Properties in Self-Supervised Vision Transformers. — 2021. — URL: <https://arxiv.org/abs/2104.14294>.
 32. Simultaneous EEG and functional MRI data during rest and sleep from humans / Yameng Gu, Lucas E. Sainburg, Feng Han, Xiao Liu // *Data in Brief*. — 2023. — июнь. — Vol. 48. — P. 109059. — URL: <http://dx.doi.org/10.1016/j.dib.2023.109059>.
 33. Le Petit Prince Hong Kong (LPPHK): Naturalistic fMRI and EEG data from older Cantonese speakers / Mohammad Momenian, Zhengwu Ma, Shuyi Wu et al. — 2024. — апрель. — URL: <http://dx.doi.org/10.1101/2024.04.24.590842>.
 34. Open multimodal iEEG-fMRI dataset from naturalistic stimulation with a short audiovisual film / Julia Berezutskaya, Mariska J. Vansteensel, Erik J. Aarnoutse et al. // *Scientific Data*. — 2022. — март. — Vol. 9, no. 1. — URL: <https://doi.org/10.1038/s41597-022-01173-0>.

35. Simultaneous and independent electroencephalography and magnetic resonance imaging: A multimodal neuroimaging dataset / Jonathan Gallego-Rudolf, María Corsi-Cabrera, Luis Concha et al. // *Data in Brief*. — 2023. — декабрь. — Vol. 51. — P. 109661. — URL: <http://dx.doi.org/10.1016/j.dib.2023.109661>.
36. *Wakeman Daniel G, Henson Richard N*. A multi-subject, multi-modal human neuroimaging dataset // *Scientific Data*. — 2015. — январь. — Vol. 2, no. 1. — URL: <http://dx.doi.org/10.1038/sdata.2015.1>.
37. *Ozcelik Furkan, VanRullen Rufin*. Natural scene reconstruction from fMRI signals using generative latent diffusion. — 2023. — URL: <https://arxiv.org/abs/2303.05334>.
38. *Chen Zijiao, Qing Jiaxin, Zhou Juan Helen*. Cinematic Mindscapes: High-quality Video Reconstruction from Brain Activity. — 2023. — URL: <https://arxiv.org/abs/2305.11675>.
39. *Scotti Paul S., Banerjee Atmadeep, Goode Jimmie et al*. Reconstructing the Mind's Eye: fMRI-to-Image with Contrastive Learning and Diffusion Priors. — 2023. — URL: <https://arxiv.org/abs/2305.18274>.
40. NeuroGAN: image reconstruction from EEG signals via an attention-based GAN / Rahul Mishra, Krishan Sharma, R. R. Jha, Arnav Bhavsar // *Neural Computing and Applications*. — 2022. — декабрь. — URL: <http://dx.doi.org/10.1007/s00521-022-08178-1>.
41. *Singh Prajwal, Pandey Pankaj, Miyapuram Krishna, Raman Shanmuganathan*. EEG2IMAGE: Image Reconstruction from EEG Brain Signals. — 2023. — URL: <https://arxiv.org/abs/2302.10121>.
42. *Esser Patrick, Rombach Robin, Ommer Björn*. Taming Transformers for High-Resolution Image Synthesis. — 2021. — URL: <https://arxiv.org/abs/2012.09841>.
43. *Hatamizadeh Ali, Song Jiaming, Liu Guilin et al*. DiffiT: Diffusion Vision Transformers for Image Generation. — 2024. — URL: <https://arxiv.org/abs/2312.02139>.

44. *Crowson Katherine, Biderman Stella, Kornis Daniel et al.* VQGAN-CLIP: Open Domain Image Generation and Editing with Natural Language Guidance. — 2022. — URL: <https://arxiv.org/abs/2204.08583>.
45. *Podell Dustin, English Zion, Lacey Kyle et al.* SDXL: Improving Latent Diffusion Models for High-Resolution Image Synthesis. — 2023. — URL: <https://arxiv.org/abs/2307.01952>.
46. *Ye Hu, Zhang Jun, Liu Sibio et al.* IP-Adapter: Text Compatible Image Prompt Adapter for Text-to-Image Diffusion Models. — 2023. — URL: <https://arxiv.org/abs/2308.06721>.
47. *Poldrack Russell A.* Region of interest analysis for fMRI // *Social cognitive and affective neuroscience*. — 2007. — Vol. 2, no. 1. — Pp. 67–70. — URL: <https://doi.org/10.1093/scan/nsm006>.
48. Riemannian geometry applied to BCI classification / Alexandre Barachant, Stéphane Bonnet, Marco Congedo, Christian Jutten // International conference on latent variable analysis and signal separation / Springer. — 2010. — Pp. 629–636. — URL: https://doi.org/10.1007/978-3-642-15995-4_78.
49. Multiclass brain–computer interface classification by Riemannian geometry / Alexandre Barachant, Stéphane Bonnet, Marco Congedo, Christian Jutten // *IEEE Transactions on Biomedical Engineering*. — 2011. — Vol. 59, no. 4. — Pp. 920–928. — URL: <https://doi.org/10.1109/TBME.2011.2172210>.
50. *Congedo Marco, Barachant Alexandre, Bhatia Rajendra.* Riemannian geometry for EEG-based brain-computer interfaces; a primer and a review // *Brain-Computer Interfaces*. — 2017. — Vol. 4, no. 3. — Pp. 155–174. — URL: <https://doi.org/10.1080/2326263X.2017.1297192>.
51. *Yger Florian, Berar Maxime, Lotte Fabien.* Riemannian approaches in brain-computer interfaces: a review // *IEEE Transactions on Neural Systems and Rehabilitation Engineering*. — 2016. — Vol. 25, no. 10. — Pp. 1753–1762. — URL: <https://doi.org/10.1109/TNSRE.2016.2627016>.
52. Classification models for P300 evoked potentials / Alina Maksimovna Samokhina, VV Goncharenko, RK Gtigoryan, VV Strijov // *Sistemy i Sredstva Informatiki*

- [*Systems and Means of Informatics*]. — 2022. — Vol. 32, no. 3. — Pp. 36–49. — URL: <https://doi.org/10.14357/08696527220304>.
53. *Hyvärinen Aapo, Oja Erkki*. Independent component analysis: algorithms and applications // *Neural networks*. — 2000. — Vol. 13, no. 4-5. — Pp. 411–430. — URL: [https://doi.org/10.1016/S0893-6080\(00\)00026-5](https://doi.org/10.1016/S0893-6080(00)00026-5).
54. *Jolliffe Ian T*. Principal Component Analysis for Special Types of Data // *Principal Component Analysis*. — Springer New York, 2002. — Pp. 338–372. — URL: https://doi.org/10.1007/0-387-22440-8_13.
55. *Hochreiter Sepp, Schmidhuber Jürgen*. Long short-term memory // *Neural computation*. — 1997. — Vol. 9, no. 8. — Pp. 1735–1780. — URL: <https://doi.org/10.1162/neco.1997.9.8.1735>.
56. Attention is all you need / Ashish Vaswani, Noam Shazeer, Niki Parmar et al. // *Advances in neural information processing systems*. — 2017. — Vol. 30.
57. Classification of recurrent major depressive disorder using a new time series feature extraction method through multisite rs-fMRI data / Peishan Dai, Da Lu, Yun Shi et al. // *Journal of Affective Disorders*. — 2023. — Vol. 339. — Pp. 511–519. — URL: <https://doi.org/10.1016/j.jad.2023.07.077>.
58. *Otsu Nobuyuki et al*. A threshold selection method from gray-level histograms // *Automatica*. — 1975. — Vol. 11, no. 285-296. — Pp. 23–27.
59. *Ho Jonathan, Jain Ajay, Abbeel Pieter*. Denoising Diffusion Probabilistic Models. — 2020. — URL: <https://arxiv.org/abs/2006.11239>.
60. Cortical Activation While Watching Video Montage: An fMRI Study / Daniel Anderson, Katherine Fite, Nicole Petrovich, Joy Hirsch // *Media Psychology - MEDIA PSYCHOL*. — 2006. — 02. — Vol. 8. — Pp. 7–24.
61. Distributed and overlapping representations of faces and objects in ventral temporal cortex / James V Haxby, M Ida Gobbini, Maura L Furey et al. // *Science*. — 2001. — Vol. 293, no. 5539. — Pp. 2425–2430. — URL: <https://doi.org/10.1126/science.1063736>.