

Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский физико-технический институт
(национальный исследовательский университет)»
Физтех-школа прикладной математики и информатики
Кафедра интеллектуальных систем

Дорин Даниил Дмитриевич

**ДЕКОДИРОВАНИЕ ВИЗУАЛЬНОЙ ИНФОРМАЦИИ ИЗ
СИГНАЛОВ МОЗГА НА ОСНОВЕ
ПРОСТРАНСТВЕННО-ВРЕМЕННЫХ
ХАРАКТЕРИСТИК**

09.04.01 — Информатика и вычислительная техника

Выпускная квалификационная работа магистра

Научный руководитель:
Грабовой Андрей Валериевич,
канд. физ.-мат. наук

Москва — 2026

Аннотация

Реконструкция визуальных стимулов по нейронным сигналам представляет собой фундаментальную задачу нейродекодирования, находящуюся на пересечении вычислительной нейронауки и современного машинного обучения. Несмотря на успехи, достигнутые с применением контрастивных представлений и диффузионных генеративных моделей, большинство существующих подходов ограничены использованием одной модальности — либо функциональной магнитно-резонансной томографии (фМРТ) с высоким пространственным разрешением, либо электроэнцефалографии (ЭЭГ) с превосходной временной точностью. Совместное использование этих модальностей остается малоизученным направлением.

В данной работе предлагается мультимодальная архитектура, которая одновременно обрабатывает фМРТ и ЭЭГ сигналы для реконструкции визуальных стимулов. Для согласования асинхронных и неоднородных записей разработан конвейер предобработки, включающий учет гемодинамической задержки, построение индивидуальных масок мозга фМРТ и восстановление пропущенных ЭЭГ-каналов методом пространственной интерполяции. Эмбединги сигналов мозга контрастивно обучаются для приближения к CLIP-эмбедингам изображений. Предложенная двухстадийная схема генерации включает: синтез промежуточного латентного представления через априорную модель, обученную на совместных фМРТ–ЭЭГ эмбедингах, и декодирование этого представления с помощью предобученной диффузионной модели SDXL. Эксперименты на открытом мультимодальном датасете подтверждают эффективность предложенной архитектуры в задаче нейродекодирования. По метрике CLIP-Score мультимодальная модель превосходит одномодальные аналоги, а интеграция диффузионной априорной модели дополнительно повышает семантическую согласованность реконструкций. Проведенный анализ исключением компонент и кросс-доменных тестов позволяет оценить устойчивость модели в рамках обучающего распределения и обозначить границы его обобщающей способности.

Содержание

Обозначения и сокращения	4
Введение	5
1 Анализ предметной области и обзор существующих решений	9
1.1 Визуальные энкодеры для извлечения семантических признаков .	9
1.2 Наборы данных с одновременной регистрацией фМРТ и ЭЭГ . .	9
1.3 Одномодальные методы декодирования визуальной информации .	10
1.4 Генеративные модели для реконструкции изображений	11
2 Постановка задачи	12
2.1 Общая постановка мультимодального декодирования	12
2.2 Двумодальное декодирование фМРТ–ЭЭГ	12
2.3 Гипотеза о гемодинамической задержке	12
3 Метод	14
3.1 Контрастивное обучение комбинированных представлений фМРТ– ЭЭГ сигналов	14
3.2 Процесс реконструкции стимулов	21
4 Вычислительный эксперимент	23
4.1 Данные	23
4.2 Параметры энкодеров	25
4.3 Результаты экспериментов	27
4.4 Ограничения метода	31
Заключение	33
Список литературы	34

Обозначения и сокращения

Сокращения

ИМК	интерфейс мозг–компьютер
фМРТ	функциональная магнитно-резонансная томография
ЭЭГ	электроэнцефалография
BOLD	blood-oxygen-level dependent
CLIP	Contrastive Language–Image Pre-training
SDXL	Stable Diffusion XL
DDPM	Denoising Diffusion Probabilistic Model
IP-Adapter	Image Prompt Adapter
MLP	многослойный перцептрон
CLIP-Score	косинусная близость в пространстве CLIP-эмбеддингов

Основные обозначения

$\mathcal{X}_f, \mathcal{X}_e$	пространства данных фМРТ и ЭЭГ
$\mathcal{Y}$	пространство визуальных стимулов
$\mathbf{F}_i, \mathbf{E}_i, \mathbf{I}_i$	фМРТ, ЭЭГ и изображение i -го наблюдения
$\mathfrak{D}$	обучающий набор триплетов
N	объем выборки
$\mathbf{f}$	целевое отображение $\mathcal{X}_f \times \mathcal{X}_e \rightarrow \mathcal{Y}$
$\mathcal{E}_f, \mathcal{E}_e, \mathcal{F}$	энкодеры фМРТ, ЭЭГ и модуль объединения
$\mathbf{Z}_f, \mathbf{Z}_e, \mathbf{Z}_c, \mathbf{Z}_I$	эмбеддинги фМРТ, ЭЭГ, комбинированный и CLIP
d_f, d_e, d	размерности латентных пространств
Δt	гемодинамическая задержка BOLD-сигнала
τ	обучаемая температура контрастивной функции потерь
$\mathcal{L}_{\text{contr}}$	контрастивная функция потерь
$\mathcal{L}_{\text{prior}}$	функция потерь априорной диффузионной модели
B	размер батча

Введение

Современные достижения в области анализа нейробиологических данных и нейровизуализации существенно расширили возможности разработки интерфейсов мозг–компьютер (ИМК) [1, 2]. ИМК представляют собой технологию прямого взаимодействия между нервной системой и внешними устройствами, минуя периферические нервно-мышечные пути [3]. На основе регистрации и декодирования нейробиологических сигналов — в частности, электроэнцефалограммы (ЭЭГ), магнитоэнцефалограммы (МЭГ) и функциональной магнитно-резонансной томографии (фМРТ) — такие системы позволяют преобразовывать ментальные намерения и когнитивные состояния в управляющие команды для протезов, роботов или компьютерных интерфейсов [4, 5, 6]. Это особенно актуально для пациентов с тяжелыми двигательными или коммуникативными нарушениями, поскольку ИМК потенциально восстанавливают их способность к автономному взаимодействию с окружающей средой [7]. В данной работе в рамках ИМК исследуется задача декодирования и реконструкции визуальных стимулов на основе одновременных неинвазивных записей мозговой активности фМРТ и ЭЭГ. Эти методы регистрируют нейробиологические сигналы, которые отражают динамические процессы восприятия визуальных сцен. При этом восприятие определяется не только характеристиками внешнего стимула, но и внутренними когнитивными состояниями, эмоциональными реакциями, а также индивидуальным опытом наблюдателя.

ЭЭГ и фМРТ представляют собой две ключевые нейробиологические модальности, демонстрирующие взаимодополняющие спектры пространственно-временного разрешения. ФМРТ регистрирует гемодинамический ответ, связанный с нейронной активностью, посредством BOLD-сигнала, который возникает с задержкой 4–8 секунд [8, 9]. Такая задержка связана с медленным откликом сосудистой системы на потребность мозга в глюкозе [10, 11]. Преимуществом фМРТ является высокое пространственное разрешение, однако временное разрешение сильно ограничено, так как частота сканирования мала [12]. Кроме того, запись фМРТ чувствительна к артефактам, вызванным движениями головы, пульсацией, дыханием и тепловым шумом сканера [13, 14]. В свою очередь, ЭЭГ обеспечивает высокое временное разрешение, позволяя отслеживать динамику нейронных процессов в реальном времени [15]. Однако ее пространственное разрешение ограничено из-за объемной проводимости тканей головы, а качество

сигнала дополнительно снижается из-за низкого отношения сигнал к шуму [16] и выраженной межиндивидуальной вариабельности [17, 18]. Одновременная запись ЭЭГ и фМРТ позволяет объединить преимущества обеих модальностей, но требует учета специфики магнитно-резонансной среды: в условиях высокого магнитного поля возникают мощные артефакты — градиентные и кардиобаллистические [19, 20]. Для их компенсации необходимы магнитно-резонансно совместимые системы записи, точная синхронизация временных меток и специализированные методы постобработки [21].

В связи с развитием контрастивного обучения появилась возможность эффективно сопоставлять данные из разных модальностей. Так, в модели CLIP [22] с помощью контрастивной функции потерь, построенной на косинусном расстоянии, удалось обучить совместное латентное пространство для эмбедингов изображений и текстовых описаний. Аналогичный подход был распространен и на другие пары модальностей — при условии подбора соответствующих энкодеров [23, 24]. В области ИМК это привело к появлению методов реконструкции изображений по нейробиологическим сигналам, в первую очередь по фМРТ или ЭЭГ в отдельности [25, 26]. Основная идея большинства современных моделей заключается в том, чтобы контрастивно приблизить эмбединги мозговой активности к CLIP-эмбедингам изображений. Поскольку CLIP обучался на сопоставлении изображений и текста, его пространство эмбедингов обладает богатой семантической структурой и демонстрирует высокую эффективность в задачах zero-shot (англ. zero-shot, «без примеров»), то есть на новые данные без дополнительного обучения [22]. Это делает CLIP-эмбединги особенно подходящими для обуславливания генеративных моделей, используемых в реконструкции изображений, предъявленных испытуемому во время записи нейросигналов [26]. Однако существующие подходы опираются лишь на одну модальность. В то же время фМРТ и ЭЭГ демонстрируют фундаментально разные, но взаимодополняющие характеристики: первая обеспечивает высокое пространственное разрешение при низком временном, вторая — наоборот [12, 15]. Их комбинация позволяет компенсировать слабые стороны каждой из модальностей и потенциально повысить качество реконструкции.

В данной работе решается задача реконструкции изображений по одновременно зарегистрированным сигналам фМРТ–ЭЭГ, как проиллюстрировано на рис. 1.




Рис. 1: Иллюстрация задачи реконструкции изображений по одновременным сигналам фМРТ-ЭЭГ

До появления недавних мультимодальных наборов данных с визуальными стимулами, таких как [27], обработка ЭЭГ и фМРТ, как правило, проводилась отдельно. Новые датасеты открывают возможность интегрировать оба типа сигналов в единую архитектуру. По аналогии с предшествующими работами, в настоящей работе используется двухэтапный метод декодирования мозговой активности: 1) контрастивное выравнивание сигналов фМРТ и ЭЭГ с эмбедами изображений; 2) обуславливание предобученной модели генерации изображений на уточненный априорной моделью эмбединг сигналов мозга. Основной же вклад настоящей работы заключается в следующем:

- Вводится мультимодальная модель, использующая одновременно и фМРТ, и ЭЭГ сигналы для реконструкции изображений, просматриваемых пациентом.
- Предлагается архитектура мультимодальной модели, в которой обучаются три модуля: два энкодера, независимо обрабатывающих наблюдаемые сигналы, и модуль объединения, переводящий их в единое комбинированное представление.
- Проводится сравнительный анализ исключением модальностей, демонстрирующий необходимость учета обоих сигналов фМРТ и ЭЭГ совместно.

Публикации и апробация результатов работы. По теме исследования автором подготовлены и представлены следующие работы.

Публикации в научных журналах:

1. *Dorin D., Kiselev N., Grabovoy A.* Decoding Visual Information from Neural Signals: Image Reconstruction Based on Joint fMRI and EEG Analysis // *Informatika i ee Primeneniya.* — 2026.

Доклады на научных конференциях:

1. *Дорин Д. Д., Грабовой А. В.* Декодирование визуальной информации из сигналов мозга на основе пространственно-временных характеристик // 68-я Всероссийская научная конференция МФТИ — 2026.
2. *Дорин Д. Д., Киселев Н. С., Грабовой А. В.* Декодирование визуальных стимулов из мультимодальных сигналов мозга // 22-я конференция «Математические методы распознавания образов» (ММРО-2025).

1. Анализ предметной области и обзор существующих решений

1.1. Визуальные энкодеры для извлечения семантических признаков

Визуальный энкодер является одной из ключевых компонент рассматриваемой модели, поскольку от его качества напрямую зависит, насколько полностью удастся извлечь семантическую информацию из изображения, включая объекты, их позы и контекст сцены. Для многих задач традиционно используются предобученные с учителем энкодеры, среди которых наиболее распространены сверточные архитектуры VGG-19 [28] и ResNet [29], а также Vision Transformer (ViT) [30]. Эти модели обеспечивают устойчивые визуальные эмбединги, однако недавние исследования в области контрастивного и самообучения показывают, что такие подходы, как CLIP [22] и DINO [31], построенные на базе ViT, формируют более выразительные и обобщаемые представления по сравнению с моделями, обученными с учителем. Это преимущество подтверждается на широком спектре задач переноса обучения, включая декодирование и реконструкцию изображений по нейросигналам. В данной работе в качестве визуального энкодера выбран CLIP [22] — ввиду его высокой эффективности, устойчивости к доменным сдвигам и богатой семантической структуры латентного пространства.

1.2. Наборы данных с одновременной регистрацией фМРТ и ЭЭГ

Наличие высококачественных наборов данных с одновременными записями фМРТ и ЭЭГ при предъявлении визуальных стимулов является необходимым условием для постановки и решения задачи реконструкции изображений по мозговой активности. За последние годы появилось несколько открытых датасетов, включающих совместную регистрацию этих модальностей. Однако большинство доступных наборов либо исключают визуальную стимуляцию, например, регистрируют активность в состоянии покоя или при аудиостимуляции [32, 33], либо содержат разнесенные во времени сессии фМРТ и ЭЭГ [34], либо ориентированы на верификацию технической совместимости методов регистрации, а не на исследование стимул-зависимой нейродинамики [35]. Из доступных на момент написания работы датасетов лишь два обеспечивают одновременную регистрацию при предъявлении визуальных стимулов: датасет Telesford и др. [27] и датасет Wakeman и др. [36]. Первый содержит записи от 22 участников при просмотре

как синтетических стимулов — мерцающего шахматного поля и абстрактных сцен в парадигме Inscapes, — так и натуралистических — коротких видеороликов. Второй включает данные 16 участников при выполнении задачи распознавания статичных изображений лиц. В работе рассматривается датасет [27] в качестве основного, поскольку разнообразие стимулов — от контролируемых синтетических до динамических естественных видео — обеспечивает более широкое покрытие визуальных паттернов и способствует обучению обобщаемых моделей реконструкции. Именно на его основе формируются обучающие тройки (фМРТ, ЭЭГ, изображение).

1.3. Одномодальные методы декодирования визуальной информации

Недавние достижения в декодировании визуальной информации по фМРТ продемонстрировали высокое качество реконструкции за счет интеграции контрастивного обучения и генеративных моделей [25]. Авторы [37] предлагают двухэтапную модель: на первом этапе данные фМРТ кодируются с помощью регрессии, обучаемой индивидуально для каждого участника, после чего реконструируется грубое изображение с помощью VDVAE; на втором — изображение уточняется диффузионной моделью, обусловленной как CLIP-эмбедингами исходного изображения, так и его текстовым описанием, что обеспечивает высокую семантическую согласованность реконструкции. В работе [38] предлагается метод реконструкции видео по временному ряду фМРТ. Используется контрастивное обучение и CLIP-эмбединги, аналогично предыдущему исследованию. Генерация видео осуществляется с помощью модифицированной диффузионной модели с временным вниманием и обуславливанием на эмбединги фМРТ. В работе [39] предлагается диффузионная априорная модель для уточнения фМРТ-эмбедингов в CLIP-пространстве, устраняющая разрыв между модальностями и повышающая качество декодирования. На основе ЭЭГ также достигнуто сопоставимое качество реконструкции. Основная идея многих работ аналогична: двухэтапная реконструкция — сначала контрастивно обучаются эмбединги сигналов ЭЭГ к CLIP-эмбедингам изображений, затем используются предобученная генеративная модель для реконструкции [26, 40, 41]. В качестве кодировщиков применяют различные архитектуры: индивидуальные LSTM для каждого пациента [41], сверточные сети [40], а также гибридные архитектуры,

сочетающие свертки с механизмом внимания [26]. Представленные подходы легли в основу проектирования предлагаемого двухмодального энкодера.

1.4. Генеративные модели для реконструкции изображений

Современные генеративные модели изображений сыграли ключевую роль в продвижении задач визуального декодирования. Наиболее успешными оказались латентно-диффузионные архитектуры, которые работают в компактном скрытом пространстве и допускают гибкое обуславливание на внешние эмбединги [42, 43]. Отдельную линию исследований составляют модели, непосредственно обусловленные на CLIP-эмбединги изображений и/или текста, что позволяет использовать общее семантическое пространство для управления генерацией [22, 44]. В таких подходах CLIP-пространство выступает универсальным интерфейсом между модулями, кодирующими различные модальности, и генератором. В настоящей работе следует этой парадигме: для реконструкции изображений используется предобученная латентно-диффузионная модель SDXL (англ. Stable Diffusion XL) [45], обусловленная на CLIP-эмбединги через адаптер IP-Adapter (англ. Image Prompt Adapter) [45, 46], что позволяет напрямую переносить информацию из комбинированных эмбедингов фМРТ–ЭЭГ в пространство генерации.

2. Постановка задачи

2.1. Общая постановка мультимодального декодирования

Пусть $\mathcal{X}_{(m)}$ — пространство наблюдений модальности m , где $m = 1, \dots, M$. Совместное пространство нейробиологических данных определяется как декартово произведение:

$$\mathcal{X} = \mathcal{X}_{(1)} \times \dots \times \mathcal{X}_{(M)}. \quad (1)$$

Пусть $\mathcal{Y}$ — пространство визуальных стимулов. Задача мультимодального декодирования состоит в построении отображения

$$\mathbf{g} : \mathcal{X} \rightarrow \mathcal{Y}, \quad (2)$$

которое восстанавливает стимул $\mathbf{y} \in \mathcal{Y}$ по совместному наблюдению $\mathbf{x} \in \mathcal{X}$. Настоящая работа рассматривает частный случай $M = 2$, в котором модальностями являются одновременные записи фМРТ и ЭЭГ.

2.2. Двумодальное декодирование фМРТ–ЭЭГ

Задан датасет триплетов (фМРТ, ЭЭГ, изображение):

$$\mathfrak{D} = \{(\mathbf{F}_i, \mathbf{E}_i, \mathbf{I}_i) \mid i = 1, \dots, N\}, \quad (\mathbf{F}_i, \mathbf{E}_i) \in \mathcal{X}_f \times \mathcal{X}_e, \quad \mathbf{I}_i \in \mathcal{Y}, \quad (3)$$

где $\mathbf{F}_i \in \mathbb{R}^{X \times Y \times Z}$ — данные фМРТ с пространственными размерностями X , Y и Z ; $\mathbf{E}_i \in \mathbb{R}^{K \times T}$ — данные ЭЭГ, где K — число каналов, T — длина временного окна; $\mathbf{I}_i \in \mathbb{R}^{H \times W \times C}$ — изображение с высотой H , шириной W и количеством каналов C . Требуется построить отображение $\mathbf{f}$ из совместного пространства данных фМРТ–ЭЭГ в пространство изображений:

$$\mathbf{f} : \mathcal{X}_f \times \mathcal{X}_e \rightarrow \mathcal{Y}. \quad (4)$$

2.3. Гипотеза о гемодинамической задержке

BOLD-сигнал фМРТ возникает с гемодинамической задержкой Δt относительно момента предъявления визуального стимула [9, 11]; ЭЭГ-сигнал, напротив, отражает нейронный отклик практически без задержки. При формировании триплета $(\mathbf{F}_i, \mathbf{E}_i, \mathbf{I}_i)$ временной сдвиг затрагивает только фМРТ-составляющую:

изображение $\mathbf{I}_i$ должно соответствовать моменту времени, предшествующему моменту регистрации фМРТ-скана $\mathbf{F}_i$ на величину Δt . Формально пусть $\mathbf{F}(t)$ — фМРТ-скан в момент t , $\mathbf{E}(t)$ — ЭЭГ-окно вокруг момента t , а $\mathbf{I}(t)$ — изображение, предъявленное в момент t . Тогда триплеты выборки (3) формируются по правилу

$$\mathbf{F}_i = \mathbf{F}(t_i), \quad \mathbf{E}_i = \mathbf{E}(t_i - \Delta t), \quad \mathbf{I}_i = \mathbf{I}(t_i - \Delta t). \quad (5)$$

В качестве значения Δt принимается оценка 4–6 с, согласующаяся с известным медицинским диапазоном гемодинамической задержки [9] и эмпирически подтвержденная в нашей предыдущей работе [8].

3. Метод

На рис. 2 представлена схема декодирования изображений. Процесс строится из двух основных этапов: контрастивное обучение комбинированных представлений фМРТ–ЭЭГ сигналов и реконструкция стимулов.




Рис. 2: Схема декодирования изображений на основе сигналов фМРТ–ЭЭГ. Процесс декодирования реализуется в два этапа. На первом этапе проводится контрастное обучение энкодера сигналов фМРТ–ЭЭГ, в ходе которого представления мозговых сигналов выравниваются с замороженными эмбедингами изображений, полученными с помощью модели CLIP. На втором этапе осуществляется двухстадийная генерация реконструкций: сначала обучается диффузионная априорная модель для уточнения эмбедингов сигналов мозга, а затем предобученная диффузионная модель, обусловленная на CLIP-эмбединги, генерирует реконструкции изображений

3.1. Контрастивное обучение комбинированных представлений фМРТ–ЭЭГ сигналов

Энкодер сигналов фМРТ–ЭЭГ. Архитектура энкодера состоит из трех модулей: энкодера фМРТ, энкодера ЭЭГ и модуля объединения. Для обеспечения персонализированного представления мозговой активности каждый модуль включает индивидуализирующие компоненты, позволяющие явно моделировать

межсубъектные различия — критически важный аспект при работе с нейросигналами. Архитектуры энкодеров фМРТ и ЭЭГ изображены на рис. 3.

Предобработка ЭЭГ. На этапе предобработки решается задача восстановления пропусков в записях ЭЭГ: сигналы незарегистрированных электродов восстанавливаются методами пространственной интерполяции на основе данных ближайших доступных каналов и известной геометрии расположения датчиков.

Полный набор электродов системы регистрации включает K каналов. Каждому каналу $\{c_k\}_{k=1}^K$ соответствуют фиксированные пространственные координаты $\mathbf{p}_k \in \mathbb{R}^3$ на поверхности скальпа. Множество фактически зарегистрированных каналов для i -й записи обозначается как $\mathcal{C}_i \subseteq \{c_1, \dots, c_K\}$, $i = 1, \dots, N$. Состав отсутствующих каналов варьируется между записями, вследствие чего использование исключительно перекрывающегося подмножества каналов приводит к существенной потере информации. Архитектура энкодера ЭЭГ $\mathcal{E}_e$ предполагает фиксированную размерность входного тензора, что необходимо для обработки элементов обучающей выборки батчами. Данное требование обуславливает необходимость восстановления сигналов отсутствующих каналов до полного набора.

Для упрощения нотации далее рассматривается единичная запись ЭЭГ $\mathbf{E}$, при этом индекс i объекта выборки опускается. Обозначим через $\mathcal{C} \subset \{c_1, \dots, c_K\}$ — подмножество каналов, для которых доступны временные ряды $\mathbf{e}_k \in \mathbb{R}^T$. Таким образом, наблюдаемая часть записи задается как $\mathbf{E} = \{\mathbf{e}_k\}_{k \in \mathcal{C}}$. Для унификации формата данных каждому отсутствующему каналу $c_k \notin \mathcal{C}$ назначается восстановленный сигнал $\hat{\mathbf{e}}_k \in \mathbb{R}^T$, рассчитываемый как взвешенное среднее значений сигналов n пространственно ближайших зарегистрированных электродов:

$$\hat{\mathbf{e}}_k = \sum_{j \in \mathcal{S}_k} w_{kj} \mathbf{e}_j, \quad \sum_{j \in \mathcal{S}_k} w_{kj} = 1, \quad (6)$$

где $\mathbf{e}_j \in \mathbb{R}^T$ — временной ряд канала c_j ; $\mathcal{S}_k$ — множество индексов n ближайших к c_k доступных электродов, определяемое в соответствии с выбранной пространственной метрикой; $w_{kj} \geq 0$ — неотрицательные нормированные веса. В исследовании рассматриваются четыре стратегии определения весов $\{w_{kj}\}$ и формирования множества соседей $\mathcal{S}_k$:

- **Zero** (нулевое заполнение): базовый метод, при котором отсутствующий

сигнал заменяется нулевым вектором:

$$\hat{\mathbf{e}}_k = \mathbf{0} \in \mathbb{R}^T.$$

- **NN** (метод одного ближайшего соседа): сигнал отсутствующего канала заменяется сигналом ближайшего зарегистрированного электрода:

$$\hat{\mathbf{e}}_k = \mathbf{e}_{j^*}, \quad j^* = \arg \min_{j: c_j \in \mathcal{C}} \rho_{\text{eucl}}(c_k, c_j), \quad \rho_{\text{eucl}}(c_k, c_j) = \|\mathbf{p}_k - \mathbf{p}_j\|_2.$$

что соответствует $n = 1$ и $w_{kj^*} = 1$ в (6).

- **KNN-Euclidean**: взвешенное усреднение по n ближайшим соседям в евклидовой метрике; веса определяются как величины, обратно пропорциональные расстоянию между электродами:

$$w_{kj} = \frac{1/\rho_{\text{eucl}}(c_k, c_j)}{\sum_{l \in \mathcal{S}_k} 1/\rho_{\text{eucl}}(c_k, c_l)}, \quad \rho_{\text{eucl}}(c_k, c_j) = \|\mathbf{p}_k - \mathbf{p}_j\|_2.$$

- **KNN-Spherical**: взвешенное усреднение по n ближайшим соседям в сферической метрике; процедура аналогична предыдущей, однако евклидово расстояние заменяется геодезическим расстоянием на поверхности скальпа, аппроксимируемой сферой радиуса R :

$$\rho_{\text{sph}}(c_k, c_j) = R \cdot \arccos\left(\frac{\langle \mathbf{p}_k, \mathbf{p}_j \rangle}{\|\mathbf{p}_k\|_2 \|\mathbf{p}_j\|_2}\right),$$

при этом веса задаются как $w_{kj} \propto 1/\rho_{\text{sph}}(c_k, c_j)$ с последующей нормировкой $\sum_{j \in \mathcal{S}_k} w_{kj} = 1$.

Применение процедуры (6) ко всем отсутствующим каналам приводит исходные данные ЭЭГ к единому матричному представлению $\mathbf{E} \in \mathbb{R}^{K \times T}$ с фиксированным числом каналов K . Данный шаг обеспечивает совместимость размерности входного тензора с архитектурой энкодера $\mathcal{E}_e$ для последующей обработки батчами.

Энкодер ЭЭГ. Энкодер ЭЭГ интегрирует индивидуальные обучаемые эмбеддинги пациентов с исходными многоканальными данными посредством кон-

катенации, формируя единое векторное представление. Архитектура энкодера включает последовательность трех сверточных слоев: одномерную свертку по временному измерению, одномерную свертку по каналам (пространству) и свертку для сжатия в вектор. Полученный эмбединг пропускается через MLP-голову, формируя итоговое представление. Формально, для батча данных ЭЭГ $\mathbf{E} \in \mathbb{R}^{B \times K \times T}$ энкодер $\mathcal{E}_e$ генерирует эмбединги:

$$\mathbf{Z}_e = \mathcal{E}_e(\mathbf{E}) \in \mathbb{R}^{B \times d_e},$$

где d_e — размерность латентного пространства ЭЭГ.

Предобработка фМРТ. Из всего объема $X \times Y \times Z$ вокселей лишь относительно небольшая часть несет информацию о реакции мозга на визуальный стимул: значительную долю занимают фоновые воксели, значения которых либо близки к нулю, либо стабильны во времени и не зависят от стимула. Прямая подача всего тензора в обучаемую модель приводит к расточительной параметризации и снижает отношение сигнал/шум. Поэтому на этапе предобработки строится индивидуальная для каждого испытуемого бинарная маска, выделяющая только информативные воксели.

Пусть $\mathbf{F}(t, i, j, k)$ — значение вокселя с координатами (i, j, k) в момент t временного ряда фМРТ длиной T_f . Для каждого вокселя вычисляется суммарная абсолютная разность значений между соседними кадрами:

$$m_{ijk} = \sum_{t=2}^{T_f} |\mathbf{F}(t, i, j, k) - \mathbf{F}(t-1, i, j, k)|.$$

Величина m_{ijk} интерпретируется как накопленная во времени вариация сигнала в данном вокселе: для фоновых вокселей m_{ijk} близка к нулю, для активно реагирующих на стимул — существенно положительна. К одномерному распределению значений $\{m_{ijk}\}$ применяется метод Оцу [47] для автоматического выбора порога, разделяющего фоновые и информативные воксели. Метод перебирает все возможные значения порога θ ; при каждом θ воксели делятся на два класса $C_0(\theta) = \{(i, j, k) : m_{ijk} \leq \theta\}$ и $C_1(\theta) = \{(i, j, k) : m_{ijk} > \theta\}$ с долями $\omega_0(\theta), \omega_1(\theta) = 1 - \omega_0(\theta)$ и средними $\mu_0(\theta), \mu_1(\theta)$. Межклассовая дисперсия имеет

вид

$$\sigma^2(\theta) = \omega_0(\theta) \omega_1(\theta) [\mu_0(\theta) - \mu_1(\theta)]^2,$$

а оптимальный порог определяется как точка ее максимума:

$$\theta^* = \arg \max_{\theta} \sigma^2(\theta).$$

По найденному порогу строится бинарная маска

$$M_{ijk} = \mathbb{1}\{m_{ijk} > \theta^*\}, \quad M \in \{0, 1\}^{X \times Y \times Z}, \quad (7)$$

персональная для каждого испытуемого; число информативных вокселей $d_{\text{mask}} = \sum_{ijk} M_{ijk}$ зависит от анатомии и индивидуальной динамики BOLD-сигнала. Для каждого фМРТ-скана $\mathbf{F}$ значения вокселей, для которых $M_{ijk} = 1$, собираются в плотный вектор размерности d_{mask} .

Энкодер фМРТ. Энкодер фМРТ учитывает индивидуальные особенности пациентов за счет персонализированной линейной проекции. Вектор информативных вокселей, отобранных по бинарной маске M , пропускается через индивидуальный для каждого испытуемого линейный слой, проецирующий признаки в общее латентное пространство размерности 4096. Завершающим этапом является обработка эмбедингов через MLP с остаточными соединениями. Формально, для батча данных фМРТ $\mathbf{F} \in \mathbb{R}^{B \times X \times Y \times Z}$ энкодер $\mathcal{E}_f$ преобразует исходный тензор в латентное представление:

$$\mathbf{Z}_f = \mathcal{E}_f(\mathbf{F}) \in \mathbb{R}^{B \times d_f},$$

где d_f — размерность латентного пространства фМРТ.

Модуль объединения. Полученные эмбединги $\mathbf{Z}_e$ и $\mathbf{Z}_f$ подаются на вход обучаемого модуля объединения $\mathcal{F}$, который интегрирует высокочастотную информацию из ЭЭГ и пространственно детализированные данные фМРТ, формируя совместные эмбединги:

$$\mathbf{Z}_c = \mathcal{F}(\mathbf{Z}_f, \mathbf{Z}_e) \in \mathbb{R}^{B \times d}.$$

В данной работе модуль объединения реализован как конкатенация эмбеддингов с последующей обработкой через MLP для извлечения совместных представлений. В качестве альтернативной реализации $\mathcal{F}$ также рассматривалось скользящее усреднение эмбеддингов модальностей вида

$$\mathbf{Z}_c = \alpha \mathbf{Z}_f + (1 - \alpha) \mathbf{Z}_e, \quad \alpha \in [0, 1],$$

где α — обучаемый скалярный параметр, балансирующий вклад фМРТ- и ЭЭГ-модальностей. Сравнительный анализ показал, что MLP более эффективно выделяет совместные признаки из пространств фМРТ–ЭЭГ, поэтому именно эта конфигурация принята в качестве основной.




Рис. 3: Архитектуры кодировщиков фМРТ и ЭЭГ. *Слева:* энкодер ЭЭГ интегрирует индивидуальные обучаемые эмбеддинги пациентов с исходными многоканальными данными посредством конкатенации, формируя единое векторное представление; далее применяются одномерные свертки по временному и каналному измерениям, а также MLP-голова для генерации итоговых эмбеддингов. *Справа:* энкодер фМРТ включает персонализированное маскирование мозга, векторизацию вокселей и проекцию в латентное пространство через индивидуальный линейный слой; завершающая обработка осуществляется с использованием MLP с остаточными соединениями

Эмбеддинги изображений. Для извлечения визуальных эмбеддингов используется предобученная модель CLIP ViT-H/14 [22], которая генерирует эмбеддинги изображений $\mathbf{Z}_I \in \mathbb{R}^{B \times d}$. Данная модель обеспечивает высококачественные, семантически насыщенные и хорошо обобщающиеся эмбеддинги, а также совместима с множеством генеративных моделей, предобученных на

CLIP-пространстве.

Контрастивное обучение энкодера сигналов мозга. Основной целью контрастивного обучения является сопоставление нейронных представлений фМРТ–ЭЭГ с визуальными эмбедингами, извлеченными с помощью замороженного энкодера CLIP, как показано на рис. 2. Обучение происходит на триплетах (фМРТ, ЭЭГ, изображение) и включает оптимизацию трех ключевых компонентов: энкодера фМРТ $\mathcal{E}_f$, энкодера ЭЭГ $\mathcal{E}_e$ и модуля объединения $\mathcal{F}$. Для вычисления логитов близости используется косинусное расстояние между нормированными эмбедингами:

$$\mathbf{z}_I^n = \frac{\mathbf{z}_I}{\|\mathbf{z}_I\|}, \quad \mathbf{z}_c^n = \frac{\mathbf{z}_c}{\|\mathbf{z}_c\|}, \quad (8)$$

где $\mathbf{z}_I$ — эмбединги изображений, полученные с помощью замороженного CLIP, а $\mathbf{z}_c$ — объединенные эмбединги фМРТ–ЭЭГ. Матрица логитов $\mathbf{L}$ вычисляется как

$$\mathbf{L} = \mathbf{Z}_I^n (\mathbf{Z}_c^n)^\top \cdot e^\tau, \quad (9)$$

где τ — обучаемый параметр температуры. В процессе контрастивного обучения рассматриваются все возможные пары «объединенный эмбединг мозга — эмбединг изображения» для максимизации эффективности обучения. Критическим аспектом данного подхода является наличие большого числа негативных примеров, что позволяет модели не только корректно сопоставлять положительные пары, но и четко различать негативные. Как показано на рис. 4, при размере батча B формируется матрица логитов размером $B \times B$, где лишь B пар, расположенных на главной диагонали, являются положительными соответствиями.

Функция потерь основывается на симметричной контрастивной оптимизации, аналогичной подходу CLIP [22], и представляет собой усредненную сумму двух кросс-энтропийных потерь:

$$\mathcal{L}_{\text{contr}} = -\frac{1}{2B} \sum_{b=0}^{B-1} \left[\log \left(\frac{\exp(\mathbf{L}_{bb})}{\sum_{j=0}^{B-1} \exp(\mathbf{L}_{bj})} \right) + \log \left(\frac{\exp(\mathbf{L}_{bb})}{\sum_{i=0}^{B-1} \exp(\mathbf{L}_{ib})} \right) \right], \quad (10)$$

где $\mathbf{L}_{ij}$ обозначает элемент матрицы логитов $\mathbf{L}$ на позиции (i, j) .

Контрастивное предварительное обучение




Рис. 4: Иллюстрация контрастивного обучения и формирования батчей. Отрицательные примеры формируются автоматически. Косинусные расстояния между эмбедами замороженного CLIP и нейронными эмбедами используются в качестве логитов

3.2. Процесс реконструкции стимулов

Вводится совместное распределение изображений $\mathbf{x}$ и их скрытых визуальных представлений $\mathbf{z}_I$ при условии комбинированных нейронных эмбедингов $\mathbf{z}_c$:

$$p(\mathbf{x}, \mathbf{z}_I \mid \mathbf{z}_c) = p(\mathbf{z}_I \mid \mathbf{z}_c) p(\mathbf{x} \mid \mathbf{z}_I).$$

Здесь $p(\mathbf{z}_I \mid \mathbf{z}_c)$ моделирует согласование комбинированного представления фМРТ–ЭЭГ с высокоуровневым визуальным пространством CLIP (стадия I), а $p(\mathbf{x} \mid \mathbf{z}_I)$ описывает генерацию изображения при условии уточненного визуального эмбединга (стадия II).

Стадия I: диффузионная модель в пространстве CLIP. В пространстве визуальных эмбедингов CLIP обучается легкая диффузионная модель вида

$$\epsilon_{\theta}(\mathbf{z}_I^{(t)}, t, \mathbf{z}_c),$$

где $\mathbf{z}_I^{(t)}$ — зашумленная версия истинного эмбединга $\mathbf{z}_I$ на шаге t прямого диффузионного процесса, а $\mathbf{z}_c$ — комбинированный эмбединг, полученный модулем слияния. Обучение осуществляется по методу DDPM (англ. Denoising Diffusion Probabilistic Models, вероятностные диффузионные модели расшумления) [48] с функцией потерь

$$\mathcal{L}_{\text{prior}}(\boldsymbol{\theta}) = \mathbb{E}_{\mathbf{z}_I, \mathbf{z}_c, t, \epsilon} \left\| \epsilon - \epsilon_{\boldsymbol{\theta}}(\mathbf{z}_I^{(t)}, t, \mathbf{z}_c) \right\|_2^2. \quad (11)$$

На инференсе априорная диффузионная модель генерирует оценку $\widehat{\mathbf{z}}_I \approx \mathbf{z}_I$ итеративной процедурой расшумления, согласующей $\mathbf{z}_c$ с визуальным пространством CLIP. Кодировщики $\mathcal{E}_f$, $\mathcal{E}_e$ и модуль слияния $\mathcal{F}$ остаются замороженными, что упрощает схему и стабилизирует обучение.

Стадия II: генерация изображения при условии $\widehat{\mathbf{z}}_I$. Для реконструкции изображения используется предобученная латентно-диффузионная модель SDXL [45]:

$$\epsilon_{\phi}(\mathbf{x}^{(t)}, t, h(\widehat{\mathbf{z}}_I)),$$

где $\mathbf{x}^{(t)}$ — зашумленный латент изображения, а $h(\cdot)$ — проекционный адаптер IP-Adapter [46], переводящий $\widehat{\mathbf{z}}_I$ в формат условия, совместимый с SDXL. Модель ϕ не дообучается.

Итоговый процесс реконструкции.

1. Контрастивное обучение выравнивает $\mathbf{z}_c$ с $\mathbf{z}_I$ (см. раздел 3.1).
2. Априорная диффузионная модель генерирует согласованное визуальное представление $\widehat{\mathbf{z}}_I$ по $\mathbf{z}_c$.
3. Предобученная SDXL, обусловленная через $h(\widehat{\mathbf{z}}_I)$, синтезирует изображение $\widehat{\mathbf{x}}$.

4. Вычислительный эксперимент

В данной главе проводится эмпирическая оценка метода, предложенного в главе 3. Раздел 4.1 описывает характеристики используемого датасета, параметры регистрации сигналов и процедуры предобработки, включая восстановление отсутствующих каналов ЭЭГ и построение индивидуальных масок мозга для фМРТ. В разделе 4.2 приведены архитектурные детали и гиперпараметры энкодеров для каждой модальности, а также модуля объединения эмбеддингов. Раздел 4.3 содержит результаты вычислительных экспериментов: качественный анализ реконструкций и количественную оценку через метрику CLIP-Score. Ограничения предложенного метода обсуждаются в разделе 4.4.

Программная реализация всех вычислительных экспериментов выполнена на фреймворке PyTorch. Исходный код, конфигурации обучения и скрипты для воспроизведения результатов находятся в открытом доступе:

https://github.com/intsystems/CreationOfIntelligentSystems_Simultaneous_fMRI-EEG.

4.1. Данные

В работе используется открытый датасет с одновременной регистрацией фМРТ и ЭЭГ при предъявлении визуальных стимулов [27]. Данные собраны у 22 здоровых участников в возрасте 23–51 года в ходе двух сканирований. Эксперимент включает записи в состоянии покоя, при просмотре мерцающего шахматного поля, абстрактной анимации **Inscapes** — компьютерно сгенерированной последовательности трехмерных фигур с плавными переходами — а также коротких видеороликов, представляющих натуралистические стимулы: фрагменты мультфильмов **The Present** и **Despicable Me**, а также фрагменты фильмов с обезьянами. Все визуальные стимулы демонстрируются в естественном, натуралистическом формате, что способствует высокой межсубъектной корреляции и устойчивости нейронных откликов. Синхронизация ЭЭГ и фМРТ достигается через запись триггеров сканера в ЭЭГ-поток. Предобработка ЭЭГ включает удаление градиентных и кардиобаллистических артефактов, полосовую фильтрацию и усредненное реферирование. Для фМРТ применяется стандартная коррекция движения, сглаживание и нормализация. Параметры регистрации приведены в табл. 1.

Исходные данные представляют собой три асинхронных потока: временные ряды фМРТ, временные ряды ЭЭГ и видеозапись стимулов. Несмотря на синхронную регистрацию, модальности различаются по частоте дискретизации: фМРТ обновляется с частотой 0,476 Гц, ЭЭГ записывается на частоте 5000 Гц, тогда как видеостимул представляет собой непрерывный поток кадров. Кроме того, каждый тип сигнала содержит специфичные артефакты (градиентные и кардиобаллистические — для ЭЭГ, движения — для фМРТ), а набор доступных электродов варьируется между участниками, что делает невозможным прямое использование сырых записей для обучения нейросетевой модели батчами. Первичный этап предобработки данных — разбиение записей на согласованные триплеты ($\mathbf{F}, \mathbf{E}, \mathbf{I}$). С учетом гемодинамической задержки $\Delta t = 5$ с согласно (5), каждому тензору фМРТ в момент времени t сопоставляется соответствующее окно ЭЭГ и кадр видеостимула, относящиеся к моменту $t - \Delta t$. Видеопоток предварительно разбивается на кадры с частотой 3 FPS, а ЭЭГ-сигнал сегментируется на матрицы размера (K, T) , где K — число каналов, а T — длина временного окна.

Параллельно с временной синхронизацией проводится пространственная предобработка, важная для снижения размерности и стандартизации входных тензоров. Чтобы снизить размерность фМРТ и убрать фоновые воксели, для каждого участника строится индивидуальная маска мозга (7): вычисляется суммарное абсолютное изменение сигнала во времени по каждому вокселю, и к полученному тензору применяется метод Оцу [47] для автоматического выбора порога. Результат — бинарная маска мозга, отделяющая воксели мозга от фона. Пример применения маски мозга на срезы снимка фМРТ показан на рис. 5. Важный этап подготовки данных — приведение записей ЭЭГ к фиксированному набору каналов. Монтаж набора данных [27] включает $K = 61$ кортикальный электрод. Расположение электродов на скальпе согласно системе 10–20 показано на рис. 6. Однако в ряде записей часть каналов отсутствует, в результате чего количество доступных каналов $|\mathcal{C}_i| \geq 50$ варьируется. Пересечение множеств доступных каналов для всей выборки оказывается пустым ($\bigcap_i \mathcal{C}_i = \emptyset$), поскольку не существует канала, присутствующего без исключений во всех элементах выборки. Следовательно, использование общего для всех записей подмножества каналов невозможно, что обуславливает необходимость восстановления отсутствующих сигналов до полного набора из $K = 61$ канала согласно методу,

описанному в разделе 3.1, см. (6). Для выбора оптимальной стратегии восстановления проведено сравнение четырех методов: нулевого заполнения, интерполяции по ближайшему соседу и двух вариантов метода k -ближайших соседей с евклидовой и сферической метриками. Качество интерполяции оценивалось по среднеквадратичной ошибке (MSE) восстановления сигнала, рассчитанной независимо для каждого канала. Результаты представлены на рис. 7, где по оси абсцисс отложен индекс канала, а по оси ординат — значение ошибки.

Таблица 1: Описание оборудования и основные параметры нейросигналов

Модальность	Оборудование	Частота дискретизации	Каналы
ЭЭГ	Brain Products BrainCap MR	5000 Гц	61 кортикальный электрод
фМРТ	Siemens 3.0 T TIM Trio	0,476 Гц	12-канальная головная катушка




Рис. 5: Для снижения размерности данных фМРТ применяются маски головного мозга, исключающие фоновые воксели, не несущие информации о визуальном стимуле. Маски формируются на основе анализа наиболее изменчивых вокселей в ответ на стимуляцию. Воксели, включенные в маску, выделены красным цветом

4.2. Параметры энкодеров

В экспериментах использовались две специализированные архитектуры, адаптированные под особенности каждой модальности. Энкодер фМРТ начинается с персонализированной линейной проекции: для каждого участника воксели, отобранные с помощью индивидуальной бинарной маски, проецируются в пространство размерности 4096 обучаемым линейным слоем. За этим следует остаточный многослойный перцептрон, состоящий из трех полносвязных преобразований: первый расширяет представление до 2048, второй сохраняет




Рис. 6: Конфигурация монтажа из $K = 61$ кортикального электрода, используемая в датасете [27]. Датчики расположены согласно системе 10–20. Данная схема используется для восстановления отсутствующих каналов методом k -ближайших соседей, описанным в разделе 3.1.

эту размерность, а третий сжимает до 1024. Между слоями применяются нелинейность GELU и нормализация по слою; к выходу каждого блока добавляется остаточное соединение от входа. Dropout во всех слоях установлен в 0,1.

Для обработки ЭЭГ-сигналов применялся компактный энкодер. Входные данные имеют размер 61×525 , где 60 каналов соответствуют кортикальным электродам, а один дополнительный канал — обучаемому эмбедингу участника. Архитектура включает три последовательные свертки: временная свертка с ядром (1, 32) и 256 фильтрами, пространственная свертка с ядром (61, 1) и 512 фильтрами, а также глобальная свертка с ядром (1, 525) и 1024 фильтрами. После сверток следует MLP-проектор, реализующий преобразование $1024 \rightarrow 2048 \rightarrow 1024$ с нелинейностью GELU и LayerNorm. Dropout во всех сверточных




Рис. 7: Сравнение стратегий восстановления отсутствующих каналов ЭЭГ. По оси абсцисс отложен индекс канала, по оси ординат — среднеквадратичная ошибка (MSE). Метод нулевого заполнения характеризуется максимальной ошибкой, тогда как алгоритмы на основе k -ближайших соседей обеспечивают минимальные значения MSE для большинства каналов.

и проекционных слоях равен 0,1. Выходной эмбединг имеет размерность 1024, что обеспечивает совместимость с модулем слияния и CLIP-пространством.

Модуль объединения эмбедингов фМРТ и ЭЭГ реализован как двух-слойный MLP: первый слой расширяет конкатенированное представление (размерность 2048) до 4096, второй сжимает его обратно до целевой размерности 1024. Активация — GELU, dropout — 0,1. Выходной эмбединг совместим с CLIP-пространством и используется как условие при генерации изображений.

4.3. Результаты экспериментов

Для проведения вычислительных экспериментов из полного набора стимулов датасета [27] было отобрано подмножество видеозаписей, характеризующееся приемлемым балансом между объемом данных и семантическим разнообразием визуальных стимулов. Полный датасет включает пять типов видеостимулов: абстрактную анимацию *Inscapes*, мультфильмы *The Present* и *Despicable Me*, а также натуралистические видеоролики с обезьянами: *monkey1*, *monkey2*, *monkey5*. Однако стимулы из категорий *Inscapes* и *Despicable Me* демонстрируют выраженный доменный сдвиг относительно реалистичных сцен. *Inscapes* представляет собой компьютерно сгенерированную последовательность абстрактных трехмерных фигур без семантически интерпретируемых объектов, тогда

как **The Present** и **Despicable Me** относится к жанру анимации с сильно стилизованной визуальной подачей. Обучение на гетерогенной смеси столь различных доменов без явной доменной адаптации приводит к конфликту градиентных сигналов и ухудшению обобщающей способности модели. В связи с этим для основного эксперимента были выбраны три видеостимула из категории **monkey**, которые обеспечивают достаточное разнообразие сцен: различные ракурсы, освещение, действия персонажей, при сохранении единого визуального домена — натуралистической видеосъемки. Объемы данных по каждому датасету приведены в табл. 2.

Таблица 2: Объемы данных по видеостимулам датасета **monkey***, использованным в основном эксперименте. Данные разделены в пропорции 80% к 20% для обучения и тестирования соответственно, с равномерным распределением записей испытуемых между выборками

Видеостимул	Общий объем	Обучающая выборка	Тестовая выборка
monkey1	5 941	4 753	1 188
monkey2	4 477	3 582	895
monkey5	4 579	3 664	915

Для верификации эффективности предложенного подхода проведены два эксперимента: визуальный анализ изображений-реконструкций и количественная оценка через CLIP-Score.

В первом эксперименте выполнено сравнение реконструкций, полученных с диффузионной априорной моделью и без нее на тестовых объектах из датасета **monkey***. Примеры приведены на рис. 8. Для проверки гипотезы о чувствительности модели к распределению визуальных стимулов был проведен дополнительный эксперимент по кросс-доменной реконструкции. Модель, обученная исключительно на датасете **monkey***, применялась для декодирования сигналов фМРТ–ЭЭГ, зарегистрированных при просмотре абстрактной анимации **Inscapes**. Поскольку визуальные характеристики стимулов **Inscapes** принципиально отличаются от реалистичных сцен, на которых проводилось обучение, энкодер фМРТ–ЭЭГ не получает на вход паттерны нейронной активности, соответствующие выученному распределению. В результате комбинированный эмбединг $\mathbf{z}_c$ формируется в области латентного пространства, удаленной от кластеров, ассоциированных с обучающими стимулами, что приводит к генерации семантически несогласованных изображений, см. рис. 9. Без явной доменной

адаптации или аугментации тренировочных данных обобщение на распределения с сильным визуальным сдвигом не гарантируется. Для оценки устойчивости моделей необходим датасет с выраженной доменной разнородностью, однако, как показано в разделе 1.2, открытые мультимодальные наборы данных, обладающие подобным разнообразием визуальных стимулов, на текущий момент отсутствуют.



Рис. 8: Примеры реконструкции изображений по сигналам фМРТ-ЭЭГ. Строки соответствуют различным режимам: (1) оригинальное изображение; (2) реконструкция из CLIP-эмбединга оригинального изображения с помощью предобученной SDXL (предельное качество реконструкции); (3) реконструкция предложенным методом без диффузионной априорной модели; (4) реконструкция предложенным методом с диффузионной априорной моделью. Применение априорной модели повышает семантическую согласованность реконструированных изображений с исходными стимулами

Во втором эксперименте проводится количественная оценка с использованием метрики CLIP-Score — косинусной близости между CLIP-эмбедингом реконструированного изображения $\mathbf{z}_I$ и комбинированным представлением мозговой активности $\mathbf{z}_c$:

$$\text{CLIP-Score}(\mathbf{z}_c, \mathbf{z}_I) = \frac{\langle \mathbf{z}_c, \mathbf{z}_I \rangle}{\|\mathbf{z}_c\| \cdot \|\mathbf{z}_I\|}. \quad (12)$$

Метрики вычислялись на тестовой выборке датасета [27], использовались данные из видеостимулов `monkey1`, `monkey2`, `monkey5`. Усреднение проводилось по участникам и объектам. Для получения результатов в табл. 3 были использованы следующие конфигурации моделей:

1. Оригинальное
изображение

2. Оригинальная
реконструкция

3. Предлагаемым
методом

4. Предлагаемым
методом с
Diffusion Prior




Рис. 9: Пример реконструкции стимула из домена **Inscapes** моделью, обученной на датасете **monkey***. Строки соответствуют различным режимам: (1) оригинальное изображение; (2) реконструкция из CLIP-эмбединга оригинального изображения с помощью предобученной SDXL (предельное качество реконструкции); (3) реконструкция предложенным методом без диффузионной априорной модели; (4) реконструкция предложенным методом с диффузионной априорной моделью. Отсутствие семантической согласованности обусловлено доменным сдвигом между обучающими и тестируемыми стимулами

1. **ЭЭГ**: используется только энкодер ЭЭГ $\mathcal{E}_e$, модуль объединения отключен, эмбединг $\mathbf{Z}_e$ напрямую используется для реконструкции без априорной модели.
2. **фМРТ**: используется только энкодер фМРТ $\mathcal{E}_f$, модуль объединения отключен, эмбединг $\mathbf{Z}_f$ напрямую используется для реконструкции без априорной модели.
3. **фМРТ–ЭЭГ**: используются оба энкодера $\mathcal{E}_e$ и $\mathcal{E}_f$ с модулем объединения $\mathcal{F}$, формирующим комбинированный эмбединг $\mathbf{Z}_c$ без априорной модели.
4. **ЭЭГ & Diffusion Prior**: используется энкодер ЭЭГ с последующей априорной диффузионной моделью для уточнения эмбединга перед генерацией.
5. **фМРТ & Diffusion Prior**: используется энкодер фМРТ с последующей априорной диффузионной моделью для уточнения эмбединга перед генерацией.
6. **фМРТ–ЭЭГ & Diffusion Prior**: используется полная архитектура с

обоими энкодерами, модулем объединения и априорной диффузионной моделью.

Полученные результаты демонстрируют, что использование одной модальности дает худшие показатели по сравнению с комбинированной моделью на основе фМРТ и ЭЭГ. Более того, интеграция диффузионной априорной модели существенно повышает CLIP-Score для всех конфигураций, а наилучшее качество достигается при совместном использовании фМРТ, ЭЭГ и диффузионной априорной модели. Это подтверждает, что мультимодальность компенсирует фундаментальные ограничения отдельных методов регистрации, а двухстадийная генерация критически важна для семантической точности реконструкции.

Таблица 3: Сравнение CLIP-Score для различных конфигураций модели на трех видеостимулах из набора данных. Произведено усреднение по всем 22 испытуемым, нижним регистром указаны среднеквадратичные отклонения. Наилучшие результаты выделены жирным шрифтом

Модель	Название видеостимула		
	monkey1	monkey2	monkey5
ЭЭГ	0,231 $\pm$ 0,004	0,262 $\pm$ 0,004	0,224 $\pm$ 0,005
фМРТ	0,254 $\pm$ 0,004	0,270 $\pm$ 0,003	0,242 $\pm$ 0,003
фМРТ–ЭЭГ	0,310 $\pm$ 0,003	0,312 $\pm$ 0,004	0,284 $\pm$ 0,003
ЭЭГ & Diffusion Prior	0,542 $\pm$ 0,005	0,557 $\pm$ 0,003	0,538 $\pm$ 0,003
фМРТ & Diffusion Prior	0,564 $\pm$ 0,005	0,571 $\pm$ 0,004	0,551 $\pm$ 0,005
фМРТ–ЭЭГ & Diffusion Prior	0,668 $\pm$ 0,003	0,647 $\pm$ 0,005	0,644 $\pm$ 0,003

4.4. Ограничения метода

Важно отметить ограничения, связанные с использованием CLIP-пространства в качестве промежуточного представления. Поскольку CLIP обучался на сопоставлении изображений и текстовых описаний, его эмбединги кодируют преимущественно семантическую информацию высокого уровня — объекты, их взаимосвязи, общий контекст сцены — но не сохраняют детальную информацию о низкоуровневых визуальных характеристиках, таких как точные текстуры, локальные паттерны или пиксельные детали. Следовательно, предложенный метод реконструкции ориентирован на семантическую согласованность реконструированных изображений с исходными стимулами, а не на точное пиксельное восста-

новление низкоуровневых визуальных деталей. Это ограничение является фундаментальным следствием выбора CLIP в качестве промежуточного представления и разделяется всеми подходами, основанными на CLIP-эмбедингах [25, 26, 39].

Экспериментальная проверка метода выполнена на одном публичном датасете [27], и оценка качества реконструкции основана преимущественно на метрике CLIP-Score. Проведенные кросс-доменные эксперименты подтвердили, что обобщающая способность модели ограничена: при применении к стимулам из домена, отсутствующего в обучающей выборке, например, абстрактная анимация **Inscapes**, качество реконструкции существенно снижается. Это обусловлено тем, что энкодеры формируют представления, оптимизированные под конкретное распределение визуальных признаков тренировочного домена, и не обладают встроенной инвариантностью к резким семантическим сдвигам. В связи с этим переносимость метода на другие типы стимулов: статичные изображения, абстрактные паттерны, текстовые сцены или иные условия регистрации требует дополнительной валидации и, вероятно, явной доменной адаптации. Кроме того, эффективность метода может варьироваться в зависимости от индивидуальных особенностей нейронной активности участников. Расширение экспериментальной базы за счет гетерогенных датасетов или альтернативных метрик укрепило бы выводы, хотя текущие результаты полностью достаточны для подтверждения работоспособности подхода в рамках заявленного домена.

Заключение

В работе предложена мультимодальная архитектура реконструкции визуальных стимулов по одновременным сигналам фМРТ и ЭЭГ, основанная на контрастном выравнивании комбинированных эмбедингов мозговой активности с CLIP-пространством и двухстадийной генерации через априорную диффузионную модель и предобученную SDXL. Важным методологическим вкладом является разработка конвейера предобработки записей, обеспечивающего временное согласование модальностей, снижение размерности фМРТ и приведение ЭЭГ-сигналов к унифицированному набору каналов. Экспериментальная верификация подтвердила, что совместное использование модальностей превосходит одномодальные аналоги, что демонстрирует комплементарность пространственно-временных характеристик данных фМРТ и ЭЭГ. Интеграция диффузионной априорной модели дополнительно повышает семантическую согласованность реконструкций.

Проведенный кросс-доменный эксперимент выявил ожидаемое снижение качества при применении модели к стимулам, отсутствующим в обучающей выборке, что обусловлено оптимизацией энкодеров под конкретное распределение признаков и отсутствием встроенной доменной инвариантности. Данный результат очерчивает границы применимости метода и указывает на необходимость доменной адаптации в будущих исследованиях. Предложенный подход создает устойчивую методологическую основу для дальнейших исследований в области мультимодального нейродекодирования и потенциально применим в задачах интерфейсов мозг–компьютер.

Список литературы

1. Brain-computer interface technology: a review of the first international meeting / Jonathan R Wolpaw, Niels Birbaumer, William J Heetderks et al. // *IEEE transactions on rehabilitation engineering*. — 2000. — Vol. 8, no. 2. — Pp. 164–173. — URL: <https://doi.org/10.1109/TRE.2000.847807>.
2. Mining event-related brain dynamics / Scott Makeig, Stefan Debener, Julie Onton, Arnaud Delorme // *Trends in cognitive sciences*. — 2004. — Vol. 8, no. 5. — Pp. 204–210. — URL: <https://doi.org/10.1016/j.tics.2004.03.008>.
3. McFarland Dennis J. Brain-computer interfaces for communication and control // *Clin. Neurophysiol.* — 2002. — Vol. 113. — Pp. 767–791. — URL: [https://doi.org/10.1016/S1388-2457\(02\)00057-3](https://doi.org/10.1016/S1388-2457(02)00057-3).
4. Assistive Mobile Robot with Shared Control of Brain-Machine Interface and Computer Vision / Yonghao Song, Weifeng Wu, Chengqi Lin et al. // 2020 IEEE 4th Information Technology, Networking, Electronic and Automation Control Conference (ITNEC) / IEEE. — Vol. 1. — 2020. — Pp. 405–409. — URL: <https://doi.org/10.1109/ITNEC48623.2020.9085096>.
5. A self-paced BCI with a collaborative controller for highly reliable wheelchair driving: Experimental tests with physically disabled individuals / Aniana Cruz, Gabriel Pires, Ana Lopes et al. // *IEEE Transactions on Human-Machine Systems*. — 2021. — Vol. 51, no. 2. — Pp. 109–119. — URL: <https://doi.org/10.1109/THMS.2020.3047597>.
6. Dorin Daniil Dmitrievich, Grabovoy Andrey Valerievich, Strijov Vadim. Enhancing fMRI data decoding with spatiotemporal characteristics in limited dataset // *Doklady Rossijskoj Akademii Nauk. Matematika, Informatika, Processy Upravleniya*. — 2025. — Vol. 527. — Pp. 11–30.
7. Decoding hand movements from human EEG to control a robotic arm in a simulation environment / Andreas Schwarz, Maria Katharina Höller, Joana Pereira et al. // *Journal of neural engineering*. — 2020. — Vol. 17, no. 3. — P. 036010. — URL: <https://doi.org/10.1088/1741-2552/ab882e>.

8. Forecasting fMRI images from video sequences: linear model analysis / Daniil Dorin, Nikita Kiselev, Andrey Grabovoy, Vadim Strijov // *Health Information Science and Systems*. — 2024. — Vol. 12, no. 1. — P. 55. — URL: <https://doi.org/10.1007/s13755-024-00315-5>.
9. Time course EPI of human brain function during task activation / Peter A. Bandettini, Eric C. Wong, R. Scott Hinks et al. // *Magnetic Resonance in Medicine*. — 1992. — июнь. — Vol. 25, no. 2. — Pp. 390–397. — URL: <http://dx.doi.org/10.1002/mrm.1910250220>.
10. Brain magnetic resonance imaging with contrast dependent on blood oxygenation. / S Ogawa, T M Lee, A R Kay, D W Tank // *Proceedings of the National Academy of Sciences*. — 1990. — декабрь. — Vol. 87, no. 24. — Pp. 9868–9872. — URL: <http://dx.doi.org/10.1073/pnas.87.24.9868>.
11. Logothetis Nikos K. The Underpinnings of the BOLD Functional Magnetic Resonance Imaging Signal // *The Journal of Neuroscience*. — 2003. — май. — Vol. 23, no. 10. — Pp. 3963–3971. — URL: <https://doi.org/10.1523/jneurosci.23-10-03963.2003>.
12. Glover Gary H. Overview of Functional Magnetic Resonance Imaging // *Neurosurgery Clinics of North America*. — 2011. — апрель. — Vol. 22, no. 2. — Pp. 133–139. — URL: <https://doi.org/10.1016/j.nec.2010.11.001>.
13. Menon Ravi S, Kim Seong-Gi. Spatial and temporal limits in cognitive neuroimaging with fMRI // *Trends in cognitive sciences*. — 1999. — Vol. 3, no. 6. — Pp. 207–216. — URL: [https://doi.org/10.1016/s1364-6613\(99\)01329-7](https://doi.org/10.1016/s1364-6613(99)01329-7).
14. Logothetis Nikos K. What we can do and what we cannot do with fMRI // *Nature*. — 2008. — Vol. 453, no. 7197. — Pp. 869–878. — URL: <https://doi.org/10.1038/nature06976>.
15. Srinivasan Ramesh. Methods to improve the spatial resolution of EEG.
16. Schlögl Alois, Slater Mel, Pfurtscheller Gert. Presence research and EEG. — 2002. — 01.

17. Learning a common dictionary for subject-transfer decoding with resting calibration / Hiroshi Morioka, Atsunori Kanemura, Jun-ichiro Hirayama et al. // *NeuroImage*. — 2015. — Vol. 111. — Pp. 167–178.
18. Transfer learning in brain-computer interfaces / Vinay Jayaram, Morteza Alamgir, Yasemin Altun et al. // *IEEE Computational Intelligence Magazine*. — 2016. — Vol. 11, no. 1. — Pp. 20–31.
19. Ritter Petra, Villringer Arno. simultaneous EEG–fMRI // *Neuroscience & Biobehavioral Reviews*. — 2006. — Vol. 30, no. 6. — Pp. 823–838.
20. Removal of fMRI environment artifacts from EEG data using optimal basis sets / Rami K Niazy, Christian F Beckmann, Gian Domenico Iannetti et al. // *Neuroimage*. — 2005. — Vol. 28, no. 3. — Pp. 720–737.
21. Methods for simultaneous EEG–fMRI: an introductory review / René J Huster, Stefan Debener, Tom Eichele, Christoph S Herrmann // *Journal of Neuroscience*. — 2012. — Vol. 32, no. 18. — Pp. 6053–6060.
22. Learning transferable visual models from natural language supervision / Alec Radford, Jong Wook Kim, Chris Hallacy et al. // International conference on machine learning / PMLR. — 2021. — Pp. 8748–8763.
23. Audio–text retrieval based on contrastive learning and collaborative attention mechanism / Tao Hu, Xuyu Xiang, Jiaohua Qin, Yun Tan // *Multimedia Systems*. — 2023. — Vol. 29, no. 6. — Pp. 3625–3638.
24. Connecting multi-modal contrastive representations / Zehan Wang, Yang Zhao, Haifeng Huang et al. // *Advances in Neural Information Processing Systems*. — 2023. — Vol. 36. — Pp. 22099–22114.
25. fmri-based decoding of visual information from human brain activity: A brief review / Shuo Huang, Wei Shao, Mei-Ling Wang, Dao-Qiang Zhang // *International Journal of Automation and Computing*. — 2021. — Vol. 18, no. 2. — Pp. 170–184.
26. Visual Decoding and Reconstruction via EEG Embeddings with Guided Diffusion / Dongyang Li, Chen Wei, Shiyong Li et al. // *Advances in Neural*

- Information Processing Systems / Ed. by A. Globerson, L. Mackey, D. Belgrave et al. — Vol. 37. — Curran Associates, Inc., 2024. — Pp. 102822–102864. — URL: https://proceedings.neurips.cc/paper_files/paper/2024/file/ba5f1233efa77787ff9ec015877dbd1f-Paper-Conference.pdf.
27. An open-access dataset of naturalistic viewing using simultaneous EEG-fMRI / Qawi K. Telesford, Eduardo Gonzalez-Moreira, Ting Xu et al. // *Scientific Data*. — 2023. — август. — Vol. 10, no. 1. — URL: <http://dx.doi.org/10.1038/s41597-023-02458-8>.
 28. *Simonyan Karen, Zisserman Andrew*. Very Deep Convolutional Networks for Large-Scale Image Recognition. — 2015. — URL: <https://arxiv.org/abs/1409.1556>.
 29. *He Kaiming, Zhang Xiangyu, Ren Shaoqing, Sun Jian*. Deep Residual Learning for Image Recognition. — 2015. — URL: <https://arxiv.org/abs/1512.03385>.
 30. *Dosovitskiy Alexey, Beyer Lucas, Kolesnikov Alexander et al.* An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. — 2021. — URL: <https://arxiv.org/abs/2010.11929>.
 31. *Caron Mathilde, Touvron Hugo, Misra Ishan et al.* Emerging Properties in Self-Supervised Vision Transformers. — 2021. — URL: <https://arxiv.org/abs/2104.14294>.
 32. Simultaneous EEG and functional MRI data during rest and sleep from humans / Yameng Gu, Lucas E. Sainburg, Feng Han, Xiao Liu // *Data in Brief*. — 2023. — июнь. — Vol. 48. — P. 109059. — URL: <http://dx.doi.org/10.1016/j.dib.2023.109059>.
 33. Le Petit Prince Hong Kong (LPPHK): Naturalistic fMRI and EEG data from older Cantonese speakers / Mohammad Momenian, Zhengwu Ma, Shuyi Wu et al. — 2024. — апрель. — URL: <http://dx.doi.org/10.1101/2024.04.24.590842>.
 34. Open multimodal iEEG-fMRI dataset from naturalistic stimulation with a short audiovisual film / Julia Berezutskaya, Mariska J. Vansteensel, Erik J. Aarnoutse et al. // *Scientific Data*. — 2022. — март. — Vol. 9, no. 1. — URL: <https://doi.org/10.1038/s41597-022-01173-0>.

35. Simultaneous and independent electroencephalography and magnetic resonance imaging: A multimodal neuroimaging dataset / Jonathan Gallego-Rudolf, María Corsi-Cabrera, Luis Concha et al. // *Data in Brief*. — 2023. — декабрь. — Vol. 51. — P. 109661. — URL: <http://dx.doi.org/10.1016/j.dib.2023.109661>.
36. *Wakeman Daniel G, Henson Richard N*. A multi-subject, multi-modal human neuroimaging dataset // *Scientific Data*. — 2015. — январь. — Vol. 2, no. 1. — URL: <http://dx.doi.org/10.1038/sdata.2015.1>.
37. *Ozcelik Furkan, VanRullen Rufin*. Natural scene reconstruction from fMRI signals using generative latent diffusion. — 2023. — URL: <https://arxiv.org/abs/2303.05334>.
38. *Chen Zijiao, Qing Jiaxin, Zhou Juan Helen*. Cinematic Mindscapes: High-quality Video Reconstruction from Brain Activity. — 2023. — URL: <https://arxiv.org/abs/2305.11675>.
39. *Scotti Paul S., Banerjee Atmadeep, Goode Jimmie et al*. Reconstructing the Mind's Eye: fMRI-to-Image with Contrastive Learning and Diffusion Priors. — 2023. — URL: <https://arxiv.org/abs/2305.18274>.
40. NeuroGAN: image reconstruction from EEG signals via an attention-based GAN / Rahul Mishra, Krishan Sharma, R. R. Jha, Arnav Bhavsar // *Neural Computing and Applications*. — 2022. — декабрь. — URL: <http://dx.doi.org/10.1007/s00521-022-08178-1>.
41. *Singh Prajwal, Pandey Pankaj, Miyapuram Krishna, Raman Shanmuganathan*. EEG2IMAGE: Image Reconstruction from EEG Brain Signals. — 2023. — URL: <https://arxiv.org/abs/2302.10121>.
42. *Esser Patrick, Rombach Robin, Ommer Björn*. Taming Transformers for High-Resolution Image Synthesis. — 2021. — URL: <https://arxiv.org/abs/2012.09841>.
43. *Hatamizadeh Ali, Song Jiaming, Liu Guilin et al*. DiffiT: Diffusion Vision Transformers for Image Generation. — 2024. — URL: <https://arxiv.org/abs/2312.02139>.

- 44. *Crowson Katherine, Biderman Stella, Kornis Daniel et al.* VQGAN-CLIP: Open Domain Image Generation and Editing with Natural Language Guidance. — 2022. — URL: <https://arxiv.org/abs/2204.08583>.
- 45. *Podell Dustin, English Zion, Lacey Kyle et al.* SDXL: Improving Latent Diffusion Models for High-Resolution Image Synthesis. — 2023. — URL: <https://arxiv.org/abs/2307.01952>.
- 46. *Ye Hu, Zhang Jun, Liu Sibao et al.* IP-Adapter: Text Compatible Image Prompt Adapter for Text-to-Image Diffusion Models. — 2023. — URL: <https://arxiv.org/abs/2308.06721>.
- 47. *Otsu Nobuyuki et al.* A threshold selection method from gray-level histograms // *Automatica*. — 1975. — Vol. 11, no. 285-296. — Pp. 23–27.
- 48. *Ho Jonathan, Jain Ajay, Abbeel Pieter.* Denoising Diffusion Probabilistic Models. — 2020. — URL: <https://arxiv.org/abs/2006.11239>.