

Федеральное государственное автономное образовательное учреждение  
высшего образования  
«Московский физико-технический институт  
(национальный исследовательский университет)»  
Физтех-школа прикладной математики и информатики  
Кафедра интеллектуальных систем

Дорин Даниил Дмитриевич

**ДЕКОДИРОВАНИЕ ВИЗУАЛЬНОЙ ИНФОРМАЦИИ ИЗ  
СИГНАЛОВ МОЗГА НА ОСНОВЕ  
ПРОСТРАНСТВЕННО-ВРЕМЕННЫХ  
ХАРАКТЕРИСТИК**

09.04.01 — Информатика и вычислительная техника

Выпускная квалификационная работа магистра

**Научный руководитель:**  
Грабовой Андрей Валериевич,  
канд. физ.-мат. наук

Москва — 2026

## Аннотация

Декодирование визуальных стимулов по нейробиологическим сигналам представляет собой ключевую задачу на стыке вычислительной нейронауки и современного машинного обучения. Несмотря на успехи, достигнутые в одномодальных подходах с применением контрастивных представлений и диффузионных генеративных моделей, большинство существующих методов опирается лишь на одну модальность — либо функциональную магнитно-резонансную томографию (фМРТ) с высоким пространственным разрешением, либо электроэнцефалографию (ЭЭГ) с высоким временным разрешением. Совместное использование этих модальностей остаётся слабо изученным направлением.

В работе предлагается мультимодальная архитектура, одновременно обрабатывающая записи фМРТ-ЭЭГ для реконструкции визуальных стимулов. Эмбединги нейробиологических сигналов обучаются контрастивно для сближения с CLIP-эмбедингами соответствующих изображений. Двухстадийная схема генерации включает уточнение эмбединга мозга в CLIP-пространстве априорной диффузионной моделью и последующую генерацию изображения предобученной диффузионной моделью. Гемодинамическая задержка BOLD-сигнала анализируется через решение вспомогательной обратной задачи прогнозирования фМРТ по визуальному стимулу; полученная оценка задержки используется на этапе предобработки при формировании обучающих триплетов.

Эксперименты на открытом мультимодальном наборе данных подтверждают эффективность предложенной архитектуры в задаче нейродекодирования. По метрике CLIP-Score мультимодальная модель превосходит одномодальные аналоги, что подчёркивает необходимость совместного учёта фМРТ и ЭЭГ для точной реконструкции визуальных стимулов.

## Содержание

|                                                                                   |           |
|-----------------------------------------------------------------------------------|-----------|
| <b>Обозначения и сокращения</b>                                                   | <b>4</b>  |
| <b>Введение</b>                                                                   | <b>6</b>  |
| <b>1. Анализ предметной области и существующих подходов</b>                       | <b>10</b> |
| 1.1. Декодирование визуальных стимулов в задачах ИМК . . . . .                    | 10        |
| 1.2. Модальности нейровизуализации и их одновременная регистрация                 | 10        |
| 1.3. Существующие подходы к декодированию визуальных стимулов .                   | 11        |
| 1.4. Открытые наборы данных с одновременной регистрацией сигналов                 | 13        |
| 1.5. Выводы и переход к постановке задачи . . . . .                               | 13        |
| <b>2. Постановка задачи</b>                                                       | <b>14</b> |
| 2.1. Общая постановка мультимодального декодирования . . . . .                    | 14        |
| 2.2. Двумодальное декодирование фМРТ–ЭЭГ . . . . .                                | 14        |
| 2.3. Гипотеза о гемодинамической задержке . . . . .                               | 15        |
| 2.4. Вспомогательная обратная задача для оценки $\Delta t$ . . . . .              | 15        |
| <b>3. Предлагаемый метод</b>                                                      | <b>17</b> |
| 3.1. Предобработка данных и учёт гемодинамической задержки . . . .                | 17        |
| 3.2. Архитектура мультимодального энкодера . . . . .                              | 20        |
| 3.3. Контрастивное обучение и метрика качества . . . . .                          | 22        |
| 3.4. Двухстадийная диффузионная генерация изображения . . . . .                   | 23        |
| 3.5. Итоговая схема и личный вклад . . . . .                                      | 24        |
| <b>4. Вычислительный эксперимент</b>                                              | <b>25</b> |
| 4.1. Оценка гемодинамической задержки и устойчивость линейной<br>модели . . . . . | 25        |
| 4.2. Мультимодальная реконструкция изображений . . . . .                          | 31        |
| <b>Заключение</b>                                                                 | <b>35</b> |
| <b>Список литературы</b>                                                          | <b>38</b> |

## Обозначения и сокращения

### Сокращения

|            |                                                     |
|------------|-----------------------------------------------------|
| ИМК        | интерфейс мозг-компьютер                            |
| фМРТ       | функциональная магнитно-резонансная томография      |
| ЭЭГ        | электроэнцефалография                               |
| BOLD       | blood-oxygen-level dependent                        |
| EPI        | echo-planar imaging                                 |
| CLIP       | Contrastive Language-Image Pre-training             |
| SDXL       | Stable Diffusion XL                                 |
| DDPM       | Denoising Diffusion Probabilistic Model             |
| IP-Adapter | Image Prompt Adapter                                |
| MLP        | multilayer perceptron                               |
| ViT        | Vision Transformer                                  |
| GELU       | Gaussian Error Linear Unit                          |
| MSE        | среднеквадратичная ошибка                           |
| MAPE       | средняя абсолютная процентная ошибка                |
| CLIP-Score | косинусная близость в пространстве CLIP-эмбеддингов |



## Основные обозначения

|                                                          |                                                                                  |
|----------------------------------------------------------|----------------------------------------------------------------------------------|
| $\mathcal{X}_f, \mathcal{X}_e$                           | пространства данных фМРТ и ЭЭГ                                                   |
| $\mathcal{Y}$                                            | пространство визуальных стимулов                                                 |
| $\mathbf{F}_i, \mathbf{E}_i, \mathbf{I}_i$               | фМРТ, ЭЭГ и изображение $i$ -го наблюдения                                       |
| $\mathfrak{D}$                                           | обучающий набор триплетов                                                        |
| $N$                                                      | объём выборки                                                                    |
| $\mathbf{f}$                                             | целевое отображение $\mathcal{X}_f \times \mathcal{X}_e \rightarrow \mathcal{Y}$ |
| $\mathbf{g}$                                             | отображение обратной задачи $\mathcal{Y} \rightarrow \mathcal{X}_f$              |
| $\mathcal{E}_f, \mathcal{E}_e, \mathcal{F}$              | энкодеры фМРТ, ЭЭГ и модуль объединения                                          |
| $\mathbf{Z}_f, \mathbf{Z}_e, \mathbf{Z}_c, \mathbf{Z}_I$ | эмбединги фМРТ, ЭЭГ, комбинированный и CLIP                                      |
| $d_f, d_e, d$                                            | размерности латентных пространств                                                |
| $\phi$                                                   | замороженный визуальный энкодер CLIP                                             |
| $\Delta t$                                               | гемодинамическая задержка BOLD-сигнала                                           |
| $\mu, \nu$                                               | частоты дискретизации фМРТ и видео кадров                                        |
| $\mathbf{F}_\ell, \mathbf{I}_\ell$                       | фМРТ-скан и видеокадр в момент $\ell$                                            |
| $\delta_\ell$                                            | приращение фМРТ $\mathbf{F}_\ell - \mathbf{F}_{\ell-1}$                          |
| $\psi_{\text{vis}}$                                      | визуальный энкодер в обратной задаче                                             |
| $\varphi$                                                | линейная регрессия по вокселям                                                   |
| $\mathbf{z}_\ell$                                        | эмбединг видеокадра $\mathbf{I}_\ell$                                            |
| $\Psi$                                                   | матрица визуальных эмбедингов                                                    |
| $\Delta_{ijk}$                                           | вектор приращений в вокселе $(i, j, k)$                                          |
| $\hat{\mathbf{w}}_{ijk}, \hat{\mathbf{W}}$               | оценки параметров: повоксельная и матричная                                      |
| $\mathbf{I}_d$                                           | единичная матрица $d \times d$                                                   |
| $\alpha$                                                 | коэффициент $L_2$ -регуляризации                                                 |
| $\tau$                                                   | обучаемая температура контрастивной функции потерь                               |
| $\mathcal{L}_{\text{contr}}$                             | контрастивная функция потерь                                                     |
| $\mathcal{L}_{\text{prior}}$                             | функция потерь априорной диффузионной модели                                     |
| $B$                                                      | размер батча                                                                     |

## Введение

**Контекст исследования.** Развитие методов анализа нейробиологических данных и техник нейровизуализации привело к становлению интерфейсов мозг–компьютер (ИМК) как самостоятельной технологической области [1, 2]. ИМК обеспечивают прямое взаимодействие нервной системы с внешними устройствами, минуя периферические нервно-мышечные пути [3], и позволяют преобразовывать нейронную активность в управляющие команды для протезов, роботизированных устройств и программных интерфейсов [4, 5, 6]. Подкласс задач ИМК — декодирование визуальных стимулов по неинвазивным записям мозговой активности; именно к этой подобласти относится настоящая работа.

**Актуальность темы.** Современные методы декодирования визуальных стимулов опираются преимущественно на одну модальность нейровизуализации — либо функциональную магнитно-резонансную томографию (фМРТ), обеспечивающую высокое пространственное разрешение, либо электроэнцефалографию (ЭЭГ), обладающую высоким временным разрешением [7, 8, 9]. Однако ни одна из этих модальностей по отдельности не охватывает всю пространственно-временную структуру нейронного отклика на визуальные стимулы. фМРТ ограничена низкой частотой сканирования и гемодинамической задержкой BOLD-сигнала продолжительностью 4–8 секунд [10, 11]; ЭЭГ обладает низким пространственным разрешением вследствие объёмной проводимости тканей головы и низким отношением сигнал/шум [12, 13]. Появление открытых наборов данных с одновременной регистрацией фМРТ и ЭЭГ при предъявлении визуальных стимулов [14] впервые делает возможной экспериментальную проверку гипотезы о взаимной комплементарности этих модальностей в задаче реконструкции изображений.

Существующие подходы к декодированию визуальных стимулов опираются лишь на одну модальность — фМРТ или ЭЭГ — и систематически используют контрастивное выравнивание с CLIP-пространством и последующую диффузионную генерацию [8, 9, 15, 16, 17, 18]. Задача декодирования визуальных стимулов по одновременным записям фМРТ и ЭЭГ не рассматривалась. На основе проведённого анализа выделены два пробела. Первый — отсутствие архитектур, объединяющих фМРТ и ЭЭГ в единое представление для декодирования визуальных стимулов с явным учётом их комплементарности. Второй — отсутствие формализованного учёта гемодинамической задержки  $\Delta t$  BOLD-

сигнала, регистрируемого фМРТ, при формировании обучающих триплетов: фМРТ-скан отражает нейронный отклик на стимул с задержкой  $\Delta t$  относительно момента предъявления, и это смещение по времени необходимо учитывать при сопоставлении фМРТ-данных с изображением.

**Объект исследования** — декодирование визуальных стимулов из неинвазивных нейробиологических сигналов мозга.

**Предмет исследования** — построение отображения из совместного пространства одновременных записей фМРТ и ЭЭГ в пространство изображений-стимулов с учётом гемодинамической задержки BOLD-сигнала.

**Цель работы** — разработка метода реконструкции визуальных стимулов по одновременным записям фМРТ и ЭЭГ, использующего пространственно-временные характеристики обеих модальностей.

Для достижения цели решаются следующие задачи:

1. Систематизация существующих подходов к декодированию визуальных стимулов и выделение нерешённых проблем.
2. Формализация двумодальной задачи декодирования: определение совместного пространства данных, целевого отображения и критерия качества.
3. Разработка метода реконструкции изображений по одновременным сигналам фМРТ–ЭЭГ, включающего предобработку данных с учётом гемодинамической задержки  $\Delta t$ , контрастивное обучение комбинированных представлений и двухстадийную диффузионную генерацию.
4. Экспериментальная проверка метода: количественная оценка гемодинамической задержки на независимом наборе данных, сравнение мультимодальной модели с одномодальными аналогами по метрике CLIP-Score, анализ устойчивости результатов.

**Методы исследования.** В работе применяются методы статистического обучения (линейная регрессия с  $L_2$ -регуляризацией, контрастивное обучение), методы вероятностного моделирования (вероятностные диффузионные модели DDPM), методы предобучения визуальных представлений (модель CLIP ViT-H/14), методы пространственного маскирования (алгоритм Оцу), а также экспериментальные методы количественной оценки (метрика CLIP-Score,

ablation-сравнение конфигураций модели, усреднение по испытуемым с указанием стандартного отклонения).

### **Научная новизна.**

- Предложена двумодальная архитектура реконструкции изображений по одновременным сигналам фМРТ–ЭЭГ, в которой два независимых энкодера и обучаемый модуль объединения формируют комбинированное представление, выравниваемое контрастивно с CLIP-пространством.
- Введён компонент препроцессинга, явно учитывающий гемодинамическую задержку  $\Delta t$  при формировании обучающих триплетов; значение  $\Delta t \approx 5$  с обосновано независимым экспериментом с линейной авторегрессионной моделью.
- Проведено систематическое ablation-сравнение шести конфигураций модели (одномодальные/двумодальные  $\times$  с/без априорной диффузионной модели), количественно подтверждающее преимущество совместного использования модальностей.

**Теоретическая значимость.** Получено эмпирическое подтверждение взаимодополнительности пространственной информации фМРТ и временной информации ЭЭГ в задаче декодирования визуальных стимулов. Формализована связь между гемодинамической задержкой BOLD-сигнала и качеством выравнивания нейронных представлений с пространством визуальных признаков.

**Практическая значимость.** Разработанный метод применим в исследованиях ИМК для визуального декодирования, в клинической диагностике зрительной коры и в инструментах семантического анализа естественных видеостимулов. Использование открытых датасетов и общедоступных предобученных моделей CLIP и SDXL обеспечивает воспроизводимость и переносимость подхода.

**Достоверность результатов** обеспечивается следующими факторами: (i) использование открытых наборов данных [14, 19] с протоколами, прошедшими этическую экспертизу; (ii) усреднение количественных оценок по 22 испытуемым с указанием стандартного отклонения; (iii) сравнение с верхней границей качества генерации, достижимой при условии на CLIP-эмбединг исходного изображения; (iv) ablation-сравнение конфигураций модели; (v) независимая оценка значения гемодинамической задержки на отдельном наборе данных и согласованность с известным диапазоном значений в медицинской литературе [10].

**Апробация результатов.** Часть результатов работы, относящаяся к анализу гемодинамической задержки, опубликована в [20]. Результаты по двумодальной реконструкции изображений по одновременным сигналам фМРТ–ЭЭГ подготовлены к публикации.

**Личный вклад автора.** Автором сформулирована двумодальная постановка задачи, разработана архитектура мультимодального энкодера, спроектирована схема двухстадийной генерации, реализованы процедуры предобработки данных с учётом гемодинамической задержки, проведены вычислительные эксперименты на двух наборах данных и выполнен анализ результатов.

**Структура работы.** Работа состоит из введения, обозначений и сокращений, четырёх глав, заключения и списка использованных источников. Глава 1 содержит анализ предметной области и существующих подходов к декодированию визуальных стимулов, выявляющий нерешённые проблемы. В Главе 2 формализуется задача двумодального декодирования. Глава 3 излагает предложенный метод реконструкции изображений, включая препроцессинг данных с учётом гемодинамической задержки, архитектуру мультимодального энкодера, контрастивное обучение и двухстадийную диффузионную генерацию. Глава 4 описывает вычислительные эксперименты: оценку гемодинамической задержки, проверку устойчивости линейной модели и количественное сравнение конфигураций двумодальной архитектуры. В заключении сформулированы основные результаты и направления дальнейших исследований.

## **1. Анализ предметной области и существующих подходов**

Данная глава содержит систематизацию существующих подходов к декодированию визуальных стимулов из неинвазивных нейробиологических сигналов. Изложение строится как сравнительный анализ идей и инженерных решений, применяемых на каждом этапе обработки данных. В конце главы формулируются нерешённые проблемы, мотивирующие постановку задачи.

### **1.1. Декодирование визуальных стимулов в задачах ИМК**

Интерфейс мозг–компьютер представляет собой техническую систему, преобразующую регистрируемые нейробиологические сигналы в управляющие команды или содержательные представления, минуя периферические нервно-мышечные пути [1, 2, 3]. В прикладных сценариях ИМК обеспечивают функциональное замещение для пациентов с двигательными или коммуникативными нарушениями [4, 5, 6]. Декодирование визуальных стимулов — подкласс задач ИМК, в котором по нейронной активности восстанавливаются характеристики предъявленного субъекту изображения. Эта задача важна как тест возможностей современных методов нейровизуализации, как инструмент изучения процессов зрительного восприятия и как основа для перспективных приложений в области сенсорной поддержки.

### **1.2. Модальности нейровизуализации и их одновременная регистрация**

**фМРТ как пространственно-информативная модальность.** Функциональная магнитно-резонансная томография — метод регистрации мозговой активности, основанный на измерении локальных изменений кровотока, индуцированных нейронной активностью [21]. В основе фМРТ лежит BOLD-сигнал (англ. blood-oxygen-level dependent), чувствительный к изменению относительного содержания оксигенированного и дезоксигенированного гемоглобина [22, 23]. Сосудистый отклик возникает не мгновенно: между нейронной активностью и максимумом BOLD-сигнала проходит 4–8 секунд [10, 11, 24]. Регистрация выполняется последовательностями эхопланарных изображений [25, 26]. Сильная сторона фМРТ — высокое пространственное разрешение порядка миллиметра. Слабая сторона — ограниченное временное разрешение и чувствительность к артефактам движения и физиологическим шумам [27, 28].

**ЭЭГ как временно-информативная модальность.** Электроэнцефалография регистрирует суммарную электрическую активность нейронных популяций с поверхности скальпа. Ключевое преимущество ЭЭГ — высокое временное разрешение, позволяющее отслеживать нейронные процессы в реальном времени [12]. Однако объёмная проводимость тканей головы приводит к сглаживанию сигналов от различных нейронных источников и снижает пространственное разрешение, а низкое отношение сигнала к шуму [13] и межиндивидуальная вариабельность [29, 30] осложняют перенос обученных моделей между испытуемыми.

**Одновременная регистрация фМРТ и ЭЭГ.** Свойства фМРТ и ЭЭГ комплементарны: высокое пространственное разрешение фМРТ компенсирует слабые стороны ЭЭГ, а высокое временное разрешение ЭЭГ — слабые стороны фМРТ. Это мотивирует одновременную регистрацию обеих модальностей. Техническая реализация осложняется специфическими артефактами: в сильном магнитном поле томографа ЭЭГ-сигнал искажается градиентными и кардиобаллистическими артефактами [31]. Для их подавления применяются магнитно-резонансно-совместимые системы записи и алгоритмы постобработки на основе оптимальных базисных наборов [32, 33], что при корректном применении делает возможным обучение мультимодальных моделей на триплетах (фМРТ, ЭЭГ, стимул).

### 1.3. Существующие подходы к декодированию визуальных стимулов

**Контрастивное обучение и общие пространства представлений.** Существенный сдвиг в задачах кросс-модального обучения связан с появлением модели CLIP [34]: она формирует совместное пространство эмбеддингов изображений и текстовых описаний через симметричную контрастивную функцию потерь на основе косинусного расстояния. Полученное пространство демонстрирует богатую семантическую структуру и устойчивость к доменным сдвигам, что обеспечивает высокое качество в задачах zero-shot. Контрастивная парадигма распространяется на другие пары модальностей при наличии подходящих энкодеров [35, 36]. В декодировании нейробиологических сигналов CLIP-пространство выступает универсальным интерфейсом между нейронными представлениями и генеративными моделями.

**Одномодальное декодирование по фМРТ.** В работе [15] предложена двухстадийная модель: индивидуальная линейная регрессия отображает фМРТ-сигнал в латентное пространство VDVAE для грубой реконструкции, после чего диффузионная модель уточняет изображение при условии на CLIP-эмбединга и текстовое описание. Аналогичные идеи распространены на видеостимулы [16]: модифицированная диффузионная модель с временным вниманием обуславливается на эмбединга фМРТ. В [9] вводится диффузионная априорная модель в CLIP-пространстве, устраняющая разрыв между фМРТ-эмбедингом и распределением визуальных эмбедедингов; этот приём принят в настоящей работе. Среди других направлений — комбинация контрастивного обучения и генеративных моделей с акцентом на инвариантность по испытуемым [7].

**Одномодальное декодирование по ЭЭГ.** В одномодальных подходах с ЭЭГ применяются индивидуализированные LSTM-энкодеры [18], свёрточные сети [17], а также гибридные архитектуры со свёртками и механизмом внимания [8]. Общая схема та же: контрастивное выравнивание ЭЭГ-эмбединга с CLIP-пространством и последующая генерация диффузионной моделью. Качество реконструкции по отдельной модальности ограничено её внутренними свойствами: для фМРТ — временным разрешением, для ЭЭГ — пространственным и шумом.

**Генеративные модели для синтеза изображений.** Современные методы визуального декодирования используют латентно-диффузионные архитектуры, оперирующие в компактном скрытом пространстве [37, 38]. Отдельную линию составляют модели, обусловленные на CLIP-эмбединга, что обеспечивает гибкое управление семантикой генерации [39]. В качестве генеративного бэкбона в настоящей работе используется Stable Diffusion XL [40] — модель, демонстрирующая высокое качество синтеза при условии на CLIP-эмбединга через адаптер IP-Adapter [41]. Среди визуальных энкодеров наиболее распространены CLIP ViT-H/14 [34] и архитектуры самообучения DINO [42], демонстрирующие превосходство контрастивных и самообучающихся представлений над классически обученными свёрточными моделями [43, 44] и над Vision Transformer без специального обучения [45].



#### 1.4. Открытые наборы данных с одновременной регистрацией сигналов

Постановка задачи мультимодального декодирования требует наличия данных, в которых фМРТ и ЭЭГ зарегистрированы одновременно при предъявлении визуальных стимулов. До недавнего времени подобные данные были ограничены: одни наборы исключают визуальную стимуляцию (состояние покоя, аудиостимуляция) [46, 47], другие содержат разнесённые во времени сессии фМРТ и ЭЭГ [19], третьи ориентированы на верификацию методической совместимости одновременной записи без анализа стимул-зависимой нейродинамики [48]. На момент написания работы лишь два открытых набора данных обеспечивают одновременную регистрацию фМРТ и ЭЭГ при предъявлении визуальных стимулов: набор [14] (22 испытуемых, синтетические и натуралистические видеостимулы) и набор [49] (16 испытуемых, статичные изображения лиц). В настоящей работе в качестве основного выбран [14] ввиду разнообразия типов стимулов и большего числа испытуемых; вспомогательно для оценки гемодинамической задержки используется [19], содержащий одновременные записи фМРТ и видеостимулов.

#### 1.5. Выводы и переход к постановке задачи

Проведённый анализ выявляет три ключевых наблюдения. Во-первых, одно-модальные подходы систематически опираются на контрастивное выравнивание с CLIP-пространством и последующую диффузионную генерацию, но упираются во внутренние ограничения соответствующей модальности. Во-вторых, совместное использование одновременных записей фМРТ и ЭЭГ для декодирования визуальных стимулов в открытой литературе систематически не рассматривалось, несмотря на доступность соответствующих наборов данных. В-третьих, гемодинамическая задержка BOLD-сигнала известна как фундаментальное свойство фМРТ, однако явный учёт этой задержки при формировании обучающих триплетов как стандартный компонент существующих архитектур отсутствует. Эти три наблюдения определяют постановку задачи (Глава 2.): построение архитектуры, объединяющей фМРТ и ЭЭГ в единое контрастивно выравненное представление с предобработкой, явно учитывающей гемодинамическую задержку BOLD-сигнала.

## 2. Постановка задачи

В данной главе формализуется задача двумодального декодирования визуальных стимулов по одновременным записям фМРТ и ЭЭГ. Изложение ограничивается определением входных и выходных пространств, обучающей выборки, целевого отображения и гипотезы о гемодинамической задержке. Конкретные методы решения, функции потерь и метрики качества вводятся в Главе 3..

### 2.1. Общая постановка мультимодального декодирования

Пусть  $\mathcal{X}^{(m)}$  — пространство наблюдений модальности  $m$ , где  $m = 1, \dots, M$ . Совместное пространство нейробиологических данных определяется как декартово произведение пространств отдельных модальностей:

$$\mathcal{X} = \mathcal{X}^{(1)} \times \dots \times \mathcal{X}^{(M)}. \quad (1)$$

Пусть  $\mathcal{Y}$  — пространство визуальных стимулов или их характеристик. Задача мультимодального декодирования состоит в построении отображения

$$\mathbf{g}_M : \mathcal{X} \rightarrow \mathcal{Y}, \quad (2)$$

которое восстанавливает стимул  $\mathbf{y} \in \mathcal{Y}$  по совместному наблюдению  $\mathbf{x} \in \mathcal{X}$ .

Настоящая работа рассматривает частный случай  $M = 2$ , в котором модальностями являются одновременные записи фМРТ и ЭЭГ:

$$\mathcal{X} = \mathcal{X}_f \times \mathcal{X}_e, \quad \mathbf{x} = (\mathbf{F}, \mathbf{E}), \quad (3)$$

а целевое пространство — пространство изображений-стимулов.

### 2.2. Двумодальное декодирование фМРТ–ЭЭГ

Задан обучающий набор  $N$  триплетов

$$\mathcal{D} = \{(\mathbf{F}_i, \mathbf{E}_i, \mathbf{I}_i) \mid i = 1, \dots, N\}, \quad (\mathbf{F}_i, \mathbf{E}_i) \in \mathcal{X}_f \times \mathcal{X}_e, \quad \mathbf{I}_i \in \mathcal{Y}, \quad (4)$$

где  $\mathbf{F}_i \in \mathbb{R}^{X \times Y \times Z}$  — тензор фМРТ-данных  $i$ -го наблюдения с пространственными размерностями  $X, Y, Z$ ;  $\mathbf{E}_i \in \mathbb{R}^{K \times T}$  — матрица ЭЭГ-данных  $i$ -го наблюдения, где  $K$  — число каналов регистрации,  $T$  — длина временного окна;  $\mathbf{I}_i \in \mathbb{R}^{H \times W \times C}$  —

изображение-стимул  $i$ -го наблюдения, где  $H, W$  — высота и ширина изображения,  $C$  — число цветовых каналов. Триплет  $(\mathbf{F}_i, \mathbf{E}_i, \mathbf{I}_i)$  соответствует одному эпизоду эксперимента: испытуемому предъявляется стимул  $\mathbf{I}_i$ , при этом синхронно регистрируются фМРТ-данные  $\mathbf{F}_i$  и ЭЭГ-данные  $\mathbf{E}_i$ .

Требуется построить отображение

$$\mathbf{f} : \mathcal{X}_f \times \mathcal{X}_e \rightarrow \mathcal{Y}, \quad (5)$$

которое по совместному наблюдению  $(\mathbf{F}, \mathbf{E})$  восстанавливает изображение  $\hat{\mathbf{I}} = \mathbf{f}(\mathbf{F}, \mathbf{E})$ , семантически соответствующее предъявленному стимулу.

### 2.3. Гипотеза о гемодинамической задержке

BOLD-сигнал фМРТ возникает с гемодинамической задержкой  $\Delta t$  относительно момента предъявления визуального стимула [10, 11]; ЭЭГ-сигнал, напротив, отражает нейронный отклик практически без задержки. Поэтому при формировании триплета  $(\mathbf{F}_i, \mathbf{E}_i, \mathbf{I}_i)$  временной сдвиг затрагивает только фМРТ-составляющую: изображение  $\mathbf{I}_i$  должно соответствовать моменту времени, предшествующему моменту регистрации фМРТ-скана  $\mathbf{F}_i$  на величину  $\Delta t$ , тогда как  $\mathbf{E}_i$  регистрируется синхронно с  $\mathbf{I}_i$ . Формально пусть  $\mathbf{F}(t)$  — фМРТ-скан в момент  $t$ ,  $\mathbf{E}(t)$  — ЭЭГ-окно вокруг момента  $t$ , а  $\mathbf{I}(t)$  — изображение, предъявленное в момент  $t$ . Тогда триплеты выборки (4) формируются по правилу

$$\mathbf{F}_i = \mathbf{F}(t_i), \quad \mathbf{E}_i = \mathbf{E}(t_i - \Delta t), \quad \mathbf{I}_i = \mathbf{I}(t_i - \Delta t), \quad (6)$$

где  $\Delta t$  — параметр предобработки, значение которого подлежит оценке.

### 2.4. Вспомогательная обратная задача для оценки $\Delta t$

Для количественной оценки  $\Delta t$  формулируется *обратная задача* по отношению к двумодальному декодированию (5): если основная (прямая) задача отображает совместное пространство сигналов мозга в пространство изображений  $(\mathcal{X}_f \times \mathcal{X}_e \rightarrow \mathcal{Y})$ , то обратная задача восстанавливает фМРТ-скан по визуальному стимулу. Формально требуется построить отображение

$$\mathbf{g} : \mathcal{Y} \rightarrow \mathcal{X}_f, \quad (7)$$

прогнозирующее фМРТ-скан по предъявленному изображению. В правой части (7) в роли наблюдения выступает визуальный стимул  $\mathbf{I} \in \mathcal{Y}$  (в основной задаче — целевая переменная), а целью прогноза выступает фМРТ  $\mathbf{F} \in \mathcal{X}_f$  (в основной задаче — наблюдение). Параметр  $\Delta t$  выступает гиперпараметром  $\mathbf{g}$ , его оптимальное значение определяется из минимума ошибки прогноза. Класс отображений  $\mathbf{g}$  и процедура оценки  $\Delta t$  описаны в Главе 3. (раздел 3.1.); экспериментальная проверка — в Главе 4..

### 3. Предлагаемый метод

В данной главе описывается метод решения задачи (5). Метод состоит из четырёх компонентов: предобработки данных с явным учётом гемодинамической задержки  $\Delta t$  через решение обратной задачи (7), архитектуры мультимодального энкодера, контрастивного обучения с введением метрики качества и двухстадийной диффузионной генерации. Общая схема приведена на рис. 1.




Рис. 1: Общая схема предложенного метода. На этапе контрастивного обучения комбинированный эмбединг  $\mathbf{Z}_c$  выравнивается с замороженным CLIP-эмбедингом  $\mathbf{Z}_I$ . На этапе генерации априорная диффузионная модель уточняет  $\mathbf{Z}_c$  до оценки  $\hat{\mathbf{Z}}_I$ , после чего предобученная SDXL синтезирует изображение, обусловленное на  $\hat{\mathbf{Z}}_I$

#### 3.1. Предобработка данных и учёт гемодинамической задержки

**Предобработка фМРТ.** Каждый фМРТ-скан  $\mathbf{F}_i$  проходит стандартную процедуру предобработки: коррекцию движения, пространственное сглаживание гауссовым ядром, нормализацию вокселей. Для снижения размерности и удаления фоновых вокселей строится индивидуальная бинарная маска мозга. Для каждого испытуемого вычисляется тензор суммарной абсолютной разности

значений вокселей во времени:

$$m_{ijk} = \sum_{t=2}^{T_{\text{scan}}} \left| v_{ijk}^t - v_{ijk}^{t-1} \right|, \quad (8)$$

где  $v_{ijk}^t$  — значение вокселя  $(i, j, k)$  в момент  $t$ , а  $T_{\text{scan}}$  — длина временного ряда фМРТ. К полученному тензору  $m = [m_{ijk}]$  применяется алгоритм автоматического выбора порога Оцу [50]: вычисляется порог  $\theta^*$ , разделяющий распределение значений  $m_{ijk}$  на два класса с максимальной межклассовой дисперсией, и бинарная маска определяется как

$$M_{ijk} = \mathbb{1}\{m_{ijk} > \theta^*\}. \quad (9)$$

Дальнейшая обработка фМРТ выполняется только на вокселях, для которых  $M_{ijk} = 1$ .

**Предобработка ЭЭГ.** Регистрация ЭЭГ в условиях работающего магнитно-резонансного томографа сопровождается двумя классами артефактов [31]: градиентными артефактами от переключения магнитных полей и кардиобаллистическими артефактами от пульсации сосудов. Подавление артефактов выполняется методом оптимальных базисных наборов [32]: для каждого типа артефакта вычисляется главный шаблон и вычитается из сигнала. Далее применяется полосовая фильтрация и усреднённое реферирование.

**Решение обратной задачи и определение  $\Delta t$ .** Для оценки гемодинамической задержки строится отображение  $\mathbf{g} : \mathcal{Y} \rightarrow \mathcal{X}_f$  из обратной задачи (7). В качестве данных используется отдельный набор с одновременной регистрацией фМРТ и видеостимулов [19, 20]. Пусть  $\mu$  — частота сканирования фМРТ,  $\nu$  — частота кадров видео,  $t$  — длительность записи. Последовательности фМРТ-сканов и изображений-стимулов обозначим

$$\mathbf{F}_1, \mathbf{F}_2, \dots, \mathbf{F}_{\mu t}, \quad \mathbf{F}_\ell \in \mathcal{X}_f, \quad (10)$$

$$\mathbf{I}_1, \mathbf{I}_2, \dots, \mathbf{I}_{\nu t}, \quad \mathbf{I}_\ell \in \mathcal{Y}. \quad (11)$$

Принимается марковское свойство временного ряда фМРТ: каждый последующий скан зависит только от предыдущего и от видеокadra, предъявленного на  $\Delta t$  секунд ранее. Это позволяет перейти к моделированию приращений

$$\boldsymbol{\delta}_\ell = \mathbf{F}_\ell - \mathbf{F}_{\ell-1}, \quad \ell = 2, \dots, \mu t, \quad (12)$$

причём обратное отображение (7) задаёт связь

$$\mathbf{g}(\mathbf{I}_{k_\ell - \nu \Delta t}) = \boldsymbol{\delta}_\ell, \quad k_\ell = \frac{\ell \cdot \nu}{\mu}, \quad (13)$$

где  $k_\ell$  — индекс видеокadra, синхронизированного по времени с  $\ell$ -м фМРТ-сканом.

**Параметризация и оценивание.** Отображение  $\mathbf{g}$  представимо в виде суперпозиции  $\mathbf{g} = \boldsymbol{\varphi} \circ \boldsymbol{\psi}_{\text{vis}}$ , где  $\boldsymbol{\psi}_{\text{vis}} : \mathcal{Y} \rightarrow \mathbb{R}^d$  — предобученный визуальный энкодер (ResNet152 [44] без последнего линейного слоя или Vision Transformer [45]), сопоставляющий каждому кадру эмбединг  $\mathbf{z}_\ell = \boldsymbol{\psi}_{\text{vis}}(\mathbf{I}_\ell) \in \mathbb{R}^d$ , а  $\boldsymbol{\varphi} : \mathbb{R}^d \rightarrow \mathbb{R}^{X \times Y \times Z}$  — покомпонентная линейная регрессия по вокселям. Для каждого вокселя  $(i, j, k)$  модель имеет вид

$$f_{ijk}(\mathbf{z}_\ell, \mathbf{w}_{ijk}) = \langle \mathbf{z}_\ell, \mathbf{w}_{ijk} \rangle, \quad \mathbf{w}_{ijk} \in \mathbb{R}^d, \quad (14)$$

параметры  $\mathbf{w}_{ijk}$  оцениваются методом наименьших квадратов с  $L_2$ -регуляризацией:

$$\hat{\mathbf{w}}_{ijk} = \arg \min_{\mathbf{w}_{ijk}} \sum_{\ell=2}^N (f_{ijk}(\mathbf{z}_\ell, \mathbf{w}_{ijk}) - \delta_{ijk}^\ell)^2 + \alpha \|\mathbf{w}_{ijk}\|_2^2, \quad (15)$$

где  $\alpha \in \mathbb{R}_+$  — коэффициент регуляризации. Через матрицу визуальных эмбедингов  $\boldsymbol{\Psi} = [\mathbf{z}_2, \dots, \mathbf{z}_N]^\top \in \mathbb{R}^{(N-1) \times d}$  (далее — *дизайн-матрица*) и вектор приращений  $\boldsymbol{\Delta}_{ijk} = [\delta_{ijk}^2, \dots, \delta_{ijk}^N]^\top$  записывается аналитическое решение

$$\hat{\mathbf{w}}_{ijk} = (\boldsymbol{\Psi}^\top \boldsymbol{\Psi} + \alpha \mathbf{I}_d)^{-1} \boldsymbol{\Psi}^\top \boldsymbol{\Delta}_{ijk}, \quad (16)$$

где  $\mathbf{I}_d \in \mathbb{R}^{d \times d}$  — единичная матрица. Оценки по всем вокселям объединяются в матрицу

$$\hat{\mathbf{W}} = [\hat{\mathbf{w}}_1, \dots, \hat{\mathbf{w}}_{XYZ}]^\top \in \mathbb{R}^{XYZ \times d}. \quad (17)$$

Авторегрессионный прогноз  $\ell$ -го фМРТ-скана имеет вид

$$\text{vec}(\hat{\mathbf{F}}_\ell) = \text{vec}(\mathbf{F}_{\ell-1}) + \hat{\mathbf{W}}\mathbf{z}_\ell. \quad (18)$$

Параметр  $\Delta t$  варьируется в дискретном диапазоне; для каждого значения переобучается модель (16) и вычисляется ошибка прогноза. Оптимальное значение  $\Delta t$  выбирается из минимума ошибки MSE, вычисленной на вокселях затылочной доли [51], и фиксируется при формировании триплетов основного эксперимента согласно (6). Экспериментальная процедура оценки  $\Delta t$  приведена в Главе 4..

### 3.2. Архитектура мультимодального энкодера

Целевое отображение  $\mathbf{f}$  из (5) реализуется через два независимых модальных энкодера и обучаемый модуль объединения. Архитектуры энкодеров представлены на рис. 2.




Рис. 2: Архитектуры энкодеров. (а) Энкодер ЭЭГ объединяет обучаемый индивидуальный эмбединг испытуемого с многоканальной записью посредством конкатенации, после чего применяются три свёртки (по времени, по каналам и глобальная) и MLP-голова. (б) Энкодер фМРТ выполняет персонализированное маскирование мозга и индивидуальную линейную проекцию вокселей в общее латентное пространство; завершающая обработка — MLP с остаточными соединениями

**Энкодер ЭЭГ.** Энкодер  $\mathcal{E}_e : \mathcal{X}_e \rightarrow \mathbb{R}^{d_e}$  реализован как последовательность трёх свёрточных слоёв и MLP-головы. Для учёта межсубъектной вариабельности



к многоканальной записи  $\mathbf{E} \in \mathbb{R}^{K \times T}$  добавляется обучаемый индивидуальный эмбединг испытуемого как дополнительный канал. Свёртки применяются последовательно: одномерная свёртка по временному измерению, одномерная свёртка по каналному измерению, глобальная свёртка для сжатия признаков в вектор. MLP-голова отображает полученный вектор в латентное пространство размерности  $d_e$ :

$$\mathbf{Z}_e = \mathcal{E}_e(\mathbf{E}) \in \mathbb{R}^{B \times d_e}, \quad (19)$$

где  $B$  — размер батча.

**Энкодер фМРТ.** Энкодер  $\mathcal{E}_f : \mathcal{X}_f \rightarrow \mathbb{R}^{d_f}$  построен на индивидуальной линейной проекции и остаточном MLP. Для каждого испытуемого с использованием бинарной маски (9) выделяются информативные воксели, формируется их векторизованное представление и применяется индивидуальный для испытуемого линейный слой, отображающий это представление в общее латентное пространство фиксированной размерности. Дальнейшая обработка — MLP с остаточными соединениями, LayerNorm и нелинейностью GELU. Выходное представление имеет вид

$$\mathbf{Z}_f = \mathcal{E}_f(\mathbf{F}) \in \mathbb{R}^{B \times d_f}. \quad (20)$$

Использование индивидуального линейного слоя для каждого испытуемого компенсирует различия анатомии и индивидуальную структуру маски мозга, сохраняя общую часть архитектуры разделяемой между испытуемыми.

**Модуль объединения.** Модуль объединения  $\mathcal{F} : \mathbb{R}^{d_f} \times \mathbb{R}^{d_e} \rightarrow \mathbb{R}^d$  интегрирует пространственно детализированное представление фМРТ и временно детализированное представление ЭЭГ в единый эмбединг:

$$\mathbf{Z}_c = \mathcal{F}(\mathbf{Z}_f, \mathbf{Z}_e) \in \mathbb{R}^{B \times d}. \quad (21)$$

В работе  $\mathcal{F}$  реализован как двухслойный MLP над конкатенацией  $[\mathbf{Z}_f; \mathbf{Z}_e]$ . Размерность  $d$  выбирается равной размерности пространства CLIP-эмбедингов для прямого выравнивания на этапе контрастивного обучения.

### 3.3. Контрастивное обучение и метрика качества

**Визуальные эмбединги.** Эмбединг  $\mathbf{Z}_I$  изображения-стимула вычисляется замороженным визуальным энкодером модели CLIP ViT-H/14 [34]:

$$\mathbf{Z}_I = \phi(\mathbf{I}) \in \mathbb{R}^{B \times d}, \quad (22)$$

параметры  $\phi$  не обновляются.

**Функция потерь.** Эмбединги нормируются по евклидовой норме:

$$\mathbf{Z}_I^n = \frac{\mathbf{Z}_I}{\|\mathbf{Z}_I\|}, \quad \mathbf{Z}_c^n = \frac{\mathbf{Z}_c}{\|\mathbf{Z}_c\|},$$

и вычисляется матрица логитов

$$\mathbf{L} = \mathbf{Z}_I^n (\mathbf{Z}_c^n)^\top \cdot e^\tau, \quad (23)$$

где  $\tau$  — обучаемый параметр температуры. Применяется симметричная контрастная функция потерь, аналогичная [34]:

$$\mathcal{L}_{\text{contr}} = -\frac{1}{2B} \sum_{b=0}^{B-1} \left[ \log \frac{\exp(\mathbf{L}_{bb})}{\sum_{j=0}^{B-1} \exp(\mathbf{L}_{bj})} + \log \frac{\exp(\mathbf{L}_{bb})}{\sum_{i=0}^{B-1} \exp(\mathbf{L}_{ib})} \right]. \quad (24)$$

Оптимизируются параметры  $\mathcal{E}_f$ ,  $\mathcal{E}_e$ ,  $\mathcal{F}$  и  $\tau$ ; параметры  $\phi$  остаются замороженными. Иллюстрация формирования батча и логитов приведена на рис. 3.

**Метрика качества реконструкции.** Качество реконструированного изображения  $\hat{\mathbf{I}} = \mathbf{f}(\mathbf{F}, \mathbf{E})$  относительно истинного стимула  $\mathbf{I}$  оценивается метрикой CLIP-Score — косинусной близостью в пространстве визуальных эмбедингов:

$$\text{CLIP-Score}(\hat{\mathbf{I}}, \mathbf{I}) = \frac{\langle \phi(\hat{\mathbf{I}}), \phi(\mathbf{I}) \rangle}{\|\phi(\hat{\mathbf{I}})\| \cdot \|\phi(\mathbf{I})\|}. \quad (25)$$

Чем выше CLIP-Score, тем ближе семантическое содержание реконструкции к содержанию исходного стимула. Метрика ориентирована на семантический уровень и не чувствительна к пиксельным деталям; это ограничение обсуждается в Главе 4..




Рис. 3: Контрастивное обучение комбинированного представления фМРТ-ЭЭГ. Положительные пары расположены на главной диагонали матрицы логитов размера  $B \times B$ , остальные  $B(B - 1)$  пар используются как отрицательные примеры

### 3.4. Двухстадийная диффузионная генерация изображения

Восстановление изображения  $\hat{\mathbf{I}}$  по комбинированному эмбедингу  $\mathbf{Z}_c$  выполняется в два этапа. Формально вводится совместное распределение изображения  $\mathbf{x}$  и его CLIP-эмбединга  $\mathbf{z}_I$  при условии нейронного представления  $\mathbf{z}_c$ :

$$p(\mathbf{x}, \mathbf{z}_I \mid \mathbf{z}_c) = p(\mathbf{z}_I \mid \mathbf{z}_c) \cdot p(\mathbf{x} \mid \mathbf{z}_I).$$

Первый сомножитель моделируется априорной диффузионной моделью в CLIP-пространстве, второй — предобученной латентно-диффузионной моделью генерации изображений.

**Стадия I: априорная диффузионная модель.** Цель априорной модели — уточнить контрастивно обученный эмбединг  $\mathbf{Z}_c$  до согласованного с распределением CLIP-эмбедингов реальных изображений представления  $\hat{\mathbf{Z}}_I$ . В пространстве CLIP-эмбедингов обучается лёгкая диффузионная модель вида

$$\epsilon_\theta(\mathbf{z}_I^{(t)}, t, \mathbf{z}_c), \quad (26)$$

где  $\mathbf{z}_I^{(t)}$  — зашумлённая версия истинного эмбединга  $\mathbf{z}_I$  на шаге  $t$  прямого диффузионного процесса. Обучение проводится по схеме DDPM [52] с функцией потерь

$$\mathcal{L}_{\text{prior}}(\boldsymbol{\theta}) = \mathbb{E}_{\mathbf{z}_I, \mathbf{z}_c, t, \epsilon} \left\| \epsilon - \epsilon_{\boldsymbol{\theta}}(\mathbf{z}_I^{(t)}, t, \mathbf{z}_c) \right\|_2^2. \quad (27)$$

На этом этапе параметры  $\mathcal{E}_f$ ,  $\mathcal{E}_e$ ,  $\mathcal{F}$  остаются замороженными. На этапе исполнения априорная модель порождает оценку  $\hat{\mathbf{Z}}_I \approx \mathbf{Z}_I$  итеративной процедурой расшумления, начиная с шумного  $\mathbf{z}_I^{(T)}$  и используя  $\mathbf{z}_c$  как условие.

**Стадия II: генерация изображения.** Финальная реконструкция изображения выполняется предобученной латентно-диффузионной моделью Stable Diffusion XL [40]:

$$\epsilon_{\phi}(\mathbf{x}^{(t)}, t, h(\hat{\mathbf{Z}}_I)), \quad (28)$$

где  $\mathbf{x}^{(t)}$  — зашумлённое латентное представление изображения на шаге  $t$ , а  $h$  — адаптер IP-Adapter [41], переводящий  $\hat{\mathbf{Z}}_I$  в формат условия, совместимый с SDXL. Параметры  $\phi$  и  $h$  не дообучаются.

### 3.5. Итоговая схема и личный вклад

Предложенный метод сводится к следующей последовательности шагов: предобработка фМРТ и ЭЭГ с построением индивидуальных бинарных масок мозга (9); решение обратной задачи (7) для оценки  $\Delta t$  и формирование триплетов  $(\mathbf{F}_i, \mathbf{E}_i, \mathbf{I}_i)$  согласно (6); контрастивное обучение энкодеров  $\mathcal{E}_f$ ,  $\mathcal{E}_e$  и модуля объединения  $\mathcal{F}$  с функцией потерь (24); обучение априорной диффузионной модели (26) в CLIP-пространстве; реконструкция изображения предобученной SDXL (28) с обусловливанием на  $\hat{\mathbf{Z}}_I$ .

Личный вклад автора в данной главе: формализация компонента предобработки с учётом  $\Delta t$  как связующего звена между обратной задачей и контрастивным обучением; проектирование архитектуры мультимодального энкодера (21) и согласованной схемы обучения. Готовыми взяты замороженный визуальный энкодер CLIP [34], предобученная SDXL [40], IP-Adapter [41] и схема DDPM [52].

## 4. Вычислительный эксперимент

Вычислительный эксперимент состоит из двух частей. Первая часть (раздел 4.1.) проводится на наборе данных [19] и предназначена для оценки гемодинамической задержки  $\Delta t$  и проверки корректности линейной модели, использованной при предобработке (Глава 3., раздел 3.1.). Вторая часть (раздел 4.2.) проводится на основном наборе данных [14] и предназначена для количественной проверки предложенной двумодальной архитектуры.

### 4.1. Оценка гемодинамической задержки и устойчивость линейной модели

**Набор данных и протокол.** Используется набор данных [19], содержащий результаты обследования 63 испытуемых, из которых для 30 доступны записи фМРТ. Все испытуемые во время регистрации смотрят один и тот же аудиовизуальный фрагмент. Параметры выборки приведены в табл. 1; пример данных приведён на рис. 4. Выборка разделена в отношении 70%/30% на обучающую и тестовую. На обучающей выборке вычисляется матрица параметров  $\hat{\mathbf{W}}$  (17), по которой авторегрессионно прогнозируются фМРТ-сканы тестовой выборки согласно (18). Метрика качества — MSE между  $\hat{\mathbf{F}}_\ell$  и истинным  $\mathbf{F}_\ell$ , усреднённое по вокселям. Коэффициент регуляризации зафиксирован на значении  $\alpha = 1000$ . Значения вокселей нормализуются на отрезок  $[0; 1]$  по статистикам обучающей выборки. Конфигурация вычислительной системы приведена в табл. 2.

Таблица 1: Параметры выборки

| Параметр                  | Обозначение | Значение    |
|---------------------------|-------------|-------------|
| Длительность записи       | $t$         | 390 с       |
| Частота кадров видео      | $\nu$       | 25 Гц       |
| Частота сканирования фМРТ | $\mu$       | 1,64 Гц     |
| Размеры видеокадра        | $W, H, C$   | 640, 480, 3 |
| Размеры фМРТ-скана        | $X, Y, Z$   | 40, 64, 64  |

**Пример прогноза.** На рис. 5 приведены срезы истинного и предсказанного фМРТ-сканов для испытуемого 7 при  $\Delta t = 5$  с. Поскольку значения вокселей нормализованы на  $[0; 1]$ , ошибка порядка  $10^{-3}$  соответствует достаточно точному прогнозу.




Рис. 4: Визуализация данных из [19]. Слева — три выбранных видеокадра, справа — срезы фМРТ-сканов в соответствующие моменты для трёх испытуемых. Поскольку частота кадров видео выше частоты сканирования, каждому скану соответствует группа кадров

Таблица 2: Конфигурация вычислительной системы для эксперимента по оценке  $\Delta t$

| Компонент  | Описание                     |
|------------|------------------------------|
| CPU        | Intel Core i7-7700 3,6 ГГц   |
| GPU        | NVIDIA GeForce GTX 1060 3 ГБ |
| RAM        | 16 ГБ 2400 МГц               |
| Накопитель | M.2 SSD                      |
| ОС         | Windows 10                   |

**Зависимость качества прогноза от  $\Delta t$ .** Исследована зависимость ошибки MSE от гиперпараметра  $\Delta t$  на испытуемом 47. Левый график рис. 7 показывает зависимость, вычисленную на всех вокселях скана: чёткий минимум не наблюдается, поскольку доля фоновых и неактивированных вокселей вносит существенный шум. Для устранения этой шумовой составляющей локализуется затылочная доля — область, ответственная за обработку визуальной информации [51]; из локализованного объёма выбираются 3% наиболее изменчивых вокселей (отсортированных по убыванию суммарного абсолютного изменения значений (8)). Правый график рис. 7 демонстрирует чёткий минимум при  $\Delta t \approx 5$  с, что согласуется с известным диапазоном гемодинамической задержки BOLD-сигнала [10].




Рис. 5: Срезы фМРТ-сканов из тестовой выборки. Истинный и прогнозируемый сканы, а также их попиксельная разность. Ошибка порядка  $10^{-3}$  свидетельствует о точности прогноза

Локализация затылочной доли проиллюстрирована на рис. 6. Полученное значение  $\Delta t = 5$  с фиксируется и используется в основном эксперименте при формировании триплетов согласно (6).




Рис. 6: Локализация наиболее активной зоны при просмотре видеостимула. Выделенная область — затылочная доля, что подтверждает корректность локализации

**Распределение весов линейной модели.** Для проверки осмысленности обученной модели исследовано распределение компонентов вектора весов  $\hat{\mathbf{w}}_{ijk}$  из (16), усреднённое по всем вокселям испытуемого 4 (рис. 8). Распределение не сосредоточено около одного значения, что свидетельствует о невырожденности модели и согласуется с интерпретацией: при просмотре видеостимула внимание испытуемого направлено на различные элементы кадра, и линейная модель отражает это в неоднородной структуре весов по компонентам визуального эмбединга.




Рис. 7: Зависимость MSE от гемодинамической задержки  $\Delta t$ . Слева — расчёт на всех вокселях скана: чёткий минимум отсутствует из-за вклада фоновых вокселей. Справа — расчёт на 3% наиболее изменчивых вокселей затылочной доли: наблюдается чёткий минимум при  $\Delta t \approx 5$  с




Рис. 8: Распределение компонент вектора весов линейной модели. Невырожденность распределения свидетельствует о том, что модель захватывает разнообразные визуальные признаки

**Инвариантность весов относительно испытуемых.** Проверяется гипотеза о том, что веса линейной модели (14) инвариантны относительно испытуемых: матрица  $\hat{\mathbf{W}}$ , обученная на одном испытуемом, может использоваться для прогнозирования фМРТ другого без существенной потери качества. Для пары испытуемых 4 и 7 значения MSE при использовании «своей» и «чужой» матрицы весов практически совпадают (табл. 3).



Таблица 3: Проверка инвариантности весов линейной модели для пары испытуемых 4 и 7

| Матрица весов | Своя                   | Чужая (от другого испытуемого) | Разность             |
|---------------|------------------------|--------------------------------|----------------------|
| MSE           | $6,3912 \cdot 10^{-5}$ | $6,3911 \cdot 10^{-5}$         | $1,37 \cdot 10^{-9}$ |

Эксперимент проведён для всех пар испытуемых; результаты сведены в тепловую карту (рис. 9): для каждой пары вычислена MAPE между «своим» MSE (с собственной матрицей весов) и «чужим» MSE (с матрицей весов другого испытуемого). Отклонения порядка 1% подтверждают гипотезу: линейная модель захватывает универсальную часть связи между видеостимулом и BOLD-откликом, общую для разных испытуемых. Этот результат поддерживает обоснованность фиксации единого значения  $\Delta t$  при предобработке триплетов основного эксперимента.




Рис. 9: Тепловая карта MAPE при подмене матрицы весов. Каждая строка и каждый столбец соответствуют испытуемому. Положительные значения означают, что использование чужой матрицы увеличивает MSE относительно своей

**Контроль на неинформативных признаках.** Для подтверждения того, что модель действительно использует визуальную информацию из видеокладов, а не подгоняется к структуре приращений фМРТ, проведён следующий эксперимент. Матрица визуальных эмбеддингов  $\Psi$  заменяется на матрицу из единиц (неинформативные признаки), после чего модель переобучается по (16) и используется для авторегрессионного прогноза (18) последнего фМРТ-скана тестовой выборки путём суммирования прогнозируемых приращений начиная с

первого скана. На рис. 10 приведены результаты для исходных видеопризнаков, на рис. 11 — для неинформативных. Численные результаты (испытываемый 35) представлены в табл. 4: MSE на неинформативных признаках почти в четыре раза больше, что подтверждает наличие значимой корреляции между видеостимулом и BOLD-сигналом.




Рис. 10: Срезы фМРТ-сканов из тестовой выборки при использовании оригинальных видеопризнаков




Рис. 11: Срезы фМРТ-сканов при использовании неинформативных признаков. MSE существенно выше, что подтверждает значимость видеопризнаков

Таблица 4: Сравнение качества прогноза при использовании оригинальных и неинформативных признаков

| Признаки | Оригинальные         | Неинформативные      | Разность             |
|----------|----------------------|----------------------|----------------------|
| MSE      | $3,67 \cdot 10^{-4}$ | $1,39 \cdot 10^{-3}$ | $1,02 \cdot 10^{-3}$ |

**Выводы по эксперименту с линейной моделью.** Эксперименты на наборе данных [19] подтверждают: значимая корреляция между видеостимулом и BOLD-сигналом (качество прогноза на оригинальных видеопризнаках существенно превышает качество на неинформативных); оценка гемодинамической задержки  $\Delta t \approx 5$  с, согласующаяся с известным медицинским диапазоном [10]; инвариантность весов линейной модели относительно испытуемых, что обосновывает использование единого значения  $\Delta t$  для всех испытуемых при формировании триплетов основного эксперимента; невырожденное распределение весов модели, согласующееся с содержательной интерпретацией. Полученное значение  $\Delta t = 5$  с фиксируется при предобработке триплетов основного эксперимента (раздел 4.2.).

## 4.2. Мультимодальная реконструкция изображений

**Набор данных.** В качестве основного набора данных используется открытый набор с одновременной регистрацией фМРТ и ЭЭГ при предъявлении визуальных стимулов [14]. В набор включены 22 здоровых испытуемых в возрасте 23–51 года; каждый испытуемый прошёл два сканирования. Стимулы охватывают состояние покоя, мерцающее шахматное поле, абстрактную анимацию Inscapes (компьютерно сгенерированную последовательность трёхмерных фигур с плавными переходами), а также короткие видеоролики: фрагменты мультфильмов *The Present* и *Despicable Me* и фрагменты документальных фильмов с обезьянами. Натуралистический характер стимулов способствует устойчивому межсубъектному нейронному отклику. Синхронизация модальностей обеспечивается записью триггеров сканера в поток ЭЭГ. Предобработка модальностей выполняется согласно процедуре, описанной в Главе 3. (раздел 3.1.). Параметры регистрации приведены в табл. 5. Пример индивидуальной маски мозга, построенной алгоритмом Оцу, приведён на рис. 12. Триплеты  $(\mathbf{F}_i, \mathbf{E}_i, \mathbf{I}_i)$  формируются с учётом фиксированной гемодинамической задержки  $\Delta t = 5$  с согласно (6), обоснованной экспериментом раздела 4.1..

Таблица 5: Параметры регистрации модальностей в наборе данных [14]

| Модальность | Оборудование               | Частота дискретизации | Каналы                        |
|-------------|----------------------------|-----------------------|-------------------------------|
| ЭЭГ         | Brain Products BrainCap MR | 5000 Гц               | 61 кортикальный электрод      |
| фМРТ        | Siemens 3.0 T TIM Trio     | 0,476 Гц              | 12-канальная головная катушка |




Рис. 12: Индивидуальная бинарная маска мозга для одного из испытуемых. Включённые в маску воксели выделены красным цветом. Маска формируется на основе наиболее изменчивых вокселей во времени и удаляет фоновые воксели, не несущие информации о визуальном стимуле

**Параметры энкодеров.** *Энкодер  $fMPT$ :* индивидуальная линейная проекция отображает векторизованные воксели, отобранные бинарной маской испытуемого, в латентное пространство размерности 4096; далее остаточный MLP с тремя полносвязными слоями последовательно  $4096 \rightarrow 2048 \rightarrow 2048 \rightarrow 1024$ , нелинейностью GELU, нормализацией по слою и dropout с вероятностью 0,1; размерность выходного эмбединга  $d_f = 1024$ . *Энкодер ЭЭГ:* вход — тензор размера  $61 \times 525$  (60 каналов корковых электродов и один канал индивидуального обучаемого эмбединга испытуемого); три свёртки (временная с ядром  $(1, 32)$  и 256 фильтрами, пространственная с ядром  $(61, 1)$  и 512 фильтрами, глобальная с ядром  $(1, 525)$  и 1024 фильтрами); MLP-голова  $1024 \rightarrow 2048 \rightarrow 1024$ ; размерность выходного эмбединга  $d_e = 1024$ . *Модуль объединения:* двухслойный MLP, конкатенированное представление размерности 2048 расширяется до 4096 и сжимается до целевой размерности  $d = 1024$ , совпадающей с размерностью CLIP-пространства.

**Качественное сравнение реконструкций.** Качественное сравнение реконструкций приведено на рис. 13. Строки соответствуют различным режимам: (1) исходный визуальный стимул; (2) реконструкция из CLIP-эмбединга исходного изображения через предобученную SDXL, представляющая верхнюю границу качества, достижимую в выбранной схеме генерации; (3) реконструкция предложенным методом без априорной диффузионной модели; (4) реконструкция предложенным методом с априорной диффузионной моделью. Включение априорной диффузионной модели визуально повышает семантическое соответствие

реконструкции исходному стимулу.



Рис. 13: Качественное сравнение реконструкций изображений по сигналам фМРТ-ЭЭГ. Строки: (1) исходный стимул; (2) предельное качество (SDXL по CLIP-эмбедингу оригинала); (3) предложенный метод без априорной диффузионной модели; (4) предложенный метод с априорной диффузионной моделью

**Количественное сравнение и ablation.** Для количественной оценки используется метрика CLIP-Score (25). Метрики вычислялись на тестовой выборке из видеостимулов *monkey1*, *monkey2*, *monkey5* с усреднением по 22 испытуемым и по объектам. Сравниваются шесть конфигураций: (1) **ЭЭГ** — только энкодер  $\mathcal{E}_e$ , модуль объединения отключен,  $\mathbf{Z}_e$  напрямую используется как условие для генерации, априорная модель не применяется; (2) **фМРТ** — аналогично с энкодером  $\mathcal{E}_f$ ; (3) **фМРТ-ЭЭГ** — оба энкодера и модуль объединения, без априорной модели; (4) **ЭЭГ & Diffusion Prior** — энкодер ЭЭГ с априорной диффузионной моделью; (5) **фМРТ & Diffusion Prior** — энкодер фМРТ с априорной диффузионной моделью; (6) **фМРТ-ЭЭГ & Diffusion Prior** — полная архитектура. Результаты сведены в табл. 6.

Двумодальная архитектура (фМРТ-ЭЭГ) систематически превосходит обе одномодальные конфигурации на всех трёх видеостимулах, что подтверждает гипотезу о комплементарности пространственной информации фМРТ и временной информации ЭЭГ. Включение априорной диффузионной модели повышает CLIP-Score для всех конфигураций приблизительно вдвое; этот эффект согласуется с наблюдениями в одномодальной литературе [9]: априорная модель устраняет разрыв между распределением контрастивно обученных нейронных эмбедин-

Таблица 6: Метрика CLIP-Score для шести конфигураций модели на трёх видеостимулах. Усреднение по 22 испытуемым; нижним индексом указаны стандартные отклонения. Наилучший результат в столбце выделен жирным шрифтом

| Конфигурация               | Видеостимул              |                          |                          |
|----------------------------|--------------------------|--------------------------|--------------------------|
|                            | monkey1                  | monkey2                  | monkey5                  |
| ЭЭГ                        | 0,231 $\pm$ 0,004        | 0,262 $\pm$ 0,004        | 0,224 $\pm$ 0,005        |
| фМРТ                       | 0,254 $\pm$ 0,004        | 0,270 $\pm$ 0,003        | 0,242 $\pm$ 0,003        |
| фМРТ-ЭЭГ                   | 0,310 $\pm$ 0,003        | 0,312 $\pm$ 0,004        | 0,284 $\pm$ 0,003        |
| ЭЭГ & Diffusion Prior      | 0,542 $\pm$ 0,005        | 0,557 $\pm$ 0,003        | 0,538 $\pm$ 0,003        |
| фМРТ & Diffusion Prior     | 0,564 $\pm$ 0,005        | 0,571 $\pm$ 0,004        | 0,551 $\pm$ 0,005        |
| фМРТ-ЭЭГ & Diffusion Prior | <b>0,668</b> $\pm$ 0,003 | <b>0,647</b> $\pm$ 0,005 | <b>0,644</b> $\pm$ 0,003 |

гов и распределением CLIP-эмбеддингов реальных изображений. Наилучшее качество достигается в полной конфигурации (фМРТ-ЭЭГ & Diffusion Prior).

**Достоверность и ограничения.** Достоверность представленных результатов обеспечивается следующими факторами: использование открытого набора данных с протоколом, прошедшим этическую экспертизу; усреднение по 22 испытуемым с указанием стандартных отклонений; систематическое ablation-сравнение шести конфигураций; сравнение с верхней границей качества, достижимой при условии на CLIP-эмбеддинг исходного изображения (рис. 13, строка 2); независимая проверка корректности значения  $\Delta t$  на отдельном наборе данных (раздел 4.1.). Использование CLIP-пространства в качестве промежуточного представления ограничивает реконструкцию семантическим уровнем: точное восстановление пиксельных деталей, текстур или низкоуровневых визуальных характеристик не гарантируется. Экспериментальная проверка проведена на одном датасете с видеостимулами определённого типа; перенос результатов на статичные изображения, абстрактные паттерны или иные условия регистрации требует дополнительной валидации. Метод обучен и протестирован на данных здоровых испытуемых; применение к пациентам с патологиями зрительной системы или нарушениями когнитивных функций выходит за рамки настоящей работы.



## Заключение

Цель исследования — разработка метода реконструкции визуальных стимулов по одновременным записям фМРТ и ЭЭГ, использующего пространственно-временные характеристики обеих модальностей.

### Соответствие задач результатам.

1. *Систематизация существующих подходов.* Глава 1. содержит структурированный анализ предметной области по идеям и инженерным решениям. Выделены два пробела в существующих работах: отсутствие двумодальных архитектур фМРТ–ЭЭГ для декодирования визуальных стимулов и отсутствие формализованного учёта гемодинамической задержки при формировании обучающих триплетов.
2. *Формализация задачи.* Глава 2. вводит совместное пространство  $\mathcal{X}_f \times \mathcal{X}_e$ , обучающую выборку триплетов с поправкой на гемодинамическую задержку  $\Delta t$  и целевое отображение  $\mathbf{f} : \mathcal{X}_f \times \mathcal{X}_e \rightarrow \mathcal{Y}$ , оцениваемое метрикой CLIP-Score.
3. *Разработка метода.* Глава 3. описывает четыре компонента метода: предобработку с учётом  $\Delta t$ , архитектуру мультимодального энкодера  $(\mathcal{E}_f, \mathcal{E}_e, \mathcal{F})$ , контрастивное обучение с замороженным CLIP и двухстадийную диффузионную генерацию (априорная модель в CLIP-пространстве + предобученная SDXL с IP-Adapter).
4. *Экспериментальная проверка.* Глава 4. приводит две группы экспериментов. На вспомогательном наборе данных [19] оценено значение  $\Delta t \approx 5$  с, подтверждена инвариантность весов линейной модели относительно испытуемых и значимость видеопризнаков. На основном наборе данных [14] двумодальная конфигурация с априорной диффузионной моделью достигла CLIP-Score 0,644–0,668 и превзошла одномодальные аналоги.

### Основные результаты.

- Формализована задача двумодального декодирования визуальных стимулов с явным учётом гемодинамической задержки BOLD-сигнала при формировании обучающих триплетов.

- Предложена и реализована архитектура мультимодального энкодера, обучаемая контрастивно относительно CLIP-пространства, в сочетании с двухстадийной диффузионной генерацией.
- Получено эмпирическое подтверждение комплементарности модальностей: CLIP-Score двумодальной конфигурации систематически превышает CLIP-Score одномодальных конфигураций на всех трёх видеостимулах.
- Получено эмпирическое подтверждение значения гемодинамической задержки  $\Delta t \approx 5$  с на независимом наборе данных и инвариантности линейной модели относительно испытуемых.

### **Элементы научной новизны.**

- Двумодальная архитектура декодирования визуальных стимулов по одновременным сигналам фМРТ–ЭЭГ с обучаемым модулем объединения модальностей.
- Компонент препроцессинга, явно учитывающий гемодинамическую задержку при формировании обучающих триплетов.
- Систематическое ablation-сравнение шести конфигураций (две модальности  $\times$  три модальностных режима), количественно подтверждающее преимущество совместного использования модальностей и пользу априорной диффузионной модели.

**Теоретическая значимость** результатов состоит в эмпирическом подтверждении взаимодополнительности пространственной информации фМРТ и временной информации ЭЭГ в задаче визуального декодирования, а также в формализации связи между гемодинамической задержкой BOLD-сигнала и качеством контрастного выравнивания нейронных представлений с CLIP-пространством.

**Практическая значимость.** Разработанный метод применим в исследованиях интерфейсов мозг–компьютер для визуального декодирования, в инструментах семантической реконструкции зрительной информации и в анализе нейронных откликов на натуралистические видеостимулы. Использование открытых наборов данных и общедоступных предобученных компонентов (CLIP, SDXL, IP-Adapter) обеспечивает воспроизводимость и переносимость подхода.



**Ограничения работы.** Реконструкция через CLIP-пространство обеспечивает семантическую близость, но не гарантирует пиксельной точности. Экспериментальная проверка проведена на одном основном наборе данных [14]; перенос на иные типы стимулов и условия регистрации требует дополнительной валидации. Метод обучен и оценён на данных здоровых испытуемых; применение к пациентам с патологиями зрительной системы остаётся за рамками работы.

**Направления дальнейших исследований.**

- Расширение экспериментальной части на статичные изображения, абстрактные паттерны и иные типы стимулов; валидация на дополнительных наборах данных одновременной регистрации фМРТ–ЭЭГ.
- Введение дополнительных метрик качества реконструкции, чувствительных к пиксельному уровню (например, LPIPS, SSIM, FID), в дополнение к CLIP-Score.
- Переход к нелинейным моделям оценки гемодинамической задержки, способным учитывать индивидуальные особенности BOLD-отклика и зависимость  $\Delta t$  от области коры.
- Расширение модуля объединения модальностей: трансформер с кросс-вниманием, динамическое взвешивание модальностей в зависимости от типа стимула.
- Валидация на пациентах с нарушениями зрительной системы как потенциальная клиническая основа.

## Список литературы

1. Brain-computer interface technology: a review of the first international meeting / Jonathan R Wolpaw, Niels Birbaumer, William J Heetderks et al. // *IEEE transactions on rehabilitation engineering*. — 2000. — Vol. 8, no. 2. — Pp. 164–173. — URL: <https://doi.org/10.1109/TRE.2000.847807>.
2. Mining event-related brain dynamics / Scott Makeig, Stefan Debener, Julie Onton, Arnaud Delorme // *Trends in cognitive sciences*. — 2004. — Vol. 8, no. 5. — Pp. 204–210. — URL: <https://doi.org/10.1016/j.tics.2004.03.008>.
3. McFarland Dennis J. Brain-computer interfaces for communication and control // *Clin. Neurophysiol.* — 2002. — Vol. 113. — Pp. 767–791. — URL: [https://doi.org/10.1016/S1388-2457\(02\)00057-3](https://doi.org/10.1016/S1388-2457(02)00057-3).
4. Assistive Mobile Robot with Shared Control of Brain-Machine Interface and Computer Vision / Yonghao Song, Weifeng Wu, Chengqi Lin et al. // 2020 IEEE 4th Information Technology, Networking, Electronic and Automation Control Conference (ITNEC) / IEEE. — Vol. 1. — 2020. — Pp. 405–409. — URL: <https://doi.org/10.1109/ITNEC48623.2020.9085096>.
5. A self-paced BCI with a collaborative controller for highly reliable wheelchair driving: Experimental tests with physically disabled individuals / Aniana Cruz, Gabriel Pires, Ana Lopes et al. // *IEEE Transactions on Human-Machine Systems*. — 2021. — Vol. 51, no. 2. — Pp. 109–119. — URL: <https://doi.org/10.1109/THMS.2020.3047597>.
6. Decoding hand movements from human EEG to control a robotic arm in a simulation environment / Andreas Schwarz, Maria Katharina Höller, Joana Pereira et al. // *Journal of neural engineering*. — 2020. — Vol. 17, no. 3. — P. 036010. — URL: <https://doi.org/10.1088/1741-2552/ab882e>.
7. fmri-based decoding of visual information from human brain activity: A brief review / Shuo Huang, Wei Shao, Mei-Ling Wang, Dao-Qiang Zhang // *International Journal of Automation and Computing*. — 2021. — Vol. 18, no. 2. — Pp. 170–184.

8. Visual Decoding and Reconstruction via EEG Embeddings with Guided Diffusion / Dongyang Li, Chen Wei, Shiyong Li et al. // Advances in Neural Information Processing Systems / Ed. by A. Globerson, L. Mackey, D. Belgrave et al. — Vol. 37. — Curran Associates, Inc., 2024. — Pp. 102822–102864. — URL: [https://proceedings.neurips.cc/paper\\_files/paper/2024/file/ba5f1233efa77787ff9ec015877dbd1f-Paper-Conference.pdf](https://proceedings.neurips.cc/paper_files/paper/2024/file/ba5f1233efa77787ff9ec015877dbd1f-Paper-Conference.pdf).
9. *Scotti Paul S., Banerjee Atmadeep, Goode Jimmie et al.* Reconstructing the Mind's Eye: fMRI-to-Image with Contrastive Learning and Diffusion Priors. — 2023. — URL: <https://arxiv.org/abs/2305.18274>.
10. Time course EPI of human brain function during task activation / Peter A. Bandettini, Eric C. Wong, R. Scott Hinks et al. // *Magnetic Resonance in Medicine*. — 1992. — . — Vol. 25, no. 2. — Pp. 390–397. — URL: <http://dx.doi.org/10.1002/mrm.1910250220>.
11. *Logothetis Nikos K.* The Underpinnings of the BOLD Functional Magnetic Resonance Imaging Signal // *The Journal of Neuroscience*. — 2003. — . — Vol. 23, no. 10. — Pp. 3963–3971. — URL: <https://doi.org/10.1523/jneurosci.23-10-03963.2003>.
12. *Srinivasan Ramesh.* Methods to improve the spatial resolution of EEG.
13. *Schlögl Alois, Slater Mel, Pfurtscheller Gert.* Presence research and EEG. — 2002. — 01.
14. An open-access dataset of naturalistic viewing using simultaneous EEG-fMRI / Qawi K. Telesford, Eduardo Gonzalez-Moreira, Ting Xu et al. // *Scientific Data*. — 2023. — . — Vol. 10, no. 1. — URL: <http://dx.doi.org/10.1038/s41597-023-02458-8>.
15. *Ozcelik Furkan, VanRullen Rufin.* Natural scene reconstruction from fMRI signals using generative latent diffusion. — 2023. — URL: <https://arxiv.org/abs/2303.05334>.
16. *Chen Zijiao, Qing Jiaxin, Zhou Juan Helen.* Cinematic Mindscapes: High-quality Video Reconstruction from Brain Activity. — 2023. — URL: <https://arxiv.org/abs/2305.11675>.

17. NeuroGAN: image reconstruction from EEG signals via an attention-based GAN / Rahul Mishra, Krishan Sharma, R. R. Jha, Arnav Bhavsar // *Neural Computing and Applications*. — 2022. — . — URL: <http://dx.doi.org/10.1007/s00521-022-08178-1>.
18. Singh Prajwal, Pandey Pankaj, Miyapuram Krishna, Raman Shanmuganathan. EEG2IMAGE: Image Reconstruction from EEG Brain Signals. — 2023. — URL: <https://arxiv.org/abs/2302.10121>.
19. Open multimodal iEEG-fMRI dataset from naturalistic stimulation with a short audiovisual film / Julia Berezutskaya, Mariska J. Vansteensel, Erik J. Aarnoutse et al. // *Scientific Data*. — 2022. — . — Vol. 9, no. 1. — URL: <https://doi.org/10.1038/s41597-022-01173-0>.
20. Forecasting fMRI images from video sequences: linear model analysis / Daniel Dorin, Nikita Kiselev, Andrey Grabovoy, Vadim Strijov // *Health Information Science and Systems*. — 2024. — Vol. 12, no. 1. — P. 55. — URL: <https://doi.org/10.1007/s13755-024-00315-5>.
21. Glover Gary H. Overview of Functional Magnetic Resonance Imaging // *Neurosurgery Clinics of North America*. — 2011. — . — Vol. 22, no. 2. — Pp. 133–139. — URL: <https://doi.org/10.1016/j.nec.2010.11.001>.
22. Brain magnetic resonance imaging with contrast dependent on blood oxygenation. / S Ogawa, T M Lee, A R Kay, D W Tank // *Proceedings of the National Academy of Sciences*. — 1990. — . — Vol. 87, no. 24. — Pp. 9868–9872. — URL: <http://dx.doi.org/10.1073/pnas.87.24.9868>.
23. Intrinsic signal changes accompanying sensory stimulation: functional brain mapping with magnetic resonance imaging. / S Ogawa, D W Tank, R Menon et al. // *Proceedings of the National Academy of Sciences*. — 1992. — . — Vol. 89, no. 13. — Pp. 5951–5955. — URL: <http://dx.doi.org/10.1073/pnas.89.13.5951>.
24. Le Bihan Denis, Karni Avi. Applications of magnetic resonance imaging to the study of human brain function // *Current Opinion in Neurobiology*. — 1995. — Vol. 5, no. 2. — Pp. 231–237. — URL: <https://www.sciencedirect.com/science/article/pii/095943889580031X>.

25. Functional mapping of activated human primary cortex with a clinical MR imaging system. / A Connelly, G D Jackson, R S Frackowiak et al. // *Radiology*. — 1993. — . — Vol. 188, no. 1. — Pp. 125–130. — URL: <http://dx.doi.org/10.1148/radiology.188.1.8511285>.
26. Dynamic magnetic resonance imaging of human brain activity during primary sensory stimulation. / K K Kwong, J W Belliveau, D A Chesler et al. // *Proceedings of the National Academy of Sciences*. — 1992. — . — Vol. 89, no. 12. — Pp. 5675–5679. — URL: <http://dx.doi.org/10.1073/pnas.89.12.5675>.
27. Menon Ravi S, Kim Seong-Gi. Spatial and temporal limits in cognitive neuroimaging with fMRI // *Trends in cognitive sciences*. — 1999. — Vol. 3, no. 6. — Pp. 207–216. — URL: [https://doi.org/10.1016/s1364-6613\(99\)01329-7](https://doi.org/10.1016/s1364-6613(99)01329-7).
28. Logothetis Nikos K. What we can do and what we cannot do with fMRI // *Nature*. — 2008. — Vol. 453, no. 7197. — Pp. 869–878. — URL: <https://doi.org/10.1038/nature06976>.
29. Learning a common dictionary for subject-transfer decoding with resting calibration / Hiroshi Morioka, Atsunori Kanemura, Jun-ichiro Hirayama et al. // *NeuroImage*. — 2015. — Vol. 111. — Pp. 167–178.
30. Transfer learning in brain-computer interfaces / Vinay Jayaram, Morteza Alamgir, Yasemin Altun et al. // *IEEE Computational Intelligence Magazine*. — 2016. — Vol. 11, no. 1. — Pp. 20–31.
31. Ritter Petra, Villringer Arno. simultaneous EEG–fMRI // *Neuroscience & Biobehavioral Reviews*. — 2006. — Vol. 30, no. 6. — Pp. 823–838.
32. Removal of FMRI environment artifacts from EEG data using optimal basis sets / Rami K Niazy, Christian F Beckmann, Gian Domenico Iannetti et al. // *Neuroimage*. — 2005. — Vol. 28, no. 3. — Pp. 720–737.
33. Methods for simultaneous EEG–fMRI: an introductory review / René J Huster, Stefan Debener, Tom Eichele, Christoph S Herrmann // *Journal of Neuroscience*. — 2012. — Vol. 32, no. 18. — Pp. 6053–6060.

34. Learning transferable visual models from natural language supervision / Alec Radford, Jong Wook Kim, Chris Hallacy et al. // International conference on machine learning / PMLR. — 2021. — Pp. 8748–8763.
35. Audio–text retrieval based on contrastive learning and collaborative attention mechanism / Tao Hu, Xuyu Xiang, Jiaohua Qin, Yun Tan // *Multimedia Systems*. — 2023. — Vol. 29, no. 6. — Pp. 3625–3638.
36. Connecting multi-modal contrastive representations / Zehan Wang, Yang Zhao, Haifeng Huang et al. // *Advances in Neural Information Processing Systems*. — 2023. — Vol. 36. — Pp. 22099–22114.
37. *Esser Patrick, Rombach Robin, Ommer Björn*. Taming Transformers for High-Resolution Image Synthesis. — 2021. — URL: <https://arxiv.org/abs/2012.09841>.
38. *Hatamizadeh Ali, Song Jiaming, Liu Guilin et al*. DiffiT: Diffusion Vision Transformers for Image Generation. — 2024. — URL: <https://arxiv.org/abs/2312.02139>.
39. *Crowson Katherine, Biderman Stella, Kornis Daniel et al*. VQGAN-CLIP: Open Domain Image Generation and Editing with Natural Language Guidance. — 2022. — URL: <https://arxiv.org/abs/2204.08583>.
40. *Podell Dustin, English Zion, Lacey Kyle et al*. SDXL: Improving Latent Diffusion Models for High-Resolution Image Synthesis. — 2023. — URL: <https://arxiv.org/abs/2307.01952>.
41. *Ye Hu, Zhang Jun, Liu Sibao et al*. IP-Adapter: Text Compatible Image Prompt Adapter for Text-to-Image Diffusion Models. — 2023. — URL: <https://arxiv.org/abs/2308.06721>.
42. *Caron Mathilde, Touvron Hugo, Misra Ishan et al*. Emerging Properties in Self-Supervised Vision Transformers. — 2021. — URL: <https://arxiv.org/abs/2104.14294>.
43. *Simonyan Karen, Zisserman Andrew*. Very Deep Convolutional Networks for Large-Scale Image Recognition. — 2015. — URL: <https://arxiv.org/abs/1409.1556>.

44. *He Kaiming, Zhang Xiangyu, Ren Shaoqing, Sun Jian.* Deep Residual Learning for Image Recognition. — 2015. — URL: <https://arxiv.org/abs/1512.03385>.
45. *Dosovitskiy Alexey, Beyer Lucas, Kolesnikov Alexander et al.* An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. — 2021. — URL: <https://arxiv.org/abs/2010.11929>.
46. Simultaneous EEG and functional MRI data during rest and sleep from humans / Yameng Gu, Lucas E. Sainburg, Feng Han, Xiao Liu // *Data in Brief*. — 2023. — . — Vol. 48. — P. 109059. — URL: <http://dx.doi.org/10.1016/j.dib.2023.109059>.
47. Le Petit Prince Hong Kong (LPPHK): Naturalistic fMRI and EEG data from older Cantonese speakers / Mohammad Momenian, Zhengwu Ma, Shuyi Wu et al. — 2024. — . — URL: <http://dx.doi.org/10.1101/2024.04.24.590842>.
48. Simultaneous and independent electroencephalography and magnetic resonance imaging: A multimodal neuroimaging dataset / Jonathan Gallego-Rudolf, María Corsi-Cabrera, Luis Concha et al. // *Data in Brief*. — 2023. — . — Vol. 51. — P. 109661. — URL: <http://dx.doi.org/10.1016/j.dib.2023.109661>.
49. *Wakeman Daniel G, Henson Richard N.* A multi-subject, multi-modal human neuroimaging dataset // *Scientific Data*. — 2015. — . — Vol. 2, no. 1. — URL: <http://dx.doi.org/10.1038/sdata.2015.1>.
50. *Otsu Nobuyuki et al.* A threshold selection method from gray-level histograms // *Automatica*. — 1975. — Vol. 11, no. 285-296. — Pp. 23–27.
51. Cortical Activation While Watching Video Montage: An fMRI Study / Daniel Anderson, Katherine Fite, Nicole Petrovich, Joy Hirsch // *Media Psychology - MEDIA PSYCHOL*. — 2006. — 02. — Vol. 8. — Pp. 7–24.
52. *Ho Jonathan, Jain Ajay, Abbeel Pieter.* Denoising Diffusion Probabilistic Models. — 2020. — URL: <https://arxiv.org/abs/2006.11239>.