

Декодирование визуальной информации из сигналов мозга на основе пространственно-временных характеристик

Даниил Дмитриевич Дорин

Научный руководитель: к.ф.-м.н. А. В. Грабовой

Кафедра интеллектуальных систем ФПМИ МФТИ

Специализация: Интеллектуальный анализ данных

Направление: 09.04.01 Информатика и вычислительная техника

Москва — 2026

Декодирование визуальных стимулов из сигналов мозга

Цель исследования

Разработать метод декодирования визуальных стимулов по мультимодальным сигналам мозга на основе пространственно-временных характеристик.

Задача

Предложить метод декодирования временных рядов фМРТ в условиях ограниченного объема выборки. Показать повышение качества при использовании нескольких модальностей.

Методы решения

1. Учесть время через анализ гемодинамического лага.
2. Описать пространственную структуру фМРТ с помощью масок активности и римановой геометрии.
3. Добавить модальность ЭЭГ для демонстрации дополняющих характеристик.

Постановка задачи

Пусть $\mathcal{X}_{(m)}$ обозначает пространство наблюдений модальности m , где $m = 1, \dots, M$. Тогда совместное пространство нейробиологических данных

$$\mathcal{X} = \mathcal{X}_{(1)} \times \dots \times \mathcal{X}_{(M)}.$$

Визуальный стимул или его характеристика $y \in \mathcal{Y}$. Требуется построить отображение декодирования

$$g : \mathcal{X} \rightarrow \mathcal{Y}.$$

Частные случаи

Классификация временных рядов фМРТ

$$g : \mathcal{X}_f \rightarrow \{1, \dots, C\}.$$

Реконструкция изображений по совместным фМРТ–ЭЭГ

$$g : \mathcal{X}_f \times \mathcal{X}_e \rightarrow \mathcal{Y}.$$

Линейная модель прогнозирования фМРТ-отклика

Сигнал фМРТ возникает с **гемодинамическим лагом** Δt относительно стимула. Для согласования их временных шкал решается обратная к декодированию задача.

Авторегрессионная марковская модель

$$\mathbf{g}(\mathbf{y}_{k_\ell - \nu \Delta t}) = \mathbf{X}_\ell - \mathbf{X}_{\ell-1}, \quad k_\ell = \frac{\ell \cdot \nu}{\mu},$$


где μ, ν – частоты дискретизации фМРТ и видеоряда, а лаг Δt сдвигает стимул в прошлое.

Параметры линейной модели $\mathbf{W}$ оцениваются на обучающей выборке, лаг Δt – по ошибке восстановления на тестовой:

$$\widehat{\mathbf{W}}(\Delta t) = \arg \min_{\mathbf{W}} \sum_{\ell \in \text{train}} \|\mathbf{g}(\mathbf{y}_{k_\ell - \nu \Delta t}) - (\mathbf{X}_\ell - \mathbf{X}_{\ell-1})\|_2^2 + \lambda \|\mathbf{W}\|_F^2,$$


Оценка гемодинамического лага

Модель обучается индивидуально для испытуемого при каждом Δt ; MSE усредняется по вокселям и объектам тестовой выборки.



Зависимость MSE от Δt имеет минимум; на локализованной зрительной коре он отчетливо выражен. Полученное значение согласуется с нейрофизиологическими оценками.

Схема метода классификации фМРТ



Метод строится из двух этапов – извлечение масок активности головного мозга для каждой категории стимула и классификация с учетом полученных масок.

Метод классификации временных рядов фМРТ

Отображение $g : \mathcal{X}_f \rightarrow \{1, \dots, C\}$ – суперпозиция $g = \varphi \circ \psi \circ \mathcal{A}$

$\mathcal{A} : \mathcal{X}_f \rightarrow \mathbb{R}^{\tau \times X/k_s \times Y/k_s \times Z/k_s}$ – Average Pooling

$\psi : \mathbb{R}^{\tau \times X/k_s \times Y/k_s \times Z/k_s} \rightarrow \mathbb{R}^d$ – векторизатор

$\varphi : \mathbb{R}^d \rightarrow \{1, \dots, C\}$ – классификатор (Logistic Regression)

Отображение ψ – конкатенация $\psi = \psi_1 \oplus \dots \oplus \psi_C$

$$\psi_k : \mathbb{R}^{\tau \times X/k_s \times Y/k_s \times Z/k_s} \rightarrow \mathbb{R}^{d_k}, \quad \psi_k = \pi_k \circ f_k, \quad d = \sum_{k=1}^C \underbrace{\frac{h_k(h_k + 1)}{2}}_{d_k},$$


$f_k : \mathbb{R}^{\tau \times X/k_s \times Y/k_s \times Z/k_s} \rightarrow \mathbb{R}^{h_k \times \tau}$ применяет маску активности $\mathcal{M}^k$,

$\pi_k : \mathbb{R}^{h_k \times \tau} \rightarrow \mathbb{R}^{d_k}$ проекция на риманово касательное пространство,

где h_k – число ненулевых элементов в $\mathcal{M}^k$ – сжатая маска активности класса k .

Проекция на риманово касательное пространство


Ковариационная матрица $\mathbf{R}_j$ проецируется на касательное пространство $T_{\mathbf{R}}$ в точке $\mathbf{R}$ с использованием отображения $\text{Log}_{\mathbf{R}}(\mathbf{R}_j)$. Полученная проекция $\mathbf{P}_j$ затем отображается обратно на риманово многообразие $\mathcal{R}$ с использованием $\text{Exp}_{\mathbf{R}}(\mathbf{P}_j)$.




- ▶ $\delta_{\mathcal{R}}(\mathbf{R}, \mathbf{R}_j)$ — геодезическое расстояние между $\mathbf{R}$ и $\mathbf{R}_j$
- ▶ $\text{Log}_{\mathbf{R}}(\mathbf{R}_j) = \mathbf{R}^{\frac{1}{2}} \log \left(\mathbf{R}^{-\frac{1}{2}} \mathbf{R}_j \mathbf{R}^{-\frac{1}{2}} \right) \mathbf{R}^{\frac{1}{2}} \in T_{\mathbf{R}}$
- ▶ $\text{Exp}_{\mathbf{R}}(\mathbf{P}_j) = \mathbf{R}^{\frac{1}{2}} \exp \left(\mathbf{R}^{-\frac{1}{2}} \mathbf{P}_j \mathbf{R}^{-\frac{1}{2}} \right) \mathbf{R}^{\frac{1}{2}} \in \mathcal{R}$

Анализ алгоритма декодирования активности мозга


- ▶ Рассматривается датасет Нахбу et al. Взяты данные фМРТ 1-го испытуемого.
- ▶ Частота снимков $\mu = 2.5 \text{ с}^{-1}$, число областей $h = 10$, размер ядра $k_s = 4$.



(a) Алгоритм



(b) Статистически
значимые области



(c) Разметка
нейробиологов

Полученные области покрывают разметку нейробиологов. Корреляция взвешенных областей со стимулом стат. значима.

Анализ компонент и сравнение с нейросетями

Рассматривается датасет Naхby et al., состоящий из данных 6 испытуемых, объём $N = 96$, число классов $C = 8$. Тестовая выборка – 20%. Метрики усреднены по 6 выборкам. Статистическая значимость обозначена $*p < .05$, $**p < .005$.

Анализ исключением компонент. Рассматриваются 3 упрощённые модели. Указаны 95% доверительные интервалы.

Method	Accuracy	Macro F1-Score	Micro F1-Score	Accuracy CI	Macro F1 CI	Micro F1 CI
Ours, w/o TSM	0.24 ± 0.11*	0.22 ± 0.11*	0.24 ± 0.11*	[0.11, 0.37]	[0.09, 0.36]	[0.10, 0.37]
Ours, w/o Class Masks	0.25 ± 0.13*	0.23 ± 0.13*	0.25 ± 0.13*	[0.09, 0.41]	[0.07, 0.39]	[0.09, 0.41]
Ours, Original Mask	0.10 ± 0.05**	0.09 ± 0.04**	0.10 ± 0.05**	[0.04, 0.16]	[0.03, 0.14]	[0.04, 0.16]
Ours	0.61 ± 0.04	0.56 ± 0.03	0.61 ± 0.04	[0.56, 0.66]	[0.52, 0.60]	[0.56, 0.66]

Сравнение с нейросетевыми решениями.

Model	Accuracy	Macro F1-Score	Micro F1-Score	Accuracy CI	Macro F1 CI	Micro F1 CI
Original Mask & LSTM	0.12 ± 0.02**	0.03 ± 0.01**	0.12 ± 0.02**	[0.09, 0.14]	[0.02, 0.04]	[0.09, 0.14]
Original Mask & Attention	0.14 ± 0.04**	0.04 ± 0.03**	0.14 ± 0.04**	[0.11, 0.18]	[0.02, 0.07]	[0.11, 0.18]
Ours, Logistic Regression φ	0.61 ± 0.04	0.56 ± 0.03	0.61 ± 0.04	[0.56, 0.66]	[0.52, 0.60]	[0.56, 0.66]

Реконструкция стимула по данным фМРТ–ЭЭГ


Задан датасет триплетов (фМРТ, ЭЭГ, изображение):

$$\mathcal{D} = \{(\mathbf{F}_i, \mathbf{E}_i, \mathbf{I}_i) \mid i = 1, \dots, N\}, \quad (\mathbf{F}_i, \mathbf{E}_i) \in \mathcal{X}_f \times \mathcal{X}_e, \quad \mathbf{I}_i \in \mathcal{Y}.$$

Требуется построить отображение $g : \mathcal{X}_f \times \mathcal{X}_e \rightarrow \mathcal{Y}$.

Решение в два этапа:

Контрастивное обучение объединенных представлений фМРТ–ЭЭГ и реконструкция стимулов с помощью двустадийной диффузионной генерации.



Контрастивное обучение представлений фМРТ-ЭЭГ

Используется косинусное расстояние между эмбедингами для вычисления матрицы логитов $\mathbf{L}$:


$$\mathbf{z}_I^n = \frac{\mathbf{Z}_I}{\|\mathbf{Z}_I\|}, \quad \mathbf{z}_c^n = \frac{\mathbf{Z}_c}{\|\mathbf{Z}_c\|}, \quad \mathbf{L} = \mathbf{Z}_I^n (\mathbf{Z}_c^n)^\top \cdot e^\tau$$

где τ — обучаемый параметр температуры.

Симметричная контрастивная функция потерь

$$\mathcal{L} = -\frac{1}{2B} \sum_{b=0}^{B-1} \log \left(\frac{\exp(\mathbf{L}_{bb})}{\sum_{j=0}^{B-1} \exp(\mathbf{L}_{bj})} \right) + \log \left(\frac{\exp(\mathbf{L}_{bb})}{\sum_{i=0}^{B-1} \exp(\mathbf{L}_{ib})} \right)$$

Здесь $\mathbf{L}_{ij}$ — это элемент матрицы логитов $\mathbf{L}$ на позиции (i, j) .



Оценка мультимодальной модели

Для оценки качества модели используется CLIP-Score, так как мы сопоставляем объединенные эмбединги с эмбедингами изображений CLIP:

$$\text{CLIP-Score}(\mathbf{z}_c, \mathbf{z}_I) = \frac{\langle \mathbf{z}_c, \mathbf{z}_I \rangle}{\|\mathbf{z}_c\| \|\mathbf{z}_I\|}.$$

Этот показатель рассчитывается для каждого триплета в тестовом наборе данных.

Модель	monkey1	monkey2	monkey5
ЭЭГ	0.231 $\pm$ 0.004	0.262 $\pm$ 0.004	0.224 $\pm$ 0.005
фМРТ	0.254 $\pm$ 0.004	0.270 $\pm$ 0.003	0.242 $\pm$ 0.003
фМРТ–ЭЭГ	0.310 $\pm$ 0.003	0.312 $\pm$ 0.004	0.284 $\pm$ 0.003
ЭЭГ & Diffusion Prior	0.542 $\pm$ 0.005	0.557 $\pm$ 0.003	0.538 $\pm$ 0.003
фМРТ & Diffusion Prior	0.564 $\pm$ 0.005	0.571 $\pm$ 0.004	0.551 $\pm$ 0.005
фМРТ–ЭЭГ & Diffusion Prior	0.668 $\pm$ 0.003	0.647 $\pm$ 0.005	0.644 $\pm$ 0.003

Мультимодальная модель фМРТ–ЭЭГ превосходит одномодальные аналоги

Примеры реконструкции изображений

Реконструкция по одновременным данным фМРТ-ЭЭГ.

1) Оригинальное изображение




2) Оригинальная реконструкция



3) Нашим методом



4) Нашим методом с Diffusion Prior



Модель успешно реконструирует семантику визуальных стимулов, просматриваемых испытуемым.

Выносятся на защиту

1. Построен метод восстановления показаний фМРТ по видеоряду, просматриваемому человеком. Обоснован учет гемодинамического лага.
2. Разработан метод классификации временных рядов фМРТ в условиях ограниченного объема выборки. Предложен алгоритм декодирования активности мозга.
3. Предложен метод реконструкции изображений по совместным сигналам фМРТ–ЭЭГ. Интеграция мультимодальности фМРТ–ЭЭГ улучшает декодирование за счет пространственно-временной комплементарности.

Публикации в журналах ВАК по теме доклада

1. **Dorin D. et al.** Forecasting fMRI Images From Video Sequences: Linear Model Analysis // Health Information Science and Systems. – 2024.
2. **Dorin D. et al.** Enhancing fMRI Data Decoding with Spatiotemporal Characteristics in Limited Dataset // Doklady Mathematics. – 2025.
3. **Dorin D. et al.** Decoding Visual Information from Neural Signals: Image Reconstruction Based on Joint fMRI and EEG Analysis // Informatika i ee Primeneniya. – 2026.