

Декодирование визуальной информации из сигналов мозга на основе пространственно-временных характеристик

Даниил Дмитриевич Дорин

Научный руководитель: к.ф.-м.н. А. В. Грабовой

Кафедра интеллектуальных систем ФПМИ МФТИ

Специализация: Интеллектуальный анализ данных

Направление: 09.04.01 Информатика и вычислительная техника

Москва — 2026

Декодирование визуальной информации из сигналов мозга

Цель исследования

Разработать метод декодирования визуальных стимулов по мультимодальным сигналам мозга на основе пространственно-временных характеристик.

Задача

Требуется предложить метод декодирования временных рядов фМРТ в условиях ограниченного объема выборки. Продемонстрировать повышение качества декодирования при совместном использовании нескольких модальностей.

Методы решения

1. Учесть временную структуру фМРТ через анализ гемодинамической задержки.
2. Описать пространственную структуру фМРТ с помощью масок активности и римановой геометрии.
3. Добавить модальность ЭЭГ для демонстрации дополняющих характеристик.

Постановка задачи

Пусть $\mathcal{X}^{(m)}$ обозначает пространство наблюдений модальности m , где $m = 1, \dots, M$. Тогда совместное пространство нейробиологических данных:

$$\mathcal{X} = \mathcal{X}^{(1)} \times \dots \times \mathcal{X}^{(M)}.$$

Визуальный стимул или его характеристика описываются элементом $\mathbf{y} \in \mathcal{Y}$. Требуется построить отображение декодирования $\mathbf{g}$:

$$\mathbf{g} : \mathcal{X} \rightarrow \mathcal{Y}.$$

Частные случаи

- ▶ Классификация временных рядов фМРТ:

$$\mathbf{g} : \mathcal{X}_f \rightarrow \{1, \dots, C\}.$$

- ▶ Реконструкция изображений по совместным фМРТ–ЭЭГ:


$$\mathbf{g} : \mathcal{X}_f \times \mathcal{X}_e \rightarrow \mathcal{Y}.$$

Анализ гемодинамической задержки

Рассматривается линейная авторегрессионная марковская модель:


$$\mathbf{g}(y_{k_\ell - \nu \Delta t}) = \mathbf{X}_\ell - \mathbf{X}_{\ell-1}, \quad k_\ell = \frac{\ell \cdot \nu}{\mu},$$

где μ и ν — частоты дискретизации фМРТ и видеоряда соответственно. Гиперпараметр Δt обеспечивает согласование временной шкалы стимула и BOLD-отклика.



Зависимость MSE от Δt имеет минимум; на локализованной зрительной коре он отчетливо выражен. Полученное значение $\Delta t \approx 5$ с согласуется с нейрофизиологическими оценками гемодинамической задержки.

Схема метода классификации фМРТ



Метод строится из двух этапов — извлечение масок активности головного мозга для каждой категории стимула и классификация с учетом полученных масок.

Метод классификации временных рядов фМРТ

Отображение $g : \mathcal{X}_f \rightarrow \{1, \dots, C\}$ представляется как $g = \varphi \circ \psi \circ \mathcal{A}$

$\mathcal{A} : \mathcal{X}_f \rightarrow \mathbb{R}^{\tau \times X/k_s \times Y/k_s \times Z/k_s}$ — Average Pooling

$\psi : \mathbb{R}^{\tau \times X/k_s \times Y/k_s \times Z/k_s} \rightarrow \mathbb{R}^d$ — векторизатор

$\varphi : \mathbb{R}^d \rightarrow \{1, \dots, C\}$ — классификатор (Logistic Regression)

Отображение ψ представляется как конкатенация $\psi = \psi_1 \oplus \dots \oplus \psi_C$

$$\psi_k : \mathbb{R}^{\tau \times X/k_s \times Y/k_s \times Z/k_s} \rightarrow \mathbb{R}^{d_k}, \quad \psi_k = \pi_k \circ f_k, \quad d = \sum_{k=1}^C d_k, \quad d_k = \frac{h_k(h_k + 1)}{2},$$


$f_k : \mathbb{R}^{\tau \times X/k_s \times Y/k_s \times Z/k_s} \rightarrow \mathbb{R}^{h_k \times \tau}$ применяет маску активности $\mathcal{M}^k$,

$\pi_k : \mathbb{R}^{h_k \times \tau} \rightarrow \mathbb{R}^{d_k}$ проекция на риманово касательное пространство,

где h_k — число ненулевых элементов в $\mathcal{M}^k$ — сжатая маска активности класса k .

Проекция на риманово касательное пространство


Ковариационная матрица $\mathbf{R}_j$ проецируется на касательное пространство $T_{\mathbf{R}}$ в точке $\mathbf{R}$ с использованием отображения $\text{Log}_{\mathbf{R}}(\mathbf{R}_j)$. Полученная проекция $\mathbf{P}_j$ затем отображается обратно на риманово многообразие $\mathcal{R}$ с использованием $\text{Exp}_{\mathbf{R}}(\mathbf{P}_j)$.




- ▶ $\delta_{\mathcal{R}}(\mathbf{R}, \mathbf{R}_j)$ — геодезическое расстояние между $\mathbf{R}$ и $\mathbf{R}_j$
- ▶ $\text{Log}_{\mathbf{R}}(\mathbf{R}_j) = \mathbf{R}^{\frac{1}{2}} \log \left(\mathbf{R}^{-\frac{1}{2}} \mathbf{R}_j \mathbf{R}^{-\frac{1}{2}} \right) \mathbf{R}^{\frac{1}{2}} \in T_{\mathbf{R}}$
- ▶ $\text{Exp}_{\mathbf{R}}(\mathbf{P}_j) = \mathbf{R}^{\frac{1}{2}} \exp \left(\mathbf{R}^{-\frac{1}{2}} \mathbf{P}_j \mathbf{R}^{-\frac{1}{2}} \right) \mathbf{R}^{\frac{1}{2}} \in \mathcal{R}$

Анализ масок активности мозга


- ▶ Рассматривается датасет Нахбу et al. Взяты данные фМРТ 1-го испытуемого.
- ▶ Частота снимков $\mu = 2.5 \text{ с}^{-1}$, число областей $h = 10$, размер ядра $k_s = 4$.



(a) Алгоритм



(b) Статистически
значимые области



(c) Разметка
нейробиологов

Полученные области хорошо покрывают разметку нейробиологов. Корреляция взвешенных областей со стимулом статистически значима.

Анализ исключением компонент и сравнение с нейросетями

Рассматривается датасет Naхby et al., состоящий из данных 6 испытуемых, объем $N = 96$, число классов $C = 8$. Тестовая выборка – 20%. Метрики усреднены по 6 выборкам. Статистическая значимость обозначена $*p < .05$, $**p < .005$.

Таблица 1: Анализ исключением компонент. Рассматриваются 3 упрощенные модели.

Method	Accuracy	Macro F1-Score	Micro F1-Score	Accuracy CI	Macro F1 CI	Micro F1 CI
Ours, w/o TSM	$0.24 \pm 0.11^*$	$0.22 \pm 0.11^*$	$0.24 \pm 0.11^*$	[0.11, 0.37]	[0.09, 0.36]	[0.10, 0.37]
Ours, w/o Class Masks	$0.25 \pm 0.13^*$	$0.23 \pm 0.13^*$	$0.25 \pm 0.13^*$	[0.09, 0.41]	[0.07, 0.39]	[0.09, 0.41]
Ours, Original Mask	$0.10 \pm 0.05^{**}$	$0.09 \pm 0.04^{**}$	$0.10 \pm 0.05^{**}$	[0.04, 0.16]	[0.03, 0.14]	[0.04, 0.16]
Ours	0.61 ± 0.04	0.56 ± 0.03	0.61 ± 0.04	[0.56, 0.66]	[0.52, 0.60]	[0.56, 0.66]

Таблица 2: Сравнение с нейросетевыми архитектурами.

Model	Accuracy	Macro F1-Score	Micro F1-Score	Accuracy CI	Macro F1 CI	Micro F1 CI
Original Mask & LSTM	$0.12 \pm 0.02^{**}$	$0.03 \pm 0.01^{**}$	$0.12 \pm 0.02^{**}$	[0.09, 0.14]	[0.02, 0.04]	[0.09, 0.14]
Original Mask & Attention	$0.14 \pm 0.04^{**}$	$0.04 \pm 0.03^{**}$	$0.14 \pm 0.04^{**}$	[0.11, 0.18]	[0.02, 0.07]	[0.11, 0.18]
Ours, Logistic Regression φ	0.61 ± 0.04	0.56 ± 0.03	0.61 ± 0.04	[0.56, 0.66]	[0.52, 0.60]	[0.56, 0.66]

Реконструкция стимула по данным фМРТ–ЭЭГ

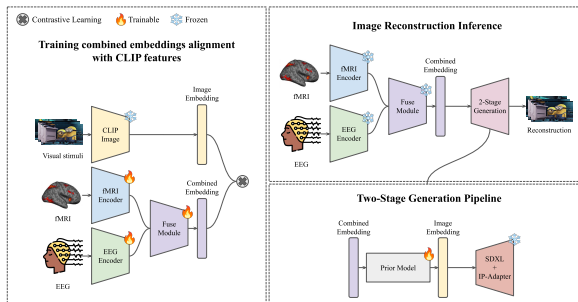
Задан датасет триплетов (фМРТ, ЭЭГ, изображение):

$$\mathcal{D} = \{(\mathbf{F}_i, \mathbf{E}_i, \mathbf{I}_i) \mid i = 1, \dots, N\}, \quad (\mathbf{F}_i, \mathbf{E}_i) \in \mathcal{X}_f \times \mathcal{X}_e, \quad \mathbf{I}_i \in \mathcal{Y}.$$

Требуется построить отображение $g : \mathcal{X}_f \times \mathcal{X}_e \rightarrow \mathcal{Y}$.

Решение в два этапа:

Контрастивное обучение объединенных представлений фМРТ–ЭЭГ и
реконструкция стимулов с помощью двустадийной диффузионной генерации.



Оценка мультимодальной модели

Для оценки качества модели используется CLIP-Score, так как мы сопоставляем объединенные эмбединги с эмбедингами изображений CLIP:

$$\text{CLIP-Score}(\mathbf{z}_c, \mathbf{z}_I) = \frac{\langle \mathbf{z}_c, \mathbf{z}_I \rangle}{\|\mathbf{z}_c\| \|\mathbf{z}_I\|}.$$

Этот показатель рассчитывается для каждого триплета в тестовом наборе данных.

Модель	monkey1	monkey2	monkey5
ЭЭГ	0.231 $\pm$ 0.004	0.262 $\pm$ 0.004	0.224 $\pm$ 0.005
фМРТ	0.254 $\pm$ 0.004	0.270 $\pm$ 0.003	0.242 $\pm$ 0.003
фМРТ–ЭЭГ	0.310 $\pm$ 0.003	0.312 $\pm$ 0.004	0.284 $\pm$ 0.003
ЭЭГ & Diffusion Prior	0.542 $\pm$ 0.005	0.557 $\pm$ 0.003	0.538 $\pm$ 0.003
фМРТ & Diffusion Prior	0.564 $\pm$ 0.005	0.571 $\pm$ 0.004	0.551 $\pm$ 0.005
фМРТ–ЭЭГ & Diffusion Prior	0.668 $\pm$ 0.003	0.647 $\pm$ 0.005	0.644 $\pm$ 0.003

Наилучшие значения достигаются при совместном использовании фМРТ и ЭЭГ.

Примеры реконструкции изображений

Реконструкция по одновременным данным фМРТ-ЭЭГ.

1) Оригинальное изображение




2) Оригинальная реконструкция



3) Нашим методом



4) Нашим методом с Diffusion Prior



Модель успешно реконструирует семантику визуальных стимулов, просматриваемых испытуемым.

1. Построен метод восстановления показаний фМРТ по видеоряду, просматриваемому человеком. Обоснован учет гемодинамической задержки для согласования стимула и BOLD-отклика.
2. Разработан метод классификации временных рядов фМРТ в условиях ограниченного объема выборки. Предложен алгоритм декодирования активности мозга. Проведено сравнение с нейросетевыми подходами.
3. Предложен метод реконструкции изображений по совместным сигналам фМРТ–ЭЭГ. Интеграция мультимодальности фМРТ–ЭЭГ улучшает декодирование за счет пространственно-временной комплементарности.

Список работ автора по теме доклада

Публикации в журналах ВАК

1. **Dorin D., Kiselev N. et al.** Forecasting fMRI Images From Video Sequences: Linear Model Analysis // Health Information Science and Systems. — 2024.
2. **Dorin D. et al.** Enhancing fMRI Data Decoding with Spatiotemporal Characteristics in Limited Dataset // Doklady Mathematics. — 2025.
3. **Dorin D. et al.** Decoding Visual Information from Neural Signals: Image Reconstruction Based on Joint fMRI and EEG Analysis // Informatika i ee Primeneniya. — 2026.

Выступления с докладом

1. Пространственно-временные методы анализа временных рядов // 66-я Всероссийская научная конференция МФТИ, 2024.
2. Улучшение декодирования фМРТ в условиях ограниченной выборки // 67-я Всероссийская научная конференция МФТИ, 2025.
3. Декодирование визуальных стимулов из мультимодальных сигналов мозга // ММРО-2025.
4. Улучшение декодирования данных фМРТ в условиях ограниченного набора данных // AI Journey 2025.